

SVM习题

浙江大学
赵洲

题目

【单选题】对于在原空间中线性不可分问题，支持向量机Q（ ）。

- A. 无法处理
- B. 在原空间中寻找线性函数Q划分数据
- C. 将数据映射到核空间中
- D. 在原空间中寻找非线性函数的划分数据

解答

正确答案: C. 将数据映射到核空间中

1. A. 无法处理

错误原因: 支持向量机可以通过核函数将数据映射到更高维核空间中, 使得问题变得线性可分, 而非完全无法处理。

2. B. 在原空间中寻找线性函数 Q 划分数据

错误原因: 如果问题在原空间中线性不可分, 支持向量机无法在原空间中找到有效的线性函数进行划分。

3. D. 在原空间中寻找非线性函数的划分数据

错误原因: 支持向量机本身并不直接在原空间寻找非线性划分, 而是通过核函数将数据映射到高维核空间, 从而实现线性划分。

题目

【单选题】 关于支持向量机中硬间隔和软间隔的说法错误的是（ ）。

- A. 软间隔有利于获取更大的分类间隔
- B. 软间隔允许一定的样本分类错误
- C. 硬间隔有利于消除模型的过拟合
- D. 硬间隔要求所有数据分类完全准确，不允许出现错误

解答

1.A. 软间隔有利于获取更大的分类间隔

错误原因: 软间隔允许部分数据点违反间隔约束, 从而获取更大的总体分类间隔。

2.B. 软间隔允许一定的样本分类错误

错误原因: 软间隔的主要特点就是允许一定的分类错误以增强模型的泛化能力。

3.C. 硬间隔有利于消除模型的过拟合Q

正确原因: 硬间隔要求严格划分所有数据点, 容易导致模型过拟合, 特别是在数据存在噪声或分布不完全线性可分时。

4.D. 硬间隔要求所有数据分类完全准确, 不允许出现错误

错误原因: 这正是硬间隔的定义。

题目

【单选题】 关于各类 核函数 Q 的优缺点说法错误的是：（ ）。

- A. 高斯核能够应对较为复杂的数据
- B. 线性核计算简单，可解释性强
- C. 多项式核需要多次特征转换
- D. 高斯核计算简单，不容易过拟合

解答

1.A. 高斯核能够应对较为复杂的数据

错误原因: 高斯核的强大之处在于其非线性能力, 适合处理复杂数据。

2.B. 线性核计算简单, 可解释性强

错误原因: 线性核不需要额外的映射操作, 计算效率高, 结果也容易解释。

3.C. 多项式核需要多次特征转换

错误原因: 多项式核确实涉及到对原始特征的多次转换操作。

4.D. 高斯核计算简单, 不容易过拟合

正确原因: 高斯核计算复杂度较高, 此外如果参数选择不当, 可能导致过拟合风险。

题目

支持向量机的基本思想是什么？

解答

支持向量机的基本思想是什么？

A:SVM分类器在类之间拟合可能的最宽的“街道”。换言之，它的目的是使决策边界之间的间隔最大化，该决策边界分隔两个类别和训练实例。SVM执行软间隔分类时，实际上是在完美分隔两个类和拥有尽可能最宽的街道之间寻找折中方法（也就是允许少数实例最终还是落在街道上）。还有一个关键点是在训练非线性数据集时，记得使用核函数Q。

题目

什么是支持向量？

解答

什么是支持向量？

A: 决策边界完全由位于“街道”边缘的实例所决定（或者称之为“支持”）。这些实例被称为支持向量。位于“街道”之上的实例被称为支持向量，这也包括处于边界上的实例。非支持向量的实例（也就是街道之外的实例）完全没有任何影响。你可以选择删除它们然后添加更多的实例，或者将它们移开，只要一直在街道之外，它们就不会对决策边界产生任何影响。计算预测结果只会涉及支持向量，而不涉及整个训练集。

题目

使用SVM时，对输入值进行缩放为什么重要？

解答

使用SVM时，对输入值进行缩放为什么重要？

A：支持向量机拟合类别之间可能的、最宽的“街道”，所以如果训练集不经缩放，SVM将趋于忽略值较小的特征。

题目

SVM 分类器。在对实例进行分类时，会输出信心分数吗？概率呢？

解答

SVM 分类器。在对实例进行分类时，会输出信心分数吗？概率呢？

A：支持向量机分类器能够输出测试实例与决策边界之间的距离，你可以将其用作信心分数。但是这个分数不能直接转化成类别概率的估算。如果创建SVM时，在Scikit-Learn

中设置probability=True，那么训练完成后，算法Q将使用逻辑回归对

SVM分数进行校准（对训练数据额外进行5-折交叉验证的训练），从而得到概率值。这会给SVM添加predict_proba（）和predict_log_proba（）两种方法。

题目

如果训练集有成百万个实例和几百个特征，你应该使用SVM原始问题还是对偶问题来训练模型？

解答

如果训练集有成百万个实例和几百个特征，你应该使用SVM原始问题还是对偶问题来训练模型？

A：使用SVM原始问题。这个问题仅适用于线性支持向量机，因为核SVM只能使用对偶问题。对于SVM问题来说，原始形式的计算复杂度与训练实例 m 的数量成正比，而其对偶形式的计算复杂度与某个介于 m^2 和 m^3 之间的数量成正比。所以如果实例的数量以百万计，一定要使用原始问题，因为对偶问题会非常慢。

当训练实例的数量小于特征数量时，解决对偶问题比原始问题更迅速。

题目

假设你用RBF核训练了一个SVM分类器，看起来似乎对训练集欠拟合，你应该提升还是降低gamma? C呢?

解答

假设你用RBF核训练了一个SVM分类器，看起来似乎对训练集欠拟合，你应该提升还是降低gamma? C呢?

A: 如果一个使用RBF核训练的支持向量机对训练集欠拟合，可能是由于过度正则化导致的。你需要提升gamma或C（或同时提升二者）来降低正则化。

正则化可以解决过拟合Q问题，降低正则化参数可以解决欠拟合问题。

Gamma提升或C提升 正则化降低——解决欠拟合问题

Gamma降低或C降低 正则化提升——解决过拟合问题

题目

如果使用现成二次规划求解器，你应该如何设置QP参数（ H 、 f 、 A 和 b ）来解决软间隔线性SVM分类器问题？

解答

如果使用现成二次规划求解器，你应该如何设置QP参数（H、f、A和b）来解决软间隔线性SVM分类器问题？

A：我们把硬间隔问题的QP参数定义为 H' 、 f' 、 A' 及 b' 。软间隔问题的QP参数还包括 m 个额外参数（ $n_p = n + 1 + m$ ）及 m 个额外约束（ $n_c = 2m$ ）。它们可以这样定义：

H 等于在 H' 右侧和底部分别加上 m 列和 m 行个0：

$$H = \begin{bmatrix} H' & \dots & 0 \\ \dots & \dots & \dots \\ 0 & \dots & 0 \end{bmatrix}$$

解答（接上页）

f 等于有 m 个附加元素的 f' ，全部等于超参数 C 的值。

b 等于有 m 个附加元素的 b' ，全部等于0。

A 等于在 A' 的右侧添加一个 $m \times m$ 的单位矩阵 I_m ，在这个单位矩阵的正下方再添加单位矩阵 $-I_m$ ，剩余部分为0：

$$A = \begin{bmatrix} A' & I_m \\ 0 & -I_m \end{bmatrix}$$

题目

题目叙述: 线性支持向量机还可以定义为以下形式:

$$\min_{w,b,\zeta} \frac{1}{2} ||w||^2 + C \sum_{i=1}^N \zeta_i^2$$

$$\text{s.t. } y_i(w \cdot x_i + b) \geq 1 - \zeta_i, \forall i = 1, 2, \dots, N$$

$$\zeta_i \geq 0, \forall i = 1, 2, \dots, N$$

试求其对偶形式

解答

首先在原定义形式下, 改写为拉格朗日函数形式:

$$L(w, b, \zeta, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \zeta_i^2 - \sum_{i=1}^N \alpha_i [y_i(w \cdot x_i + b) - 1 + \zeta_i] - \sum_{i=1}^N \mu_i \zeta_i$$

$$\text{s.t. } \alpha_i \geq 0, \mu_i \geq 0, \forall i = 1, 2, \dots, N$$

拉格朗日形式原问题是求解:

$$\min_{w, b, \zeta} \max_{\alpha, \mu} L(w, b, \zeta, \alpha, \mu)$$

通过对偶问题转化为求解:

$$\max_{\alpha, \mu} \min_{w, b, \zeta} L(w, b, \zeta, \alpha, \mu)$$

解答

首先求极小化 $\min_{w,b,\zeta} L(w, b, \zeta, \alpha, \mu)$

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \zeta_i} = 2C\zeta_i - \alpha_i - \mu_i = 0, \forall i = 1, 2, \dots, N$$

解答

将以上三个条件代回拉格朗日函数中可以求得:

$$\min_{w,b,\zeta} L(w, b, \zeta, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i - \frac{1}{4C^2} \sum_{i=1}^N (\alpha_i + \mu_i)^2$$

如此便得到了问题的最终对偶形式:

$$\min_{\alpha, \mu} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i + \frac{1}{4C^2} \sum_{i=1}^N (\alpha_i + \mu_i)^2$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0, \forall i = 1, 2, \dots, N$$

$$\alpha_i \geq 0, \mu_i \geq 0, \forall i = 1, 2, \dots, N$$

计算题

- Q1: Support Vector Regression (SVR)
- In class, we discussed support vector classification but did not cover the regression problem. Here you derive the dual form of Support Vector Regression (SVR). The training data is $(x_1, y_1), \dots, (x_n, y_n)$, where $x_i \in \mathbb{R}^m, y_i \in \mathbb{R}$.
- A frequently used loss function for regression is the epsilon-sensitive loss:
$$L_\epsilon(x, y, f) = \max(0, |y - f(x)| - \epsilon),$$
where x is the input, y is the output, and $f(x)$ is the function predicting the label.
- The SVR cost function is:
$$\frac{1}{2}|w|^2 + C \sum_{i=1}^n L_\epsilon(x_i, y_i, f),$$
where $f(x) = w^T x$ and $C, \epsilon > 0$.

计算题

- Q1: Support Vector Regression (SVR)
- 1. Introduce appropriate slack variables, and rewrite this problem as a quadratic problem (i.e. quadratic objective with linear constraints). This form is called the Primal form of support vector regression.

解答

- Q1: Support Vector Regression (SVR)
- 1. Introduce appropriate slack variables, and rewrite this problem as a quadratic problem (i.e. quadratic objective with linear constraints). This form is called the Primal form of support vector regression.
- Introduce slack variables ξ_i and ξ_i^* to account for errors outside the ϵ -tube:

$$\begin{aligned}y_i - \langle w, x_i \rangle - \epsilon &\leq \xi_i, \\ \langle w, x_i \rangle - y_i - \epsilon &\leq \xi_i^*, \\ \xi_i, \xi_i^* &\geq 0.\end{aligned}$$

- The primal problem becomes:

$$\min_{w, \xi, \xi^*} \frac{1}{2} |w|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*),$$

subject to:

$$\begin{aligned}y_i - \langle w, x_i \rangle - \epsilon &\leq \xi_i, \\ \langle w, x_i \rangle - y_i - \epsilon &\leq \xi_i^*, \\ \xi_i, \xi_i^* &\geq 0.\end{aligned}$$

计算题

- Q1: Support Vector Regression (SVR)
- 2. Write down the Lagrangian function for the above primal form

解答

- Q1: Support Vector Regression (SVR)
- 2. Write down the Lagrangian function for the above primal form.
- The Lagrangian for the primal form is:

$$L(w, \xi, \xi', a, a', \beta, \beta') = \frac{1}{2} |w|^2 + C \sum_{i=1}^n (\xi_i + \xi'_i) \cdot \sum_{i=1}^n \beta_i \xi_i - \sum_{i=1}^n \beta_i^* \xi_i^* \cdot \sum_{i=1}^n a_i (\epsilon + \xi_i - y_i + \langle w, x_i \rangle) \cdot \sum_{i=1}^n a_i^* (\epsilon + \xi_i^* + y_i - \langle w, x_i \rangle),$$

where $a_i, a_i', \beta_i, \beta_i' \geq 0$, for $i = 1, \dots, n$.

计算题

- Q1: Support Vector Regression (SVR)
- 3. Using the Karush Kunh Tucker conditions derive the dual form.

解答

- Q1: Support Vector Regression (SVR)
- 3. Using the Karush Kunh Tucker conditions derive the dual form.

- **Solutions:**

- To derive the dual, solve:

$$\begin{aligned}(w, \xi, \xi^*, a, a^*, \beta, \beta^*) &= \min_{w, \xi, \xi^*} \max_{a, a^*, \beta, \beta^*} L(w, \xi, \xi^*, a, a^*, \beta, \beta^*) \\ &= \max_{a, a^*, \beta, \beta^*} \min_{w, \xi, \xi^*} L(w, \xi, \xi^*, a, a^*, \beta, \beta^*)\end{aligned}$$

- 1. Stationarity (derivatives w.r.t primal variables):

- $\frac{\partial L}{\partial w} = w - \sum_{i=1}^n (a_i - a_i^*) x_i = 0 \Rightarrow w = \sum_{i=1}^n (a_i - a_i^*) x_i.$

$$\frac{\partial L}{\partial \xi_i} = C - a_i - \beta_i = 0,$$

$$\frac{\partial L}{\partial \xi_i^*} = C - a_i^* - \beta_i^* = 0.$$

解答

- From this:

$$0 \leq \beta_i = C - a_i,$$

$$0 \leq \beta_i^* = C - a_i^*.$$

- 2. Substituting back, the dual problem is:

$$\max_{a, a^*} -\frac{1}{2} \sum_{i,j=1}^n (a_i - a_i^*) (a_j - a_j^*) \langle x_i, x_j \rangle + \sum_{i=1}^n (a_i + a_i^*) + \sum_{i=1}^n y_i (a_i - a_i^*),$$

subject to:

$$0 \leq a_i, a_i^* \leq C,$$

- Note that if you use $\langle w, x \rangle + b$ instead of $\langle w, x \rangle$, then you have an extra constraint:

$$\sum_{i=1}^n (a_i - a_i^*) = 0.$$

计算题

- Q1: Support Vector Regression (SVR)
- 4. Can we use quadratic optimization solvers to solve the dual problem?

解答

- Q1: Support Vector Regression (SVR)
- 4. Can we use quadratic optimization solvers to solve the dual problem?
- **Solutions:**
- Yes, the problem has a quadratic objective with linear constraints and can be solved using Quadratic Programming solvers.

计算题

- Q1: Support Vector Regression (SVR)
- 5. How would you define support vectors in this problem?

解答

- Q1: Support Vector Regression (SVR)
- 5. How would you define support vectors in this problem?
- **Solutions:**
- The KKT complementary slackness conditions are as follows.

$$a_i(\epsilon + \xi_i - y_i + \langle w, x_i \rangle) = 0 \quad (1)$$

$$a_i^*(\epsilon + \xi_i^* + y_i - \langle w, x_i \rangle) = 0 \quad (2)$$

$$\beta_i \xi_i = 0 \quad (3)$$

$$\beta_i^* \xi_i^* = 0 \quad (4)$$

for all $i = 1, \dots, n$.

Equation(1) implies that if $a_i > 0$, then $(\epsilon + \xi_i - y_i + \langle w, x_i \rangle) = 0$

解答(续)

- Q1: Support Vector Regression (SVR)
- 5. How would you define support vectors in this problem?
- **Solutions:**
- Now, if $\xi_i = 0$, then it implies that x_i is on the border of the ϵ -tube, therefore x_i is a margin support vector.
- If $\xi_i > 0$, then it means we are outside of the ϵ -tube.
- These x_i vectors are the non-margin support vectors. Similar reasoning holds for ξ_i^* and a_i^* .

计算题

- Q1: Support Vector Regression (SVR)
- 6. Write down the equation that can be used for predicting the label of an unseen sample X .

解答

- Q1: Support Vector Regression (SVR)
- 6. Write down the equation that can be used for predicting the label of an unseen sample X .
- **Solutions:**
- Since for prediction we use $f(x) = \langle w, x \rangle$, and $w = \sum_{i=1}^n (a_i - a_i^*)$, therefore:
- The predicted label for an unseen sample x is:

$$f(x) = \sum_{i=1}^n (a_i - a_i^*) \langle x_i, x \rangle.$$

计算题

- Q1: Support Vector Regression (SVR)
- 7. Is it possible to kernelize this algorithm?

解答

- Q1: Support Vector Regression (SVR)
- 7. Is it possible to kernelize this algorithm?
- Solutions:
- Yes, we can write the above equation in the kernel form.

$$f(x) = \sum_{i=1}^n (a_i - a_i^*) k(x_i, x),$$

where $k(x_i, x)$ is the kernel function.

计算题

- Q1: Support Vector Regression (SVR)
- 8. What happens if we change ϵ ?

解答

- Q1: Support Vector Regression (SVR)
- 8. What happens if we change ϵ ?
- **Solutions:**
- ϵ plays the opposite role of C . The smaller the value of ϵ , the harder SVM tries to fit smaller errors around the learnt SVM function, and leads to a more complex model. Smaller ϵ also leads to a less sparse solution (more support vectors).
- Small ϵ – More complex model. Low Bias, High variance.
- Large ϵ – Less complex model. High Bias, Low Variance.

计算题

- Q1: Support Vector Regression (SVR)
- 9. What happens if we change C ?

解答

- Q1: Support Vector Regression (SVR)

- 9. What happens if we change C ?

- **Solutions:**

- C plays a similar role as it did during classification. It is a measure of how strongly we penalize errors. It should be tuned for bias vs variance with model selection. The higher the value of C , the larger the tendency of SVM to penalize errors and overfit the data. The lower the value of C , the larger its tendency to ignore errors and underfit the data.

- Large C – More complex model. Low Bias, High variance.

- Small C – Less complex model. High Bias, Low Variance.

参考文献

- CMU 10-701
- Stanford CS229
- 统计学习方法
- CMU 10-715
- UTORONTO CSC2515

End