

机器学习第二次随堂测试

浙江大学

赵洲

单选题

- 1) 哪一个机器学习的合理定义?
- A. 机器学习从标记的数据中学习
- B. 机器学习能使计算机能够在没有明确编程的情况下学习
- C. 机器学习是计算机编程的科学
- D. 机器学习是允许机器人智能行动领域

单选题

- 1) 哪一个是机器学习的合理定义? (B)
- A. 机器学习从标记的数据中学习
- B. 机器学习能使计算机能够在没有明确编程的情况下学习
- C. 机器学习是计算机编程的科学
- D. 机器学习是允许机器人智能行动领域

单选题

- A. 机器学习从标记的数据中学习
- 不完全正确。虽然监督学习依赖标记数据，但机器学习包括多种方法，如无监督学习（使用未标记数据）和强化学习，所以仅指“从标记的数据中学习”是不完整的。
- B. 机器学习能使计算机能够在没有明确编程的情况下学习
- 正确。机器学习的核心定义是：通过数据训练模型，使计算机能够从数据中学习规律，而不需要手工编写每个决策逻辑。这是机器学习区别于传统编程的关键。
- C. 机器学习是计算机编程的科学
- 不完全正确。机器学习是一种通过数据驱动的方法实现学习的技术，虽然涉及编程，但不等同于计算机编程的科学。
- D. 机器学习是允许机器人智能行动领域
- 不完全正确。机器学习是人工智能的一个分支，可以应用于机器人，但不单单限于使机器人智能行动。

单选题

- 2) 在前馈神经网络中，各神经元分别属于不同的层。整个网络中无反馈，信号从输入层向输出层单向传播，可用一个_____表示。
- A. 有向无环图;
- B. 有环图;
- C. 简单循环图;
- D. 二叉树;

单选题

■ 2) 在前馈神经网络中，各神经元分别属于不同的层。整个网络中无反馈，信号从输入层向输出层单向传播，可用一个____A_____表示。

■ A. 有向无环图;

B. 有环图;

■ C. 简单循环图;

D. 二叉树;

单选题

■ A. 有向无环图 (Directed Acyclic Graph, DAG)

■

- 正确。在前馈神经网络中，信号从输入层向输出层单向传播，没有反馈和循环。这种结构可以被表示为一个有向无环图，因为数据流单向传递且不存在闭环。

■ B. 有环图

■

- 错误。有环图表示存在反馈环路，而前馈神经网络没有反馈，信号只能单向传播。

■ C. 简单循环图

■

- 错误。简单循环图表示网络中存在循环路径，而前馈神经网络没有任何循环或反馈。

■ D. 二叉树

■

- 错误。二叉树是一种特殊的树状结构，其中每个节点最多有两个子节点。前馈神经网络的结构并非树形，也没有这种约束。

单选题

- 3) 经验风险最小化原则很容易导致模型在训练集上错误率很低,但是在未知数据上错误率很高。这就是所谓的_____。
- A. 欠拟合;
- B. 过拟合;
- C. 正则化;
- D. 样本不足;

单选题

- 3) 经验风险最小化原则很容易导致模型在训练集上错误率很低,但是在未知数据上错误率很高。这就是所谓的__B__。
- A. 欠拟合;
- B. 过拟合;
- C. 正则化;
- D. 样本不足;

单选题

■ A. 欠拟合

- • 错误。欠拟合指模型过于简单，无法很好地捕捉训练数据的模式，导致在训练集和测试集上的错误率都很高。

■ • B. 过拟合

- • 正确。过拟合指模型过度学习了训练集的数据，包括噪声和细节，导致训练集上的错误率很低，但在未知数据（测试集）上的表现较差，泛化能力不足。经验风险最小化容易导致这种情况，因为模型会过分追求在训练集上表现完美。

■ C. 正则化

- • 错误。正则化是一种解决过拟合的手段，通过在损失函数中引入惩罚项来限制模型复杂度，提升泛化能力。

■ • D. 样本不足

- • 错误。样本不足指训练数据量太少，无法提供足够的信息来训练一个泛化良好的模型。这通常是导致过拟合或欠拟合的原因之一，但不是这里描述的问题核心。

单选题

- 4) 关于 L1、L2 正则化下列说法正确的是？
- A. L2 正则化能防止过拟合，提升模型的泛化能力，但 L1 做不到这点
- B. L2 正则化技术又称为 Lasso Regularization
- C. L1 正则化得到的解更加稀疏
- D. L2 正则化得到的解更加稀疏

单选题

- 4) 关于 L1、L2 正则化下列说法正确的是? C
- A. L2 正则化能防止过拟合, 提升模型的泛化能力, 但 L1 做不到这点
- B. L2 正则化技术又称为 Lasso Regularization
- C. L1 正则化得到的解更加稀疏
- D. L2 正则化得到的解更加稀疏

单选题

- • A. L2 正则化能防止过拟合，提升模型的泛化能力，但 L1 做不到这点
- • 错误。
- L1 和 L2 正则化都可以防止过拟合，提升模型的泛化能力，只是效果和特性有所不同。L1 正则化还能引导稀疏解（部分权重变为 0），而 L2 正则化主要会缩小权重值但不使其为 0。
- • B. L2 正则化技术又称为 Lasso Regularization
- • 错误。
- L2 正则化称为 Ridge Regression，而 Lasso Regularization 指的是 L1 正则化。
- C. L1 正则化得到的解更加稀疏
- • 正确。
- L1 正则化通过引入权重的绝对值作为惩罚项，会使部分权重收缩为 0，从而得到稀疏解。这对特征选择很有用。
- • D. L2 正则化得到的解更加稀疏
- • 错误。
- L2 正则化通过权重的平方和作为惩罚项，会使权重趋向于较小的值，但一般不会收缩为 0。因此，L2 正则化不会得到稀疏解。

单选题

- 5) 假设你有以下数据：输入和输出都只有一个变量。使用线性回归模型 ($y=wx+b$) 来拟合数据。那么使用留一法 (Leave-One Out) 交叉验证得到的均方误差是多少？

X	Y
-1	1
1	1
2	0

- A. $10/27$ B. $39/27$
- C. $49/27$ D. $55/27$

单选题

- 5) 假设你有以下数据：输入和输出都只有一个变量。使用线性回归模型 ($y=wx+b$) 来拟合数据。那么使用留一法 (Leave-One Out) 交叉验证得到的均方误差是多少？ C

X	Y
-1	1
1	1
2	0

- A. 10/27 B. 39/27
- C. 49/27 D. 55/27

单选题

- We use Leave-One-Out Cross-Validation (LOOCV). For each sample (x_i, y_i) , we:
- Fit a linear regression model using the remaining $n - 1$ points.
 - ◆ Predict $\hat{y}_i$ for the left-out sample.
 - ◆ Compute the squared error $(y_i - \hat{y}_i)^2$.

- (1) Leave out $(-1, 1)$:
- Fit the model using points $(1, 1)$ and $(2, 0)$:
- The slope w and intercept b are calculated as:

$$w = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, b = \bar{y} - w\bar{x}.$$

- For these two points:

$$w = -1, b = 2.$$

- Thus, the model becomes:

$$y = -x + 2.$$

- Predict for the left-out point $x = -1$:

$$\hat{y} = -(-1) + 2 = 3.$$

单选题

- (2) Leave out (1,1):
- Fit the model using points $(-1,1)$ and $(2,0)$:
- For these two points:

$$w = -\frac{1}{3}, b = \frac{2}{3}.$$

- Thus, the model becomes:

$$y = -\frac{1}{3}x + \frac{2}{3}.$$

- Predict for the left-out point $x = 1$:

$$\hat{y} = -\frac{1}{3} + \frac{2}{3} = \frac{1}{3}.$$

- The squared error is:

$$\left(1 - \frac{1}{3}\right)^2 = \frac{4}{9}.$$

单选题

- (3) Leave out (2,0):
- Fit the model using points $(-1,1)$ and $(1,1)$:
- For these two points:
 $w = 0, b = 1.$
- Thus, the model becomes:
 $y = 1.$
- Predict for the left-out point $x = 2$:
 $\hat{y} = 1.$
- The squared error is:
 $(0 - 1)^2 = 1.$
- Final Mean Squared Error (MSE)
- The MSE is the average of the squared errors:

■ $MSE = \frac{4 + \frac{4}{9} + 1}{3} = \frac{49}{27}.$ Final Answer:

单选题

6) 假如你在训练一个线性回归模型，有下面两句话：

- 1. 如果数据量较少，容易发生拟合。
- 2. 如果假设空间较小，容易发生拟合。
- 关于这两句话，下列说法正确的是？
-

■ A. 1 和 2 都错误

■ C. 1 错误，2 正确

B. 1 正确，2 错误

D. 1 和 2 都正确

单选题

6) 假如你在训练一个线性回归模型，有下面两句话：

- 1. 如果数据量较少，容易发生拟合。
- 2. 如果假设空间较小，容易发生拟合。
- 关于这两句话，下列说法正确的是？(B)

■ A. 1 和 2 都错误

■ C. 1 错误，2 正确

B. 1 正确，2 错误

D. 1 和 2 都正确

单选题

1. “如果数据量较少，容易发生拟合。”

•正确。

过拟合的一个主要原因是数据量不足，导致模型在训练集上学到噪声或局部特征，无法很好地泛化到新数据。数据量越少，模型越容易对训练集拟合过度。

2. “如果假设空间较小，容易发生拟合。”

•错误。

假设空间较小意味着模型的复杂度较低，例如简单的线性模型。假设空间较小通常会导致欠拟合，而不是过拟合，因为模型无法捕捉数据的复杂模式。

总结：

- 数据量较少容易导致过拟合，所以 1 正确。
- 假设空间较小容易导致欠拟合，所以 2 错误。

最终答案是：B. 1 正确，2 错误。

单选题

- 7) 关于 k 折交叉验证, 下列说法正确的是?
- A. k 值并不是越大越好, k 值过大, 会降低运算速度
 - B. 选择更大的 k 值, 会让偏差更小, 因为 k 值越大, 训练集越接近整个训练样本
 - C. 选择合适的 k 值, 能减小方差
 - D. 以上说法都正确

单选题

7) 关于 k 折交叉验证, 下列说法正确的是? (D)

A. k 值并不是越大越好, k 值过大, 会降低运算速度

B. 选择更大的 k 值, 会让偏差更小, 因为 k 值越大, 训练集越接近整个训练样本

C. 选择合适的 k 值, 能减小方差

D. 以上说法都正确

单选题

•A. ☐ k值并不是越大越好，k值过大，会降低运算速度

•正确。

在 ☐ k-折交叉验证中，k 越大，模型需要训练 k次，计算量增加，降低运算速度。特别是当 ☐ k=n（即留一法 LOOCV）时，训练次数等于样本数量，计算开销最大。

B. 选择更大的 k值，会让偏差更小，因为 k值越大，训练集越接近整个训练样本

•正确。

当k 增大时，每次划分的训练集所占比例更接近整个数据集，导致模型的偏差减小。但过大的 k 也可能引入计算开销。

C. 选择合适的 k 值，能减小方差

•正确。

合适的k值可以在偏差与方差之间找到平衡。小k值导致训练集较小，方差较大；较大的k ☐ 值能减小结果的方差，但计算成本增加。

D. 以上说法都正确

•正确。

A、B、C 的描述均是正确的，因此 D 是最终答案。

单选题

8) 数据科学家经常使用多个算法进行预测，并将多个机器学习算法的输出（称为“集成学习”）结合起来，以获得比所有个体模型都更好的更鲁棒的输出。则下列说法正确的是？

- A. 基本模型之间相关性高
- B. 基本模型之间相关性低
- C. 集成方法中，使用加权平均代替投票方法
- D. 基本模型都来自于同一算法

单选题

8) 数据科学家经常使用多个算法进行预测，并将多个机器学习算法的输出（称为“集成学习”）结合起来，以获得比所有个体模型都更好的更鲁棒的输出。则下列说法正确的是？ B

- A. 基本模型之间相关性高
- B. 基本模型之间相关性低
- C. 集成方法中，使用加权平均代替投票方法
- D. 基本模型都来自于同一算法

单选题

A. 基本模型之间相关性高

- 错误。

集成学习的核心思想是结合多个相互独立或低相关性的模型，以降低模型的方差和偏差，提高预测性能。如果基本模型之间高度相关，它们的错误也可能是相似的，集成的效果将大打折扣。

B. 基本模型之间相关性低

- 正确。

集成学习通过结合多个低相关性（独立性较高）的基本模型，使得模型的整体预测更加鲁棒，因为不同模型的错误可能会相互抵消。

C. 集成方法中，使用加权平均代替投票方法

- 错误。

集成学习可以使用多种方法，如简单投票（如 Bagging）或加权平均（如 Boosting）。但这并不意味着加权平均一定会替代投票方法，具体方法取决于集成的设计。


D. 基本模型都来自于同一算法

- 错误。

集成学习可以使用同一算法（如 Bagging 使用多个决策树），也可以使用不同算法（如 Stacking 方法结合不同类型的模型，如逻辑回归、SVM 和神经网络）。

单选题


9) 假设我们使用 kNN 训练模型，其中训练数据具有较少的观测数据（下图是两个属性 x 、 y 和两个标记为 “ $\times$ ” 和 “ $\circ$ ” 的训练数据）。现在令 $k = 1$ ，则图中的 Leave-One-Out 交叉验证错误率是多少？



- A. 0%
- B. 20%
- C. 50%
- D. 100%

单选题

9) 假设我们使用 kNN 训练模型，其中训练数据具有较少的观测数据（下图是两个属性 x 、 y 和两个标记为 “ $\times$ ” 和 “ $\circ$ ” 的训练数据）。现在令 $k = 1$ ，则图中的 Leave-One-Out 交叉验证错误率是多少？(D)



A. 0%

B. 20%

C. 50%

D. 100%

单选题

- 9) 本题考查的是 kNN 算法和 Leave-One-Out 交叉验证。
- kNN 算法是标记类算法，取当前实例最近邻的 k 个样本， k 个样本中所属的最多类别即判定为该实例的类别。本题中 $k = 1$ ，则只需要看最近邻的那一个样本属于 “x” 还是 “o” 即可。
- Leave-One-Out 交叉验证是一种用来训练和测试分类器的方法，假定数据集有 N 个样本，将这个样本分为两份，第一份 $N-1$ 个样本用来训练分类器，另一份 1 个样本用来测试，如此迭代 N 次，所有的样本里所有对象都经历了测试和训练。
- 分别对这 10 个点进行观察可以发现，每个实例点最近邻的都不是当前实例所属的类别，因此每次验证都是错误的。整体的错误率即为 100%。

单选题

- 10) 关于PCA说法错误的是?
- A. 必须在使用PCA前规范化数据
- B. 应该选择使得模型有最大variance的主成分
- C. 应该选择使得模型有最小variance的主成分
- D. 可以使用PCA在低维度上做数据可视化

单选题

- 10) 关于PCA说法错误的是? (C)
- A. 必须在使用PCA前规范化数据
- B. 应该选择使得模型有最大variance的主成分
- C. 应该选择使得模型有最小variance的主成分
- D. 可以使用PCA在低维度上做数据可视化

单选题

- A. 必须在使用 PCA 前规范化数据
- 正确。
- 在 PCA 中，数据的尺度对结果影响很大。如果特征的取值范围不同，方差较大的特征会主导主成分的选择。因此，PCA 通常需要对数据进行规范化（标准化），使所有特征的均值为 0、方差为 1。
- B. 应该选择使得模型有最大 variance 的主成分
- 正确。
- PCA 的目标是找到方差最大的方向（即主成分），因为方差大的方向携带更多的信息。主成分是数据在高维空间中最大方差方向的投影。

单选题

- C. 应该选择使得模型有最小 variance 的主成分
- 错误。

PCA 的目标是选择方差最大的主成分，而非最小方差的主成分。最小方差的方向通常对应于数据中的噪声和信息损失。

- D. 可以使用 PCA 在低维度上做数据可视化
- 正确。

PCA 常用于降维，并在二维或三维空间中对数据进行可视化，从而帮助直观地观察数据的分布和结构。

总结：

PCA 的目标是找到最大方差的方向，最小方差的方向不被选用。因此，选项 C 是错误的。

计算题

- 2. 决策树(12分)
- 下表为一个网站客户的数据，包括客户收入、浏览时间、订阅情况以及是否购买产品等信息。你需要建立一个决策树来预测未来的客户是否会购买产品。表中最右列为预测的标签，其他列为可用的特征。
- (1) 为了获得最大的信息增益 (information gain)，根节点应该选择哪个特征？
- (2) 请构造ID3决策树判断客户是否买房。

客户编号	收入	浏览时间	订阅情况	是否购买
1	<5000	12	是	是
2	>5000	20	是	是
3	>5000	12	是	否
4	<5000	20	否	否
5	<5000	5	是	是
6	<5000	20	是	是
7	>5000	12	否	否
8	>5000	5	否	否
9	<5000	12	否	否

计算题

- 2. 决策树(12分)
- 计算整体熵 $H(D)$
- 数据中标签分布如下:

- 是: 4 个
- 否: 5 个

- 整体熵 $H(D)$ 的公式为:

$$H(D) = -p_{\text{是}} \log_2 p_{\text{是}} - p_{\text{否}} \log_2 p_{\text{否}}$$

- 其中 $p_{\text{是}} = \frac{4}{9}$, $p_{\text{否}} = \frac{5}{9}$, 代入计算:

$$H(D) = -\frac{4}{9} \log_2 \frac{4}{9} - \frac{5}{9} \log_2 \frac{5}{9} \approx 0.991$$

计算题

■ 2. 决策树(12分)

■ 计算各特征的信息增益

■ (1) 按“订阅情况”划分数据:

- 是: 6 个样本, 标签分布: 是 4, 否 2
- 否: 3 个样本, 标签分布: 否 3

■ 计算各组熵:

$$H(\text{是}) = -\frac{4}{6} \log_2 \frac{4}{6} - \frac{2}{6} \log_2 \frac{2}{6} \approx 0.918$$

$$H(\text{否}) = -\frac{3}{3} \log_2 \frac{3}{3} = 0$$

■ 条件熵 $H(\text{订阅情况})$ 为:

$$H(\text{订阅情况}) = \frac{6}{9} H(\text{是}) + \frac{3}{9} H(\text{否})$$

$$H(\text{订阅情况}) = \frac{6}{9} (0.918) + \frac{3}{9} (0) = 0.612$$

■ 信息增益:

$$\text{Gain}(\text{订阅情况}) = H(D) - H(\text{订阅情况})$$

$$\text{Gain}(\text{订阅情况}) = 0.991 - 0.612 = 0.379$$

计算题

■ 2. 决策树(12分)

■ (2) 按“收入”划分数据:

- < 5000: 6 个样本, 标签分布: 是 4, 否 2
- > 5000: 3 个样本, 标签分布: 是 1, 否 2

■ 计算各组熵:

$$H(< 5000) = -\frac{4}{6}\log_2\frac{4}{6} - \frac{2}{6}\log_2\frac{2}{6} \approx 0.918$$

$$H(> 5000) = -\frac{1}{3}\log_2\frac{1}{3} - \frac{2}{3}\log_2\frac{2}{3} \approx 0.918$$

■ 条件熵 $H(\text{收入})$ 为:

$$H(\text{收入}) = \frac{6}{9}H(< 5000) + \frac{3}{9}H(> 5000)$$

$$H(\text{收入}) = \frac{6}{9}(0.918) + \frac{3}{9}(0.918) = 0.918$$

■ 信息增益:

$$\text{Gain}(\text{收入}) = H(D) - H(\text{收入})$$

$$\text{Gain}(\text{收入}) = 0.991 - 0.918 = 0.073$$

计算题

■ (3) 按“浏览时间”划分数据:

- 5: 2 个样本, 标签分布: 是 1, 否 1
- 12: 4 个样本, 标签分布: 是 2, 否 2
- 20: 3 个样本, 标签分布: 是 2, 否 1

■ 计算各组熵:

$$H(5) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{2}\log_2\frac{1}{2} = 1$$

$$H(12) = -\frac{2}{4}\log_2\frac{2}{4} - \frac{2}{4}\log_2\frac{2}{4} = 1$$

$$H(20) = -\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3} \approx 0.918$$

■ 条件熵 $H(\text{浏览时间})$ 为:

$$H(\text{浏览时间}) = \frac{2}{9}H(5) + \frac{4}{9}H(12) + \frac{3}{9}H(20)$$

$$H(\text{浏览时间}) = \frac{2}{9}(1) + \frac{4}{9}(1) + \frac{3}{9}(0.918) \approx 0.972$$

■ 信息增益:

$$\text{Gain}(\text{浏览时间}) = H(D) - H(\text{浏览时间})$$

$$\text{Gain}(\text{浏览时间}) = 0.991 - 0.972 = 0.019$$

计算题

■ 3. 神经网络 (14 分)

■ 考虑如下的神经网络，神经网络的输入为 a, b, c ，输出为 j 。

■ $d = ab$, $e = s(d)$, $f = r(a)$, $g = 3a$,

■ $h = 2e + f + g$, $i = ch$, $j = f + i^2$

■ 其中 $s(y) = \frac{1}{1+e^{-y}}$ 是sigmoid函数， $r(y) = \max\{0, y\}$ 是ReLU函数。

■ 你需要计算在反向传播方式下， j 关于每一个其他变量 a 到 i 的偏导数。例如，对于 i 和 h ,

■ $\frac{\partial j}{\partial i} = \frac{dj}{di} = 2i$ (无链式法则)

■ $\frac{\partial j}{\partial h} = \frac{\partial j}{\partial i} \frac{\partial i}{\partial h} = 2ic$ (通过链式法则计算)

■ 请计算 j 关于 a 到 g 的偏导数并且化简至最简形式。 $r'(y)$ 可以表示为 $\mathbf{1}(y \geq 0)$ 。 $s(y)$ 的导数可以直接表示为 $s'(y)$ 。

■ 提示：前向过程中 f 和 a 使用过多次，所以他们需要采用多元链式法则。

计算题

■ 3. 神经网络 (14 分)

■ 考虑如下的神经网络，神经网络的输入为 a, b, c ，输出为 j 。

■ $d = ab$, $e = s(d)$, $f = r(a)$, $g = 3a$,

■ $h = 2e + f + g$, $i = ch$, $j = f + i^2$

■ 其中 $s(y) = \frac{1}{1+e^{-y}}$ 是sigmoid函数， $r(y) = \max\{0, y\}$ 是ReLU函数。

■ 你需要计算在反向传播方式下， j 关于每一个其他变量 a 到 i 的偏导数。例如，对于 i 和 h ,

■ $\frac{\partial j}{\partial i} = \frac{dj}{di} = 2i$ (无链式法则)

■ $\frac{\partial j}{\partial h} = \frac{\partial j}{\partial i} \frac{\partial i}{\partial h} = 2ic$ (通过链式法则计算)

■ 请计算 j 关于 a 到 g 的偏导数并且化简至最简形式。 $r'(y)$ 可以表示为 $\mathbf{1}(y \geq 0)$ 。 $s(y)$ 的导数可以直接表示为 $s'(y)$ 。

■ 提示：前向过程中 f 和 a 使用过多次，所以他们需要采用多元链式法则。

计算题

$$\begin{aligned}
 & \frac{\partial j}{\partial g} = \frac{\partial j}{\partial h} \frac{\partial h}{\partial g} = 2ic \\
 & \frac{\partial j}{\partial f} = \frac{\partial j}{\partial h} \frac{\partial h}{\partial f} + \frac{dj}{df} = 2ic + 1 \\
 & \frac{\partial j}{\partial e} = \frac{\partial j}{\partial h} \frac{\partial h}{\partial e} = 4ic \\
 & \frac{\partial j}{\partial d} = \frac{\partial j}{\partial e} \frac{\partial e}{\partial d} = 4ics(d)(1 - s(d)) \\
 & \frac{\partial j}{\partial c} = \frac{\partial j}{\partial i} \frac{\partial i}{\partial c} = 2ih \\
 & \frac{\partial j}{\partial b} = \frac{\partial j}{\partial d} \frac{\partial d}{\partial b} = 4icas(d)(1 - s(d)) \\
 & \frac{\partial j}{\partial a} = \frac{\partial j}{\partial d} \frac{\partial d}{\partial a} + \frac{\partial j}{\partial f} \frac{\partial f}{\partial a} + \frac{\partial j}{\partial g} \frac{\partial g}{\partial a} = 4icbs(d)(1 - s(d)) + (2ic + 1) \cdot \mathbf{1}(a \geq 0) + 6ic
 \end{aligned}$$

计算题

- 4. 性能度量方法 (10分)
- 假设某机器学习模型预测是否为好西瓜的原始类别和预测类别如下表所示, 计算其的混淆矩阵、准确率、精确率、召回率、F1 score。

样本序列	1	2	3	4	5	6	7	8	9	10	11
真实类别	好	好	好	好	好	坏	坏	坏	坏	坏	坏
预测类别	好	好	坏	好	好	好	坏	坏	坏	好	坏

计算题

■ 4. 性能度量方法 (10分)

1. 混淆矩阵的定义

■ 混淆矩阵如下:

	预测: 好	预测: 坏
真实: 好	TP	FN
真实: 坏	FP	TN

	预测: 好	预测: 坏
真实: 好	4	1
真实: 坏	2	4

■ 其中:

- TP (True Positive): 预测为“好”，真实也是“好”
- FP (False Positive): 预测为“好”，真实为“坏”
- FN (False Negative): 预测为“坏”，真实为“好”
- TN (True Negative): 预测为“坏”，真实也是“坏”

混淆矩阵
 $\begin{pmatrix} 4 & 1 \\ 2 & 4 \end{pmatrix}$

计算题

- 4. 性能度量方法 (10分)
- 准确率 (Accuracy)
- 准确率的公式为:

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN}. \quad (1)$$

- 代入数值:

$$\text{Accuracy} = \frac{4 + 4}{4 + 2 + 1 + 4} = \frac{8}{11} \approx 0.727. \quad (2)$$

计算题

■ 4. 性能度量方法 (10分)

精确率 (Precision)

精确率的公式为:

$$\text{Precision} = \frac{TP}{TP + FP}. \quad (3)$$

代入数值:

$$\text{Precision} = \frac{4}{4 + 2} = \frac{4}{6} \approx 0.667. \quad (4)$$

召回率 (Recall)

召回率的公式为:

$$\text{Recall} = \frac{TP}{TP + FN}. \quad (5)$$

代入数值:

$$\text{Recall} = \frac{4}{4 + 1} = \frac{4}{5} = 0.8. \quad (6)$$

计算题

■ 4. 性能度量方法 (10分)

F1 Score

F1 Score 是精确率和召回率的调和平均，公式为：

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (7)$$


代入数值：

$$F1 = \frac{2 \times 0.667 \times 0.8}{0.667 + 0.8} = \frac{2 \times 0.5336}{1.467} \approx 0.727. \quad (8)$$

计算题

■ 5. SVM (10 分)


- a) 给定如图所示的样本点，绘制并标记两条线：硬间隔SVM学习的决策边界和软间隔SVM学到的决策边界。不需要写出具体的分界线方程。请使用虚线表示两个分类边界的边距。
- b) 二者的区别是什么？



计算题

■ 5. SVM (10 分)

■ a)



(b)区别：软间隔SVM引入了一个松弛变量 (slack variable)，允许一些样本违反硬间隔的条件。这就允许在一定程度上容忍一些噪声和异常值。硬间隔SVM要求训练数据集中的每个样本都必须被正确分类，对于噪声和异常值非常敏感，可能导致过拟合。

计算题

- 6. PCA (10 分)

- 给定如下6个点 $X_i \in R^2$:

$$\begin{pmatrix} 0 & 1 & 0 & 2 & 2 & 0 \\ 1 & 2 & 0 & 2 & 1 & 0 \end{pmatrix}$$

- 计算样本点的平均值，并写出中心化之后的矩阵X。
- 计算所有主成分并将它们写成单位向量。

计算题

■ 6. PCA (10 分)

$$X = \begin{pmatrix} 0 & 1 & 0 & 2 & 2 & 0 \\ 1 & 2 & 0 & 2 & 1 & 0 \end{pmatrix}. \quad (1)$$

■ (1) 计算样本点的平均值

■ 对于矩阵 X ，每一列是 $X_i \in \mathbb{R}^2$ 一个样本向量，样本点的平均值向量是每个维度上的均值：

■ • 第 1 维的平均值：

$$\bar{x}_1 = \frac{0 + 1 + 0 + 2 + 2 + 0}{6} = \frac{5}{6}. \quad (2)$$

■ • 第 2 维的平均值：

$$\bar{x}_2 = \frac{1 + 2 + 0 + 2 + 1 + 0}{6} = \frac{6}{6} = 1. \quad (3)$$

计算题

■ 6. PCA (10 分)

- 因此，样本点的平均值向量为：

$$\bar{x} = \left(\frac{5}{6}, 1 \right). \quad (4)$$

■ (2) 中心化矩阵：

- 中心化的矩阵 X' 是将每个样本点减去平均值向量 $\bar{x}$ 。对于样本 (x_{1i}, x_{2i}) ，中心化后的坐标为：

$$x'_{1i} = x_{1i} - \frac{5}{6}, \quad x'_{2i} = x_{2i} - 1. \quad (5)$$

- 将矩阵 的元素中心化，得到中心化矩阵：

$$X' = \begin{pmatrix} 0 - \frac{5}{6} & 1 - \frac{5}{6} & 0 - \frac{5}{6} & 2 - \frac{5}{6} & 2 - \frac{5}{6} & 0 - \frac{5}{6} \\ 1 - 1 & 2 - 1 & 0 - 1 & 2 - 1 & 1 - 1 & 0 - 1 \end{pmatrix}. \quad (6)$$

计算题

■ 6. PCA (10 分)

$$X' = \begin{pmatrix} \frac{5}{6} & \frac{1}{6} & -\frac{5}{6} & \frac{7}{6} & \frac{7}{6} & -\frac{5}{6} \\ 0 & 1 & -1 & 1 & 0 & -1 \end{pmatrix}. \quad (7)$$

■ (3) 计算主成分的单位向量

■ 协方差矩阵：

$$C = \frac{1}{n} X' (X')^T, \quad (8)$$

■ 其中 $n=6$ 是样本数量。

■ 将中心化矩阵 与其转置相乘，得到：

$$X' (X')^T = \begin{pmatrix} \text{第 1 行} \cdot \text{第 1 行} & \text{第 1 行} \cdot \text{第 2 行} \\ \text{第 2 行} \cdot \text{第 1 行} & \text{第 2 行} \cdot \text{第 2 行} \end{pmatrix}. \quad (9)$$

计算题

■ 6. PCA (10 分)

- 计算各个元素得到:

$$C = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{2} \end{pmatrix}. \quad (10)$$

- 特征值与特征向量:

- 协方差矩阵 C 的特征方程为:

$$\det(C - \lambda I) = 0. \quad (11)$$

- 其中 $C = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{2} \end{pmatrix}$ 解特征方程: $\begin{vmatrix} \frac{1}{2} - \lambda & 0 \\ 0 & \frac{1}{2} - \lambda \end{vmatrix} = 0. \quad (12)$

计算题

■ 6. PCA (10 分)

- 得到两个特征值:

$$\lambda_1 = \frac{1}{2}, \quad \lambda_2 = \frac{1}{2}. \quad (13)$$

- 对应的特征向量为:

- • 对于 λ_1 和 λ_2 , 经过归一化后, 主成分的单位向量分别为:

$$v_1 = \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}} \right), \quad v_2 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right). \quad (14)$$

■ 最终结果

- 1. 样本点的平均值:

$$\bar{x} = \left(\frac{5}{6}, 1 \right). \quad (15)$$

计算题

■ 6. PCA (10 分)

■ 2. 中心化矩阵：

$$X' = \begin{pmatrix} \frac{5}{6} & \frac{1}{6} & -\frac{5}{6} & \frac{7}{6} & \frac{7}{6} & -\frac{5}{6} \\ 0 & 1 & -1 & 1 & 0 & -1 \end{pmatrix}. \quad (16)$$

■ 3. 主成分的单位向量：

$$v_1 = \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}} \right), \quad v_2 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right). \quad (17)$$

计算题

■ 7. 贝叶斯分类 (12分)

- 下表为客户是否买买房的数据集，其中是否买房为标签，其他特征为标签，试由下表学习一个朴素贝叶斯分类器，判断特征为(32岁，男，24W) 的客户是否买房：

客户ID	年龄	性别	收入	是否买房
1	27	男	15W	否
2	47	女	30W	是
3	32	男	12W	否
4	24	男	45W	是
5	45	男	30W	否
6	56	男	32W	是
7	31	男	15W	否
8	23	女	25W	否
9	25	男	19W	是
10	32	女	42W	是

注：年龄分为20-30，31-40，41+三个阶段，收入分为10-20，21-40，41+三个级别。

计算题

■ 7. 贝叶斯分类 (12分)

■ 为了使用朴素贝叶斯分类器判断特征为 (32岁, 男, 24W) 的客户是否买房:

■ 定义变量与分类

- 标签 (目标变量): 是否买房 (买房 / 不买房)
- 特征:
 - 年龄: 20–30岁, 31–40岁, 41岁以上
 - 性别: 男, 女
 - 收入: 10–20W, 21–40W, 41W以上

1. 计算先验概率

■ 总共有10个客户, 其中5个买房, 5个不买房。

■ $P(\text{买房}) = \frac{5}{10} = \frac{1}{2} \quad (1)$

■ $P(\text{不买房}) = \frac{5}{10} = \frac{1}{2} \quad (2)$

计算题

■ 7. 贝叶斯分类 (12分)

1. 计算条件概率

- 年龄为32岁 (属于31-40岁)
- 买房客户中, 年龄在31-40岁的有2个 (客户9和10) :

$$\blacksquare P(\text{年龄} = 32 | \text{买房}) = \frac{2}{5} \quad (3)$$

- 不买房客户中, 年龄在31-40岁的有2个 (客户3和7) :

$$\blacksquare P(\text{年龄} = 32 | \text{不买房}) = \frac{2}{5} \quad (4)$$

- 性别为男

- 买房客户中, 性别为男的有3个 (客户4、6、9) :

$$\blacksquare P(\text{性别} = \text{男} | \text{买房}) = \frac{3}{5} \quad (5)$$

计算题

■ 7. 贝叶斯分类 (12分)

- • 不买房客户中，性别为男的有4个（客户1、3、5、7）：

- $P(\text{性别} = \text{男} | \text{不买房}) = \frac{4}{5} \quad (6)$

- • 收入为24W（属于21-40W）

- 买房客户中，收入在21-40W的有2个（客户2、6）：

- $P(\text{收入} = 24W | \text{买房}) = \frac{2}{5} \quad (7)$

- 不买房客户中，收入在21-40W的有2个（客户5、8）：

- $P(\text{收入} = 24W | \text{不买房}) = \frac{2}{5} \quad (8)$

计算题

■ 7. 贝叶斯分类 (12分)

计算后验概率

■ 根据朴素贝叶斯公式:

$$\blacksquare P(\text{买房}|\text{特征}) \propto P(\text{买房}) \cdot P(\text{年龄} = 32|\text{买房}) \cdot P(\text{性别} = \text{男}|\text{买房}) \cdot P(\text{收入} = 24W|\text{买房}) \quad (9)$$

$$\blacksquare P(\text{不买房}|\text{特征}) \propto P(\text{不买房}) \cdot P(\text{年龄} = 32|\text{不买房}) \cdot P(\text{性别} = \text{男}|\text{不买房}) \cdot P(\text{收入} = 24W|\text{不买房}) \quad (10)$$

$$\blacksquare P(\text{买房}|\text{特征}) = \frac{1}{2} \times \frac{2}{5} \times \frac{3}{5} \times \frac{2}{5} = \frac{12}{250} = \frac{6}{125} \quad (11)$$

$$\blacksquare P(\text{不买房}|\text{特征}) = \frac{1}{2} \times \frac{2}{5} \times \frac{4}{5} \times \frac{2}{5} = \frac{16}{250} = \frac{8}{125} \quad (12)$$

比较后验概率并做出预测

$$\frac{6}{125} < \frac{8}{125} \quad (13)$$

因此, 预测该客户不买房。

计算题

■ 8. 极大似然估计(12分)

■ 假设有3枚硬币，分别记作A, B, C. 这些硬币正面出现的概率分别是 π, p, q 。进行如下掷硬币试验：先掷硬币A，根据其结果选出硬币B或硬币C，正面选硬币B，反面选硬币C；然后掷选出的硬币，掷硬币的结果，出现正面记作1，出现反面记作0；独立地重复 n 次试验（这里 $n = 10$ ），观测结果如下：

■ 0,1,0,1,0,0,1,0,1,1

■ 假设只能观测到掷硬币的结果，不能观测掷硬币的过程。

1. 请使用 π, p, q 三个参数，

(a) 估计三硬币模型在一次实验中正反面出现的概率 $P(y|\pi, p, q)$ 。

(b) 计算在模型参数 π, p, q 下观测数据 y 来自掷硬币B的概率 y 。

1. 写出进行 n 次试验，观测数据的似然函数 $P(Y|\pi, p, q)$ ，现有 $\pi = \frac{1}{2}, p = \frac{1}{2}, q = \frac{1}{2}$ 和 $\pi = \frac{1}{2}, p = \frac{1}{3}, q = \frac{2}{3}$ 两个猜测，请比较以上两组似然估计参数。

计算题

(1)(a)

$$\begin{aligned} P(y|\theta) &= \sum_z P(y, z|\theta) = \sum_z P(z|\theta)P(y|z, \theta) \\ &= \pi p^y (1-p)^{1-y} + (1-\pi) q^y (1-q)^{1-y} \end{aligned}$$

或者写成

$$\begin{aligned} P(y = 1|\theta) &= \pi p + (1-\pi)q \\ P(y = 0|\theta) &= \pi(1-p) + (1-\pi)(1-q) \end{aligned}$$

计算题

■ (b)

$$P(B|y) = \frac{\pi p^y (1-p)^{1-y}}{\pi p^y (1-p)^{1-y} + (1-\pi) q^y (1-q)^{1-y}}$$

或者写成

$$P(B|y = 1) = \frac{\pi p}{\pi p + (1-\pi) q}$$

$$P(B|y = 0) = \frac{\pi(1-p)}{\pi(1-p) + (1-\pi)(1-q)}$$

计算题

■ (2)

$$P(Y|\pi, p, q) = \prod_{i=1}^n [\pi p^{y_i} (1-p)^{1-y_i} + (1-\pi) q^{y_i} (1-q)^{1-y_i}]$$

■ 根据极大似然估计函数计算出

$$P\left(Y \middle| \pi = \frac{1}{2}, p = \frac{1}{2}, q = \frac{1}{2}\right) = (1/2)^{10}$$

$$P\left(Y \middle| \pi = \frac{1}{2}, p = \frac{1}{3}, q = \frac{2}{3}\right) = (1/2)^{10}$$

■ 所以以上两组似然估计参数概率一致

End