

数理统计是数学的一个分支，它是以概率论为基础，通过对实验数据的统计分析，寻找所服从的分布和数字特征，从而推断总体的规律性。

可分为描述统计和推断统计：

- 描述性统计的任务是搜集资料，进行整理、分组，编制次数分配表，绘制次数分配曲线，计算各种特征指标，以描述资料分布的集中趋势、离散趋势和次数分布的偏斜度等。
- 推断性统计是在描述统计的基础上，根据样本资料归纳出的规律性，对总体进行推断和预测。

主要参考书：



1. 描述性统计(descriptive statistics)

1.1 基本概念(basic concepts)

1.2 次数分布(frequency distribution)

1.3 数据的集中性(central tendency of data)

1.4 数据的离散性(spread of data)

1.5 理论总体的平均数和标准差(mean and standard deviation of population)

1.1 基本概念 (basic concepts)

- 总体(population) —— 具有共同性质的个体所组成的集团。
 - 有限总体——由有限个个体构成的总体。
 - 无限总体——总体所包含的个体数目有无穷多个。
- 观察值(observation) —— 每一个体的某一性状、特性的测定数值(个别 x, y, z 表示)。
- 变量(variable) —— 观察值集合起来，称为总体的变量。变量又称为随机变量(random variable)。常用大写字母 X, Y, Z 等表示。
- 样本(sample) —— 从总体中抽取若干个个体的集合称为样本。
- 统计量(statistic) —— 测定样本中的各个体而得的样本特征数，如平均数等，称为统计量。
- 随机样本(random sample) —— 从总体中随机抽取的样本称为随机样本。
- 样本容量(sample size) —— 样本中包含的个体数称为样本容量或样本含量。

• 数量性状(quantitative trait)

有计数和量测两种方式，其所得变数不同：

不连续性或间断性变量(discontinuous or discrete variable) 指用计数方法获得的数据。

连续性变量(continuous variable)指称量、度量或测量方法所得到的数据，其各个观察值并不限于整数，在两个数值之间可以有微量数值差异的第三个数值存在。

- 质量性状(qualitative trait)指能观察而不能量测的性状即属性性状，如花药、子粒、颖壳等器官的颜色、芒的有无、绒毛的有无等。要从这类性状获得数量资料，可采用下列两种方法：

统计次数法：于一定总体或样本内，统计其具有某个性状的个体数目及具有不同性状的个体数目，按类别计其次数或相对次数。

给分法：给予每类性状以相对数量的方法

1.2 次数分布(frequency distribution)

1.2.1 间断性变量资料

以某小麦品种的每穗小穗数为例，随机采取100个麦穗，计数每穗小穗数。

100个麦穗的每穗小穗数(未加整理的资料)

18	15	17	19	16	15	20	18	19	17
17	18	17	16	18	20	19	17	16	18
17	16	17	19	18	18	17	17	17	18
18	15	16	18	18	18	17	20	19	18
17	19	15	17	17	17	16	17	18	18
17	19	19	17	19	17	18	16	18	17
17	19	16	16	17	17	17	15	17	16
18	19	18	18	19	19	20	17	16	19
18	17	18	20	19	16	18	19	17	16
15	16	18	17	18	17	17	16	19	17

1.3.5 总体平均数 (population mean)

总体平均数用 μ 来代表, 它同样具有算术平均数所具有的特性。

$$\mu = \frac{\sum_{i=1}^N y_i}{N}$$

上式 y_i 代表各个观察值, N 代表有限总体所包含的个体数, $\sum_{i=1}^N y_i$ 表示总体内各个观察值的总和。

34

1.4 数据的离散性 (spread of data)

1.4.1 极差 (range)

极差 (range) 又称全距, 记作 R , 是资料中最大观察值与最小观察值的差数。例如调查两个小麦品种的每穗小穗数, 每品种计数 10 个麦穗, 经整理后的数字列于下表。

品种名称	每穗小穗数	总和	平均
甲	13 14 15 17 18 18 19 21 22 23	180	18
乙	16 16 17 18 18 18 18 19 20 20	180	18

上表中, 甲品种每穗小穗数最少为 13 个, 最多为 23 个, 共 23-13=10 个小区; 乙品种每穗小穗数最少为 16 个, 最多为 20 个, 共 20-16=4 个小区。可以求出, 甲品种的平均每穗小穗数为 18, 乙品种的平均每穗小穗数为 18。因此, 甲品种的小穗数比乙品种的小穗数多, 平均数也代表其特性, 乙品种的每穗小穗数比甲品种的小, 其平均数也代表其特性。

35

1.4.2 方差 (variance)

离均差平方和 (简称平方和, sum of squares of deviation from mean, SS) —— 将各个离均差平方后相加

$$\text{样本 } SS = \sum (y_i - \bar{y})^2$$

$$\text{总体 } SS = \sum (y_i - \mu)^2$$

方差 (variance) 或均方 (mean square) —— 用观察值数目去除平方和

样本方差用 s^2 表示, 定义为:

$$s^2 = \frac{\sum (y_i - \bar{y})^2}{n-1}$$

总体方差用 σ^2 表示, 定义为:

$$\sigma^2 = \frac{\sum (y_i - \mu)^2}{N}$$

样本方差是总体方差的无偏估计值

36

1.4.3 标准差 (standard deviation)

标准差的定义:

标准差 (standard deviation, SD) 为方差的正平方根值, 用以表示资料的变异度, 其单位与观察值的度量单位相同。从样本资料计算标准差的公式为:

$$s = \sqrt{\frac{\sum (y - \bar{y})^2}{n-1}}$$

总体标准差用表示:

$$\sigma = \sqrt{\frac{\sum (y - \mu)^2}{N}}$$

样本标准差是总体标准差的估计值

无偏估计

37

自由度 (degrees of freedom) 的意义

或 df

自由度 (degrees of freedom) 记作 DF , 其具体数值则常用 V 表示。

统计意义: 是指样本内独立而能自由变动的离均差个数。

例如一个有 5 个观察值的样本, 因为受统计数的约束, 在 5 个离均差中, 只有 4 个数值可以在一定范围之内自由变动取值, 而第五个离均差必须满足。如一样本为 (3, 4, 5, 6, 7), 平均数为 5, 前 4 个离均差为 -2, -1, 0 和 1, 则第 5 个离均差为前 4 个离均差之和的变号数, 即 $-(-2)=2$ 。一般地, 样本自由度等于观察值的个数 (n) 减去约束条件的个数 (k), 即 $\nu = n - k$ 。

约束条件 $\sum (y - \bar{y}) = 0$

38

$$s = \sqrt{\frac{\sum (y - \bar{y})^2}{n-1}}$$

$$\sigma = \sqrt{\frac{\sum (y - \mu)^2}{N}}$$

注: 比较上面两个公式, 样本标准差不以样本容量 n , 而以自由度 $n-1$ 作为除数, 这是因为通常所掌握的是样本资料, 不知 μ 的数值, 不得不用样本平均数 $\bar{y}$ 代替 μ 。 $\bar{y}$ 与 μ 有差异, 由算术平均数的性质 (2) 可知, $\sum (y - \bar{y})^2$ 比 $\sum (y - \mu)^2$ 小, 因此, 由 $\sqrt{\sum (y - \bar{y})^2 / n}$ 算出的标准差将偏小。如分母用 $n-1$ 代替, 则可免除偏小的弊病。数理统计上可以证明用自由度作除数计算标准差的无偏性。

因为这里用了 $\bar{y}$ 而没用 μ , 如果用 μ 就偏大了 (因为 $\bar{y}$ 比 μ 小), 因此用 $n-1$

39

1.4.4 变异系数(coefficient of variation)

变异系数(coefficient of variation)——样本的标准差对均数的百分数:

$$CV = \frac{s}{\bar{y}} \times 100\%$$

变异系数是一个不带单位的纯数, 可用以比较二个事物的变异度大小。

两个小麦品种主茎高度的测量结果

品种	平均数 $\bar{y}$ (cm)	标准差 s (cm)	变异系数 CV(%)
甲	95.0	9.02	9.5
乙	75.0	8.50	11.3

上表为两个小麦品种主茎高度的平均数、标准差和变异系数。如果以甲品种为基准, 则乙品种的平均数比甲品种低21%, 标准差比甲品种低11.3%, 变异系数比甲品种高18.4%。

43

1.5 理论总体的平均数和标准差(mean and standard deviation of population)

设总体的第 i 个构成成分的概率为 p_i , 其平均数为 μ_i , 那么总体的平均数为:

$$\mu = \sum (p_i \mu_i)$$

总体的方差为:

$$\sigma^2 = \sum [p_i (\mu_i - \mu)^2]$$

44

【例】由单个位点控制的数量性状, F_2 代群体有三种基因型 AA, aa Aa, 这三种基因型值分别为 $m+d$, $m-d$ 和 $m+h$, 而这三种基因型的理论频率分别为 0.25, 0.25 和 0.5,

F_2 群体的构成成分	基因型	频率 (f)	平均数
1	AA	0.25	$m+d$
2	aa	0.25	$m-d$
3	Aa	0.50	$m+h$

因而可以计得其平均数为: $\mu = 0.25(m+d) + 0.25(m-d) + 0.5(m+h)$

其方差为: $\sigma^2 = 0.25(m+d-\mu)^2 + 0.25(m-d-\mu)^2 + 0.5(m+h-\mu)^2$

将总体平均数代入上式, 化简的方差为: $\sigma^2 = \frac{1}{2}d^2 + \frac{1}{4}h^2$

45

2. 理论分布和抽样分布(theoretical distribution and sampling distribution)

2.1 事件、概率和随机变量(event, probability and random variable)

2.2 理论分布(theoretical distribution)

2.3 抽样分布(sampling distribution)

46

2.1 事件、概率和随机变量(event, probability and random variable)

2.1.1 事件和事件发生的概率(event, and probability of occurrence)

事件(random event)——在自然界中一种事物, 常存在几种可能出现的情况, 每一种可能出现的情况称为事件。

随机事件(random event)——某特定事件只是可能发生的几种事件中的一种, 这种事件称为随机事件。

概率(probability)——每一个事件出现的可能性称为该事件的概率。

必然事件(certain event)——对于一类事件来说, 在同一组条件的实现之下必然要发生的, 称为必然事件; 其概率为1。

不可能事件(impossible event)——对于一类事件来说, 在同一组条件的实现之下必然不发生的, 称为不可能事件, 其概率为0。

47

事件发生的可能性(概率, probability)是在大量的实验中观察得到的, 例如棉田发生盲蝽象为害的情况, 并不是所有的棉株都受害, 随着观察的次数增多, 我们对棉株受害可能性程度大小的把握越准确、越稳定。

在相同条件下盲蝽象在某棉田危害程度的调查结果

调查株数 (n)	5	25	50	100	200	500	1000	1500	2000
受害株数 (a)	2	12	15	33	72	177	351	525	704
棉株受害 频率(a/n)	0.40	0.48	0.30	0.33	0.36	0.354	0.351	0.350	0.352

由上表可知, 随着调查株数 n 的增加, 受害株数 a 也随之增加, 但受害频率 a/n 却趋于稳定, 约为 0.35。这说明, 随着观察次数的增加, 我们对棉株受害可能性程度的把握越准确、越稳定。

因此, 在大量重复实验中, 事件发生的频率 a/n 可以作为该事件发生的概率 P 的估计值。当 n 很大时, a/n 与 P 的误差可以忽略不计。

48

2.2 理论分布(theoretical distribution)

理论分布(theoretical distribution)是指按照某种数学模型计算和推论出有关总体的次数(或频数)分布规律的概率分布。其特征主要由总体平均数(μ)、方差(σ^2)来表征。

包括下列四个分布:

- ▶ 二项分布(binomial distribution)或贝努利分布(Bernoulli distribution)
- ▶ 多项分布(multinomial distribution)
- ▶ 泊松分布(Poisson distribution)
- ▶ 正态分布(normal distribution)

61

2.2.1 二项分布(binomial distribution)或贝努利分布(Bernoulli distribution)

二项总体(binary population): 由非此即彼的两项所构成的总体。

例如: 小麦种子发芽和不发芽, 大豆子叶色为黄色和青色, 调查棉田盲蝽象为害分为受害株和受害株等等。

通常将二项总体中的“此”事件以变量“1”表示, 具概率 p ; 将“彼”事件以变量“0”表示, 具概率 q 。因而二项总体又称为0、1总体, 其概率则显然有: $p+q=1$ 或 $q=1-p$

二项分布(binomial distribution): 是从二项总体中抽样总数的分布。如果从二项总体进行 n 次重复抽样, 设出现“此”的次数为 y , 那么 y 的取值可能为0、1、2、...、 i , 共有 $i+1$ 种可能取值, 这 $i+1$ 种取值各有其概率, 因而由变量 y 及其概率就构成了一个分布, 这个分布叫做二项式概率分布, 简称二项式分布或二项分布。

二项总体的抽样试验具有:

- ▶ 重复性(repetitivity)是指每次试验条件不变, 即在每次试验中“此”事件出现的概率皆为 p 。
- ▶ 独立性(Independency)是指任何一次试验中“此”事件的出现与其余各次试验中出现何种结果无关。

62

二项式总体中包含两项(“此”和“彼”), 这两项的概率相应为 p 和 q , 并且 $p+q=1$, 可推知变量 y 的概率函数为:

$$P(y) = C_n^y p^y q^{n-y} \quad \text{其中} \quad C_n^y = \frac{n!}{y!(n-y)!}$$

复合事件的概率必等于该事件出现的组合数日乘以单个事件的概率; 而这一复合事件的可能组合数日则相当于从 n 个物体中任取 y 个物体的组合数。右侧为计算组合数的组合公式。

这一分布律也称贝努利(Bernoulli)分布, 描述了离散型随机变量 y 取不同值的概率, 具有 n 和 p 两个参数, 故通常记为 $B(n, p)$ 。

$$\sum_{y=0}^n P(y) = 1$$

累积函数(cumulative function) $F(y)$: 变量小于等于 y 的所有可能取值的概率之和

$$F(y) = \sum_{i=0}^y P(y=i)$$

理论次数(theoretical times): 对于任意 y , 理论次数= $nP(y)$

63

整个二项概率分布可以由 $(p+q)^n$ 的泰勒展开式给出:

$$(p+q)^n = C_n^0 p^0 q^{n-0} + C_n^1 p^1 q^{n-1} + C_n^2 p^2 q^{n-2} + \dots + C_n^y p^y q^{n-y} + \dots$$

$$= \sum_{y=0}^n C_n^y p^y q^{n-y}$$

可以看到, 上式右边的每一项即为二项分布中变量 y 取0、1、2、...、 n 时的概率。由于变量 $y=0, 1, 2, \dots, n$ 为完全事件系, 所以这个分布的各项概率之和显然等于1。又 $p+q=1$, 从而 $(p+q)^n=1$

$$\sum_{y=0}^n P(y) = \sum_{y=0}^n C_n^y p^y q^{n-y} = 1$$

显然二项总体具有平均数 $\mu = E(y) = \sum y \cdot P(y) = 0 \times q + 1 \times p = p$

和方差

$$\sigma^2 = E(y^2) - [E(y)]^2 = 0^2 \times q + 1^2 \times p - p^2 = p(1-p)$$

64

$\mu = p$
 $\sigma^2 = p(1-p)$

[例]: 在由具有一对基因差异的亲本杂交形成的 F_2 代群体中, 出现黄色子叶的概率为0.75, 出现青色子叶的概率为0.25, 这是二项总体的概率分布。如果从这种总体抽取3(n)粒, 那么得到1(y)粒是黄色子叶的概率是多少呢?

抽取三粒种子(以Y代黄子叶, 以G代青子叶), 即 $n=3$, 有两粒黄子叶种子, 即 $y=2$, 这时有3种不同组合: GGY, GYG, YGG, 出现第一粒, 第二粒和第三粒种子是互不影响的, 因此这三个事件是独立事件, 由乘法法则可得:

$$P(GGY) = \left(\frac{3}{4}\right)\left(\frac{3}{4}\right)\left(\frac{1}{4}\right) = \frac{9}{64} \quad P(GYG) = \left(\frac{3}{4}\right)\left(\frac{1}{4}\right)\left(\frac{3}{4}\right) = \frac{9}{64}$$

$$P(YGG) = \left(\frac{1}{4}\right)\left(\frac{3}{4}\right)\left(\frac{3}{4}\right) = \frac{9}{64}$$

由于这三个事件都是相互排斥的, 所以出现两粒黄子叶种子($y=2$)的概率为这三种概率之和:

$$P(y=2) = \left(\frac{3}{64}\right) + \left(\frac{3}{64}\right) + \left(\frac{3}{64}\right) = \frac{9}{64}$$

上述结果也可以表示为: $P(y=2) = C_3^2 \left(\frac{3}{4}\right)^2 \left(\frac{1}{4}\right)^1$

65

[例] 棉田盲蝽象为害的统计概率乃从调查2000株后获得近似值 $p=0.35$ 。现受害株事件为A, 其概率为 $p=0.35$, 未受害株事件为对立事件, 其概率 $q=(1-0.35)=0.65$ 。这一试验是可以重复的。假定做了 n 次试验, 即抽出 n 株为一个抽样单位, 那么, 试问出现有 y 株是受害的, 其概率应有多少?

假定以 $n=1$, 即抽出一株为一个抽样单位, 这里已知 $P(A)=0.35$ 和 $P(\bar{A})=0.65$, 总体的理论次数分布则以 n 乘上述概率分布, 即 np 和 $n(1-p)$, 所以有 $2000 \times 0.35=700$ 株受害和 $2000 \times 0.65=1300$ 株未受害。

如调查 $n=5$ 株为一个抽样单位, 则受害株数 $y=0, 1, 2, 3, 4$ 和5的概率可以计算出来。棉株受害数乃一随机变量(y), 可以计算变量 y 相应的

概率函数 $P(y=i) = C_n^i p^i q^{n-i}$ 和其累积函数 $F(y) = \sum_{i=0}^y P(y=i)$

如果每次抽5个单株, 抽400次, 理论上我们能够得到 $y=2$ 的次数应为:

理论次数= $400 \times P(y=2)$


66

调查单位为 $n=5$ 株的概率分布表 ($p=0.35, q=0.65$)


受害株数 概率函数 $P(y)$	$C_n^y p^y q^{n-y}$	$P(y)$	$F(y)$	$400 \times P(y)$
$P(0)$	$C_5^0 \times 0.35^0 \times 0.65^5$	0.1160	0.1160	46.40
$P(1)$	$C_5^1 \times 0.35^1 \times 0.65^4$	0.3124	0.4284	124.96
$P(2)$	$C_5^2 \times 0.35^2 \times 0.65^3$	0.3364	0.7648	134.56
$P(3)$	$C_5^3 \times 0.35^3 \times 0.65^2$	0.1811	0.9459	72.44
$P(4)$	$C_5^4 \times 0.35^4 \times 0.65^1$	0.0488	0.9947	19.52
$P(5)$	$C_5^5 \times 0.35^5 \times 0.65^0$	0.0053	1.0000	2.12

67

棉株受害百株象为害的概率函数
 $P(y)$ 分布图 ($p=0.35, n=5$)



棉株受害百株象为害的累积概率函数
 $F(y)$ 分布图 ($p=0.35, n=5$)



68

[例] 某种昆虫在某地区的死亡率为40%，即 $p=0.4$ ，现对这种害虫用一种新药进行治疗试验，每次抽样10头作为一组治疗。试问如新药无疗效，则在10头中死3头、2头、1头，以及全部愈好的概率为多少？

按上述二项分布概率函数式计算

7头愈好，3头死去概率： $P(3) = C_{10}^3 (0.40)^3 (0.60)^7 = 0.21499$

8头愈好，2头死去概率： $P(2) = C_{10}^2 (0.40)^2 (0.60)^8 = 0.12093$

9头愈好，1头死去概率： $P(1) = C_{10}^1 (0.40)^1 (0.60)^9 = 0.04031$

10头全部愈好的概率： $P(0) = C_{10}^0 (0.40)^0 (0.60)^{10} = 0.00605$


若问10头中不超过2头死去的概率为多少？则应该应用累积函数，即

$$\begin{aligned}
 F(2) &= \sum_{y=0}^2 P(y) \\
 &= P(0) + P(1) + P(2) \\
 &= 0.00605 + 0.04031 + 0.12093 \\
 &= 0.16729
 \end{aligned}$$


69

二项式分布的形状

棉株受害百株象为害的概率函数分布图
($p=0.35, n=5$)



棉株受害百株象为害的概率函数 $f(y)$ 图
($p=0.5, n=5$ 株)



从图可看出，如 $p=q$ ，二项式分布呈对称形状，如 $p \neq q$ ，则表现偏斜形状。

70

二项式分布的参数

仍以上述棉株受害为例，抽取5株中受害株数的多少(y)作为统计指标的话，从总体中可以抽取的所有样本均有一个 y ，这样所有的 y 构成了一个新总体，该总体也属于二项式总体，其平均数、方差和标准差如下式：

$$\begin{aligned}
 \mu &= np \\
 \sigma^2 &= npq \\
 \sigma &= \sqrt{npq}
 \end{aligned}$$

$$\begin{aligned}
 \mu &= E(y) = \sum_{y=0}^n y \cdot P(y = y) = np \\
 \sigma^2 &= E(y^2) - [E(y)]^2 = np(1-p)
 \end{aligned}$$

从而，上述棉田受害率调查结果， $n=5, p=0.35$ ，可求得总体参数为：

$$\begin{aligned}
 \mu &= 5 \times 0.35 = 1.75 \text{ 株} \\
 \sigma &= \sqrt{5 \times 0.35 \times 0.65} = \sqrt{1.1375} = 1.067 \text{ 株}
 \end{aligned}$$

71


Binomial distribution is often used to describe statistical regularity for the number of success outcome in n independent experiments.

$$X \sim B(n, p)$$

The expected value and variance of random variable X with binomial distribution are

$$E(X) = np = \sum_{i=1}^n i \times f(i)$$

$$\sigma^2(X) = np(1-p)$$



72

血球计计数的每平方格内酵母细胞数

酵母细胞数	0	1	2	3	4	5	6	7	8
次数	...	20	43	53	86	70	54	37	18
理论次数	3.71	17.37	40.65	63.41	74.19	69.44	54.16	36.21	21.18
酵母细胞数	9	10	11	12	13	14	15	16	总
次数	10	5	2	2	...	...	...	...	400
理论次数	11.02	5.16	2.19	0.86	0.31	0.10	0.03	0.01	400.00

本例 $\mu=4.68$, $e^{-\mu}=(2.71828)^{-4.68}=0.009275$, $0.009275 \times 400=3.71$. 3.71是理论次数第一项, 其他各理论次数均可按上述公式计算。概率值乘以400得理论次数。

本例标准差估计值为 $\hat{\sigma}=\sqrt{4.68}=2.16$

79

2.2.4 正态分布(normal distribution)—二项分布的极限分布

正态分布(normal distribution)是连续变量的理论分布, 在理论和实践问题上都具有非常重要的意义。

正态分布是二项分布的极限分布。以上述二项分布棉株受害率为例, 假定受害概率 $p=1/2$, 那么, $p=q=1/2$ 。现假定每个抽样单位包括20株, 这样将有21个组, 其受害株的概率函数为:

$$P(y) = C_{20}^y 0.5^y 0.5^{(20-y)}$$

于是概率分布计算如下:

$$\begin{aligned} \left(\frac{1}{2} + \frac{1}{2}\right)^{20} &= 1\left(\frac{1}{2}\right)^{20} + 20\left(\frac{1}{2}\right)^{20} + 190\left(\frac{1}{2}\right)^{20} + \dots + 20\left(\frac{1}{2}\right)^{20} + 1\left(\frac{1}{2}\right)^{20} \\ &= 0.00000 + 0.00002 + 0.00018 + \dots + 0.00002 + 0.00000 \end{aligned}$$


80

现将这概率分布绘于下图。从图看出它是对称的, 分布的平均数 μ 和方差 σ^2 为:

$$\mu = np = 20(1/2) = 10(\text{株}),$$

$$\sigma^2 = npq = 20(1/2)(1/2) = 5(\text{株})^2$$

- > 如 $p=q$, 不论 n 值大小, 二项分布的多边形图必形成对称;
- > 如 $p \neq q$, 而 n 很大时, 这多边形仍趋对称。



棉株受害率(0.5+0.5)²⁰分布图(实线表示二项式概率分布, 虚线表示接近的正态分布曲线)

81

倘 n 或组数增加到无穷多时($n \rightarrow \infty$), 多边形的折线就表现为一个光滑曲线。这个光滑曲线在数学上的意义是一个二项分布的极限曲线, 属于连续性变数分布曲线, 一般称之为正态分布曲线或正态概率密度曲线。可以推导出正态分布的概率密度函数为:

$$f_N(y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2}$$

其中, y 是所研究的变量; $f_N(y)$ 是概率密度函数;

μ 和 σ 为总体参数, μ 表示所研究总体平均数, σ 表示所研究总体标准差, 不同正态分布可以有不同 μ 和 σ , 但某一总体的 μ 和 σ 是常数(constant value)。

82

参数 μ 和 σ^2 有如下的数学表述:

$$\left. \begin{aligned} \mu &= \int_{-\infty}^{+\infty} y f_N(y) dy \\ \sigma^2 &= \int_{-\infty}^{+\infty} (y - \mu)^2 f_N(y) dy \end{aligned} \right\}$$


$$\text{令 } u = \frac{y - \mu}{\sigma} \text{ 可将 } f_N(y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2}$$

$$\text{标准化为: } \varphi(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u^2}$$


上式称为标准化正态分布方程, 它是参数 $\mu=0, \sigma^2=1$ 时的正态分布, 记作 $N(0, 1)$, 称为标准正态分布(standard normal distribution)。所有正态分布都可以转换为标准化正态分布

83

正态分布的曲线图



正态分布曲线图
(平均数为 μ , 标准差为 σ)




标准正态分布曲线图
(平均数 μ 为0, 标准差 σ 为1)

84

正态分布曲线的特性

(1) 正态分布曲线是以 $y = \mu$ 为对称轴，向左右两侧作对称分布，所以它是一个对称曲线。从所竖立的纵轴 $O = \mu$ 是最大值，所以正态分布曲线的算术平均数、中数和众数是相等的，三者均合一位位于点 μ 上。

(2) 正态分布曲线以参数 μ 和 σ 的不同而表现为一系列曲线，所以它是一个曲线族而不仅是一个曲线。 μ 确定它在横轴上的位置，而 σ 确定它的变异度，不同 μ 和 σ 的正态总体具有不同的曲线和变异度，所以任何一个特定正态曲线必须在其 μ 和 σ 确定后才能确定。



(3) 正态分布资料的次数分布表现为多数次数集中于算术平均数 μ 附近，离平均数越远，其相应的次数越少；且在 μ 左右相等 $|y - \mu|$ 范围内具有相等次数；在 $|y - \mu| \geq 3\sigma$ 以上其次数极少。

(4) 正态曲线在 $|y - \mu| = 1\sigma$ 处有“拐点”。曲线两尾向左右伸展，永不接触横轴，所以当 $y \rightarrow \pm\infty$ ，分布曲线以 y 轴为渐近线，因之曲线全距从 $-\infty$ 到 $+\infty$ 。

(5) 正态曲线与横轴之间的总面积等于 1，因此在曲线下横轴的任何定值，例如从 y_1 到 y_2 之间的面积，等于介于这两个定值间面积占总面积的成数，或者说等于 y 落在这个区间内的概率。

正态曲线的任何两个 y 定值 y_a 与 y_b 之间的面积或概率乃完全以曲线的 μ 和 σ 而确定的。详细数值见附表 2，下面为几对常见的区间与其相对应的面积或概率的数字：

区间 $\mu \pm 1\sigma$	面积或概率 = 0.6827
$\mu \pm 2\sigma$	= 0.9545
$\mu \pm 3\sigma$	= 0.9973
$\mu \pm 1.960\sigma$	= 0.9500
$\mu \pm 2.576\sigma$	= 0.9900

66

[例] 前面讲到的水稻 140 行产量资料的样本分布表现出接近正态分布，其平均数 ($\bar{y}$)、标准差 (s) 以及离均差为 1、2 和 3 个标准差的区间所包括的次数列于下表。实验的结果与正态分布的理论结果很相近。

140 行水稻产量在 $\bar{y} \pm 1s$, $\bar{y} \pm 2s$, $\bar{y} \pm 3s$ 范围内所包括的次数表

$\bar{y} \pm ks$	数值(g)	区间(g)	区间内包括的次数	
			次数	%
$\bar{y} \pm 1s$	157.9 $\pm$ 36.4	121.5 ~ 194.5	99	70.71
$\bar{y} \pm 2s$	157.9 $\pm$ 72.8	85.1 ~ 230.7	134	95.71
$\bar{y} \pm 3s$	157.9 $\pm$ 109.2	48.7 ~ 267.1	140	100.00

67

计算正态分布曲线区间面积或概率的方法


在正态分布曲线下， y 的定值从 $y=a$ 到 $y=b$ 间的概率可用曲线下区间的面积来表示，或者说，用其定积分的值表示：

$$P(a < y \leq b) = \int_a^b \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2} dy$$

同样可以计算曲线下从 $-\infty$ 到 y 的面积，其公式如下：

$$F_N(y_0) = \int_{-\infty}^{y_0} f_N(y) dy$$

这里 $F_N(y)$ 称为正态分布的累积函数，具有平均数 μ 和标准差 σ 。



68

现如给予变量任何一定值如 a ，那么，可以计算 $y \leq a$ 的概率为 $F_N(a)$ ，即

$$P(y \leq a) = F_N(a)$$


如果 a 与 b ($a < b$) 是 y 的两个定值，则其区间概率可从下式计算：

$$P(a < y \leq b) = F_N(b) - F_N(a)$$

$$\text{当 } y \rightarrow -\infty, F_N(-\infty) = 0$$

$$\text{当 } y \rightarrow +\infty, F_N(+\infty) = 1$$

正态分布的密度函数 $f_N(y)$ 是按 y 值将累积函数 $F_N(y)$ 求其导数得之。



69

[例] 假定 y 是一随机变量具有正态分布，平均数 $\mu=30$ ，标准差 $\sigma=5$ ，试计算小于 26，小于 40 的概率，介于 26 和 40 区间的概率以及大于 40 的概率。

$$\text{首先计算: } P(y \leq 26) = F_N(26)$$

$$\text{先将 } y \text{ 转换为 } u \text{ 值 } u = \frac{y - \mu}{\sigma} = \frac{26 - 30}{5} = -0.8$$


查附表 2 (参考书)，当 $u = -0.8$ 时， $F_N(26) = 0.2119$ ，说明这一分布从 $-\infty$ 到 26 范围内的变量数占全部变量数的 21.19%，或者说， $y \leq 26$ 概率为 0.2119。

$$\text{同理可得: } F_N(40) = 0.9773$$

$$\text{所以: } P(26 < y < 40) = F_N(40) - F_N(26) = 0.9773 - 0.2119 = 0.7654$$

$$P(y > 40) = 1 - P(y \leq 40) = 1 - 0.9773 = 0.0227$$

70



[例] 在应用正态分布时，经常要讨论随机变量 y 离其平均数的差数大于或小于若干个值的概率。例如计算离均差绝对值等于小于和等于大于 1σ 的概率为：

$$P(\mu - \sigma \leq y \leq \mu + \sigma) = 0.84134 - 0.15866 = 0.68268$$

也可以简写为： $P(|y - \mu| \leq \sigma) = 0.6827$

$$\therefore P(|y - \mu| \geq \sigma) = 1 - 0.6827 = 0.3173$$

相应地，离均差绝对值等于小于 2σ 、等于大于 2σ 、等于小于 3σ 和等于大于 3σ 的概率值为：

$$P(|y - \mu| \leq 2\sigma) = P(\mu - 2\sigma \leq y \leq \mu + 2\sigma) = P(-2 \leq u \leq +2) = 0.9545$$


$$P(|y - \mu| \geq 2\sigma) = 1 - 0.9545 = 0.0455$$

$$P(|y - \mu| \leq 3\sigma) = P(\mu - 3\sigma \leq y \leq \mu + 3\sigma) = P(-3 \leq u \leq +3) = 0.9973$$

$$P(|y - \mu| \geq 3\sigma) = 1 - 0.9973 = 0.0027$$

以上结果解释了正态分布曲线的概率特性，可参考下页图。

92



[例] 计算正态分布曲线的中间概率为0.99时，其 y 或 u 值应等于多少？

因为正态分布是对称的，故在曲线左边从 $-\infty$ 到 $-u$ 的概率和在曲线右边从 u 到 $+\infty$ 的概率都应等于 $1/2(1-0.99)=0.005$ 。查表， $u=-2.58$ 时， $f_N(y)=0.00494 \approx 0.005$ 。于是知，当 $y = \mu \pm 2.58\sigma$ 时，在其范围内包括99%的变量，仅有1%变量在此范围之外。上述结果写作：

$$P(|y - \mu| \geq 2.58\sigma) = P(|u| \geq 2.58) = 0.01$$

$$P(|y - \mu| \leq 2.58\sigma) = P(|u| \leq 2.58) = 0.99$$

同理可求得：

$$P(|y - \mu| \geq 1.96\sigma) = P(|u| \geq 1.96) = 0.05$$

$$P(|y - \mu| \leq 1.96\sigma) = P(|u| \leq 1.96) = 0.95$$

以上 $P(|y - \mu| \geq 2.58\sigma)$ 乃正态曲线下左边一尾 y 从 $-\infty$ 到 $y_1 = \mu - 2.58\sigma$ 上的面积和右边一尾 y 从 $y_2 = \mu + 2.58\sigma$ 到 $+\infty$ 上的面积之和，亦可写成：

$$P(|y - \mu| \geq 2.58\sigma) = P(y \leq \mu - 2.58\sigma) + P(y \geq \mu + 2.58\sigma)$$

同理， $P(|y - \mu| \geq 1.96\sigma)$ 亦可写成：

$$P(|y - \mu| \geq 1.96\sigma) = P(y \leq \mu - 1.96\sigma) + P(y \geq \mu + 1.96\sigma)$$

94

2.3 抽样分布(sampling distribution)

统计学的一个主要任务是研究总体(population)和样本(sample)之间的关系，根本目的是用样本来推断总体。由于抽样的随机性(randomicity)，从同一个总体中可能取到不同的样本，导致统计量(statistic)的取值不同进而统计分析的结果也不同。


从总体中随机抽样(random sampling)得到样本，获得样本观察值(observation value)后可以计算一些统计量，统计量是随机变量(random variable)，其概率分布(probability distribution)称为抽样分布(sampling distribution)。

两个方向

- 从总体到样本的方向，即本节所要讨论的抽样分布。
- 从样本到总体的方向，即统计推断(statistical inference)问题。

抽样分布是统计推断的基础。

95



2.3.1 统计量的抽样分布及其参数(sampling distribution of a statistic and its distribution parameters)

如果总体为无限总体(unlimited), 那么通过随机抽样可以得到无限多个随机样本; 如果从容量为 N 的有限总体(limited)抽样, 若每次抽取容量为 n 的样本, 那么一共可以得到 N^n 个样本(所有可能的样本个数)。

针对每个抽取容量 $n \geq 3$ 的随机样本, 都可以计算其平均数、方差、标准差等。多个随机样本的同一类统计量集合起来就可以形成一个新总体, 那么任何一种统计量就成为这个新的总体的一个变量(variable), 这种变量的分布称为统计量的抽样分布(sampling distribution of a statistic)。

97

(1) 样本平均数的抽样分布(sampling distribution of mean)

抽样所得到的每一个样本可以计算一个平均数, 全部可能的样本都被抽取后可以得到许多平均数, 如 $\bar{y}_1, \bar{y}_2, \dots, \bar{y}_m$ 等。如果将抽样得到的所有可能的样本平均数集合起来便构成一个新的总体(new population), 那么平均数(mean)就成为这个新总体的变量。由平均数构成的新总体的分布, 称为平均数的抽样分布(sampling distribution of mean)。

新总体与母总体在特征参数上存在函数关系。以平均数抽样分布为例, 这种关系可表示为以下两个方面:

- (1) 该抽样分布的平均数 $\mu_{\bar{y}}$ 与母总体的平均数相等。

$$\mu_{\bar{y}} = \mu$$

- (2) 该抽样分布的方差与母总体方差间存在如下关系:

$$\left. \begin{aligned} \sigma_{\bar{y}}^2 &= \sigma^2/n \\ \sigma_{\bar{y}} &= \sigma/\sqrt{n} \end{aligned} \right\}$$

其中 n 为样本容量。抽样分布的标准差(standard deviation)又称为标准误(standard error), 它可以度量抽样分布的变异(variation of sampling distribution)。

98

[例] 设有一总体 $N=3$ (例2, 4, 6)。以样本容量 $n=1, n=2, n=4$ 及 $n=8$, 从总体中进行重复抽样:

$n=1$: 3种可能: 2, 4, 6

$n=2$: $3 \times 3 = 9$ 种可能: 2+2, 2+4, 2+6, 4+2, 4+4, 4+6, 6+2, 6+4, 6+6

$n=4$: $3 \times 3 \times 3 \times 3 = 81$ 种可能


$n=8$: $3 \times 3 \times 3 \times 3 \times 3 \times 3 \times 3 \times 3 = 6561$ 种可能

99


各种不同样本容量的样本平均数($\bar{y}$)的抽样分布

$n=1$		$n=2$		$n=4$		$n=8$	
$\bar{y}$	f	$\bar{y}$	f	$\bar{y}$	f	$\bar{y}$	f
						2.00	1
						2.25	8
						2.50	36
						2.75	112
						3.00	266
				2.0	1	3.25	504
				2.5	4	3.50	784
				3.0	10	3.75	1016
		2	1	3.5	16	4.00	1107
		3	2	4.0	19	4.25	1016
		4	3	4.5	16	4.50	784
		5	2	5.0	10	4.75	504
		6	1	5.5	4	5.00	266
				6.0	1	5.25	112
						5.50	36
						5.75	8
						6.00	1
							6561
平均数	4	4	4	4	4	4	
方差	8/3	4/3	2/3	1/3			

100



101



102

由表中第一列当 $N=3, n=1$ 的总体平均数和方差为:

$$\mu = \sum_{i=1}^N y_i / N = (2+4+6)/3 = 12/3 = 4$$

$$\sigma^2 = \sum_{i=1}^N (y_i - \mu)^2 / N = [(2-4)^2 + (4-4)^2 + (6-4)^2] / 3 = 8/3$$

当样本容量依次为2、4、8时, 其 $\mu_{\bar{y}}$ 相应为4、4、4; 其 $\sigma_{\bar{y}}^2$ 相应为4/3、2/3、1/3。即:

$$\mu_{\bar{y}} = \mu$$

$$\sigma_{\bar{y}}^2 = \sigma^2 / n$$

183

(2) 两个独立随机样本平均数差数的抽样分布(sampling distribution of difference between means of two independent samples)

如果从一个总体随机地抽取一个样本容量为 n_1 的样本, 同时随机独立地从另一个总体抽取一个样本容量为 n_2 的样本, 那么可以得到分别属于两个总体的样本, 这两个独立随机抽取的样本平均数间差数($\bar{y}_1 - \bar{y}_2$)的抽样分布参数与两个母总体间存在如下关系:

(1) 该抽样分布的平均数与母总体的平均数之差相等。

$$\mu_{\bar{y}_1 - \bar{y}_2} = \mu_1 - \mu_2$$

(2) 该抽样分布的方差与母总体方差间的关系为:

$$\sigma_{\bar{y}_1 - \bar{y}_2}^2 = \sigma_{\bar{y}_1}^2 + \sigma_{\bar{y}_2}^2 = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$$

184

[例] 假定第一个总体包括3个观察值, 2、4和6 ($N_1=3$), 抽出的样本容量为2($n_1=2$), 所有样本数为 $N=3^2=9$ 个, 总体平均数和方差 $\mu_1=4, \sigma_1^2=8/3$ 。第二个总体包括2个观察值, 3和6 ($N_2=2$), 抽出的样本容量为3($n_2=3$), 所以所有样本数为 $2^3=8$ 个, 总体平均数和方差 $\mu_2=4.5, \sigma_2^2=2.25$ 。下表为两个总体 $\bar{y}$ 的次分布表及其分布的参数。

$\bar{y}_1$	f	$\bar{y}_2$	f
2	1	3	1
3	2	4	3
4	3	5	3
5	2	6	1
6	1		
总和	9	总和	8
$N_1=3$ $\mu_1=4$ $\sigma_1^2=8/3$	$n_1=2$ $\mu_{\bar{y}_1}=\mu_1=4$ $\sigma_{\bar{y}_1}^2=\sigma_1^2=8/3$	$N_2=2$ $\mu_2=4.5$ $\sigma_2^2=2.25$	$n_2=3$ $\mu_{\bar{y}_2}=\mu_2=4.5$ $\sigma_{\bar{y}_2}^2=\sigma_2^2=2.25$

将第一总体的9个样本平均数和第二总体的8个样本平均数作所有可能的相互比较, 这样共有 $9 \times 8 = 72$ 个比较或72个差数。

185

72个样本平均数差数的次分布表

$\bar{y}_1$	2, 2, 2, 2, 3, 3, 3, 3, 4, 4, 4, 4	$\bar{y}_2$	3, 4, 5, 6, 3, 4, 5, 6, 3, 4, 5, 6	总和
$\bar{y}_1 - \bar{y}_2$	-1, -2, -3, -4, 0, -1, -2, -3, 1, 0, -1, -2		2, 1, 0, -1, 3, 2, 1, 0	
f	1, 3, 3, 1, 2, 6, 6, 2, 3, 9, 9, 3		2, 6, 6, 2, 1, 3, 3, 1	72

72个样本平均数差数分布的平均数和方差计算表

$\bar{y}_1 - \bar{y}_2$	f	$f(\bar{y}_1 - \bar{y}_2)$	$(\bar{y}_1 - \bar{y}_2 + 0.5)$	$(\bar{y}_1 - \bar{y}_2 + 0.5)^2$	$(\bar{y}_1 - \bar{y}_2 + 0.5)^2$
-4	1	-4	-3.5	12.25	12.25
-3	5	-15	-2.5	6.25	31.25
-2	12	-24	-1.5	2.25	27.00
-1	18	-18	-0.5	0.25	4.50
0	18	0	0.5	0.25	4.50
1	12	12	1.5	2.25	27.00
2	5	10	2.5	6.25	31.25
3	1	3	3.5	12.25	12.25
总和	72	-36			150.00

186

由表可算得:

$$\mu_{\bar{y}_1 - \bar{y}_2} = (-36)/72 = -0.5 \quad \mu_1 - \mu_2 = 4 - 4.5 = -0.5$$

$$\sigma_{\bar{y}_1 - \bar{y}_2}^2 = \frac{\sum [(\bar{y}_1 - \bar{y}_2) - (\mu_1 - \mu_2)]^2}{72} = \frac{\sum (\bar{y}_1 - \bar{y}_2 + 0.5)^2 f}{72} = \frac{150}{72} = \frac{25}{12}$$

$$\text{而 } \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} = \frac{8/3}{2} + \frac{9/4}{3} = \frac{4}{3} + \frac{3}{4} = \frac{25}{12}$$

这与按照前面给的公式的计算结果相同:

$$\mu_{\bar{y}_1 - \bar{y}_2} = \mu_1 - \mu_2 = 4 - 4.5 = -0.5$$

$$\sigma_{\bar{y}_1 - \bar{y}_2}^2 = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} = \frac{4}{3} + \frac{3}{4} = \frac{25}{12}$$


187

2.3.2 正态总体的抽样分布(sampling distribution of normal population)

(1) 样本平均数的抽样分布(sampling distribution of the sample mean)

从正态总体抽取的样本, 无论样本容量大小, 其样本平均数($\bar{y}$)的分必呈正态分布 $N(\mu, \sigma^2/n)$, 而且方差随样本容量的增大而降低。

右图给出样本容量 $n=1, 4$ 与9时的分布, 从图中可以看出随着样本容量的增加, 分布的集中程度增加了, 说明方差减少了。



不同样本容量的抽样分布

188

平均数的抽样分布

中心极限定理(central limit theorem)

如果母总体(μ, σ^2)不是正态分布, 从中抽样所得的平均数($\bar{y}$)的分布不一定属于正态分布, 但当样本容量(n)增大时, 从该总体抽出样本的平均数($\bar{y}$)的抽样分布趋近于正态分布。

也就是说, 只要样本容量适当大, 不论总体分布形状如何, 其平均数 $\bar{y}$ 的分布都可看作为正态分布, 且具平均数 μ 和方差 σ^2/n 。被称为中心极限定理(central limit theorem)。

在实际应用上, 如 $n>30$ 就可以应用这一定理。

平均数的标准化分布是将上述平均数 $\bar{y}$ 转换为 u 变数。

$$u = \frac{\bar{y} - \mu}{\sigma_{\bar{y}}} = \frac{\bar{y} - \mu}{\sigma/\sqrt{n}}$$

109

[例] 在江苏沛县调查336个 m^2 小地老虎虫害情况的结果, $\mu=4.73$ 头,

$\sigma=2.63$, 试问样本容量 $n=30$ 时, 由于随机抽样得到样本平均数 $\bar{y}$ 等于或小于4.37的概率为多少?

$$\sigma_{\bar{y}} = \frac{\sigma}{\sqrt{n}} = \frac{2.63}{\sqrt{30}} = \frac{-0.36}{0.48} = 0.480(\text{头})$$

$$u = \frac{\bar{y} - \mu}{\sigma_{\bar{y}}} = \frac{(4.37 - 4.73)}{0.480} = \frac{-0.36}{0.48} = -0.75$$

查附表2(参考书), $P(u \leq -0.36) = 0.2266$, 即概率为22.66%(属一尾概率)。因所得概率较大, 说明差数-0.36是随机误差, 从而证明这样本平均数4.37是有代表性的, 变异系数为:

$$CV = \frac{\sigma_{\bar{y}}}{\bar{y}} = \frac{0.48}{4.37} \times 100\% = 11.0\%$$

110

(二) 两个独立样本平均数差数的抽样分布(sampling distribution of the difference between the means of two independent samples)

假定有两个正态总体各具有平均数和标准差为 μ_1, σ_1 和 μ_2, σ_2 , 从第一个总体随机抽取 n_1 个观察值, 同时独立地从第二个总体随机抽取 n_2 个观察值。这样计算出样本平均数和标准差 $\bar{y}_1, s_1$ 和 $\bar{y}_2, s_2$ 。

从统计理论可以推导出其样本平均数的差数($\bar{y}_1 - \bar{y}_2$)的抽样分布, 具有以下特性:

(1) 如果两个总体各作正态分布, 则其样本平均数差数($\bar{y}_1 - \bar{y}_2$)准确地遵循正态分布律, 无论样本容量大或小, 都有 $N(\mu_{\bar{y}_1 - \bar{y}_2}, \sigma_{\bar{y}_1 - \bar{y}_2}^2)$ 。

(2) 两个样本平均数差数分布的平均数必等于两个总体平均数的差数, 即 $\mu_{\bar{y}_1 - \bar{y}_2} = \mu_1 - \mu_2$ 。

(3) 两个独立的样本平均数差数分布的方差等于两个总体的样本平均数的方差总和, 即 $\sigma_{\bar{y}_1 - \bar{y}_2}^2 = \sigma_{\bar{y}_1}^2 + \sigma_{\bar{y}_2}^2 = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$ 。

其差数标准差为: $\sigma_{\bar{y}_1 - \bar{y}_2} = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$ 这个分布也可标准化, 获得 u 值。 $u = \frac{(\bar{y}_1 - \bar{y}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$

111

小结:

● 若两个样本来自于同一正态总体, 则其平均数差数的抽样分布不论容量大小亦作正态分布具:

$$\mu_{\bar{y}_1 - \bar{y}_2} = 0, \sigma_{\bar{y}_1 - \bar{y}_2} = \sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

● 若两个样本来自于同一总体, 但并非正态总体, 则其平均数差数的抽样分布按中心极限定理在 n_1 和 n_2 相当大时(大于30)才逐渐接近于正态分布。

● 若两个样本来自于两个非正态总体, 当 n_1 和 n_2 相当大, 而 σ_1^2 与 σ_2^2 相差不太远时, 也可近似地应用正态接近方法估计平均数差数出现的概率, 当然这种估计的可靠性得依两总体偏离正态的程度和相差大小而转移。

112

2.3.3 二项总体的抽样分布(sampling distribution of binomial population)

(1) 二项总体的分布参数

平均数: $\mu = p$

方差: $\sigma^2 = p(1-p) = pq$

标准差: $\sigma = \sqrt{p(1-p)} = \sqrt{pq}$

其中 p 为二项总体中要研究的属性事件发生的概率, $q=1-p$ 。

(二) 样本平均数(成数)的抽样分布

从二项总体进行抽样得到样本, 样本平均数抽样分布的参数为:

平均数: $\mu_{\bar{y}} = p$

方差: $\sigma_{\bar{y}}^2 = \frac{pq}{n}$ 标准差: $\sigma_{\bar{y}} = \sqrt{\frac{pq}{n}} = \sqrt{\frac{p(1-p)}{n}}$

同样 n 是样本容量。

113

[例] 棉田盲蚜象为害棉株分为受害株与未受害株。假定调查2000株作为一个总体, 受害株为704株。

这是一个二项总体, 于是计算出受害率 $p=35.2\%$, 或0.352。

$\sigma = \sqrt{p(1-p)} = \sqrt{0.352 \times 0.648} = 0.4776$ 或47.76%。

现从这一总体抽样, 以株为单位, 用简单随机抽样方法, 调查200株棉株, 获得74株受害, 那么, 观察受害率(就是成数, 或者说是样本平均数) $\bar{p} = 74/200 = 37.0\%$,

试问样本平均数与总体真值的差数的概率为多少?

114

总体真值 $p=0.352$,

差数 $= (\hat{p} - p) = (0.370 - 0.352) = 0.018$.

成数的标准差 $\sigma_{\hat{p}} = \sqrt{p(1-p)/n} = \sqrt{0.228096/200}$
 $= 0.034$ 或 3.4% .

由于二项分布在 np 及 nq 大于 5 时, 趋近于正态分布, 本例样本较大可视为正态分布, 采用正态离差 u 查出概率。

$$\text{于是 } u = \frac{\hat{p} - p}{\sigma_{\hat{p}}} = \frac{0.018}{0.034} = 0.53.$$

查附表3 (参考书), 当 $u=0.53$, 概率值为 0.59,

即获得这种 $|\hat{p} - p| \geq 0.018$ 的概率 (两尾概率) 为 0.59。因所得概率太大, 说明差数 0.018 是随机误差, 这就说明样本估计的受害率 (样本平均数) 为 37.0% 有代表性 (可以近似代表总体的受害率)。

115

针对每个抽取容量 $n \geq 3$ 的随机样本, 都可以计算其平均数、方差、标准差等。多个随机样本的同一类统计量集合起来就可以形成一个新的总体, 那么任何一种统计量就成为这个新的总体的一个变量 (variable), 这种变量的分布称为统计量的抽样分布 (sampling distribution of a statistic)。

因此, 除了本章讲的平均数的抽样分布外还有总和数、方差、标准差的抽样分布等。抽样分布是统计推断分析的基础, 其它重要的统计抽样分布如 t 分布、 χ^2 分布、 F 分布将在后继相应章节详细介绍。

116