

数理统计基础-3

Fundamentals of Mathematical Statistics

卢运海

2020-9

5. 卡平方(χ^2)测验(χ^2 -testing)
6. 参数估计方法(estimation methods of parameters)

5. 卡平方(χ^2)测验(χ^2 -testing)

- 5.1 卡平方(χ^2)的定义和分布(definition and distribution of χ^2)
- 5.2 方差同质性测验(test of homogeneity of variance)
- 5.3 适合性测验(test of goodness of fit)
- 5.4 独立性测验(test of independence)
- 5.5 χ^2 的可加性和联合分析(additivity and joint analysis of χ^2)

5.1 卡平方(χ^2)的定义和分布(definition and distribution of χ^2)

所谓 χ^2 (chi-square),是指相互独立的多个正态离差平方值的总和,即:

$$\chi^2 = u_1^2 + u_2^2 + \dots + u_i^2 + \dots + u_n^2 = \sum_{i=1}^n u_i^2 = \sum_{i=1}^n \left(\frac{y_i - \mu_i}{\sigma_i} \right)^2$$

其中 y_i 服从正态分布 $N(\mu_i, \sigma_i^2)$,

$u_i = (y_i - \mu_i) / \sigma_i$ 为标准正态离差。

y_i 不一定来自同一个正态总体,即 μ_i 及 σ_i 可以是不同正态分布的参数。

若通常所研究的对象属同一个总体,则 $\mu_i = \mu$, $\sigma_i = \sigma$, 从而有

$$\chi^2 = \sum_{i=1}^n \left(\frac{y_i - \mu}{\sigma} \right)^2$$

若所研究的总体 μ 未知,而以样本 $\bar{y}$ 代替,则

$$\chi^2 = \sum_{i=1}^n \left(\frac{y_i - \bar{y}}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{(n-1)s^2}{\sigma^2} = \frac{ns^2}{\sigma^2}$$

此时独立的正态离差个数为 $n-1$ 个,故 $v = n-1$ 。

$$\left(s^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1} \right)$$

χ^2 分布是由阿贝(Ernest Abbe)于1863年首先提出的,后来由海尔默特(Friedrich Robert Hermert)和现代统计学的奠基人之一的卡·皮尔逊(Karl Pearson)分别于1875年和1900年推导出来。

χ^2 抽样分布的密度函数为: $f(\chi^2) = \frac{(\chi^2)^{(v/2)-1} e^{-\chi^2/2}}{2^{v/2} \Gamma(v/2)}$

χ^2 累积分布函数为: $F(\chi_p^2) = P(\chi^2 \geq \chi_p^2) = \int_{\chi_p^2}^{\infty} f(\chi^2) d(\chi^2)$

χ^2 分布的自由度为独立的正态离差的个数,此处 $v=n$ 。


其分布图形为一组具不同自由度 v 值的曲线。

χ^2 值最小为0,最大为 $+\infty$,因而在坐标轴的右面。

自由度小时呈偏态,随着自由度增加,偏度降低,至 $+\infty$ 时,呈对称分布。

该分布的平均数为 v , 方差为 $2v$ 。

附表5给出了 $\chi^2 \geq \chi_p^2$ 时的右尾概率。



χ^2 与 u 、 t 、 F 统计量的比较:

按定义 $\sum_{i=1}^n u_i^2 = \chi^2$, 当只有1个正态离差时 $u^2 = \chi^2$, $u = \sqrt{\chi^2}$

$t = \frac{y - \mu}{s}$, 当 s 的自由度无限增大时 $t = \frac{y - \mu}{\sigma} = u = \sqrt{\chi^2}$,

此时 χ^2 的 $v=1$ 。

$F = s_1^2 / s_2^2$, 当 s_2^2 的自由度无限增大时 $F = s_1^2 / \sigma^2 = \chi^2 / v$,

v 为 s_1^2 的自由度。


$$\left(\chi^2 = \sum_{i=1}^n \left(\frac{y_i - \bar{y}}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{(n-1)s^2}{\sigma^2} = \frac{ns^2}{\sigma^2} \right)$$

卡尔·皮尔逊 Karl Pearson (1857~1936) 1900年根据 χ^2 的上述定义从属性状的分布推导出用于数量资料(亦称计数资料)分析的 χ^2 公式:

$$\chi^2 = \sum_i \frac{(O - E)^2}{E}$$

上式中 O 为观察次数, E 为理论次数, $i=1, \dots, k$ 为计数资料的分组数, 自由度为 ν , 依分组数及其相互独立的程度决定, 这种形式的 χ^2 分布图形与前面介绍的相同。

► 因此, χ^2 值是多项 u_i^2 或 $(O-E)^2/E$ 之和, χ^2 具有可加性。



5.2 方差同质性测验 (test of homogeneity of variance)

5.2.1 一个样本方差与给定总体方差比较的假设测验(test of comparison of variances between a sample and a given population)

$\chi^2 = \frac{1s^2}{\sigma^2}$ 可用来测验单个样本方差 s^2 其所代表的总体方差和给定的总体方差值 σ^2 是否有显著差异, 简称为一个样本与给定总体方差的比较。

在作两尾测验时有 $H_0: \sigma^2 = C$, 对 $H_1: \sigma^2 \neq C$ 。其显著大于和小于 C 的 χ^2 值是 $\chi^2 > \chi^2_{(1-\alpha/2), \nu}$ 和 $\chi^2 < \chi^2_{(\alpha/2), \nu}$, 此时, H_0 在 α 显著水平上被否定。

【例】硫酸铵施于水田表层试验，得4个小区的稻谷产量为517、492、514、522(kg)，计得样本方差为175.6(kg)²。现要测验 $H_0: \sigma^2 = 50(\text{kg})^2$ 对 $H_A: \sigma^2 \neq 50(\text{kg})^2$ ，采用显著水平 $\alpha=0.05$ 。

据 $\chi^2 = \frac{15s^2}{\sigma^2}$ 可算得: $\chi^2 = \frac{(4-1) \times 175.6}{50} = 10.54$

查附表5, 在 $v=n-1=3$ 时, $\alpha/2$ 和 $(1-\alpha/2)$ 水平的 χ^2 临界值为: $\chi_{0.025}^2=9.35$, $\chi_{0.975}^2=0.22$. 现 $\chi^2=10.54$, 大于 $\chi_{0.025}^2=9.35$, 在 $0.22\sim 9.35$ 范围外 (前面讲的区间估计), 符合 H_0 的概率小于 0.05 , H_0 被否定。

结论: 这一样本并非从 $\sigma^2 = 50(\text{kg})^2$ 的总体中所抽取的.

品名	單位	數量	價格	合計	備註
1. 水泥	噸	100	120.00	12000.00	
2. 砂	方	500	15.00	7500.00	
3. 石子	方	300	20.00	6000.00	
4. 磚	千塊	200	10.00	2000.00	
5. 木材	方	100	30.00	3000.00	
6. 石灰	噸	50	8.00	400.00	
7. 石膏	噸	20	12.00	240.00	
8. 玻璃	方	10	15.00	150.00	
9. 油漆	桶	50	2.00	100.00	
10. 五金	元	1000	1.00	1000.00	
11. 電料	元	500	1.00	500.00	
12. 其他	元	200	1.00	200.00	
13. 人工	工日	1000	10.00	10000.00	
14. 材料	元	500	1.00	500.00	
15. 運輸	元	100	1.00	100.00	
16. 管理	元	50	1.00	50.00	
17. 利潤	元	100	1.00	100.00	
18. 稅金	元	50	1.00	50.00	
19. 其他	元	20	1.00	20.00	
20. 合計	元			50000.00	

若测验该样本总体方差是否小于某给定总体方差 C , 则作一尾测验, 即 $H_0: \sigma^2 \leq C$ 对 $H_A: \sigma^2 > C$, 如果算得的 $\chi^2 > \chi^2_{\alpha, n}$, 那就跌入了右侧的小概率区域, 因此可以否定 H_0 , 否则接受 H_0 ; 这里应用分布的右边一尾。

► 如果测验其是否大于C, 则 $H_0: \sigma^2 \geq C$ 对 $H_A: \sigma^2 < C$, 若算得的 $\chi^2 < \chi^2_{(1-\alpha), n}$, 则否定 H_0 ; 这里应用分布的左边一尾.

[例] 试审查前一个例子中试验结果的总体方差是否真大于某一定值, 如 $50(\text{kg})^2$?

这里试验的表面结果方差 $175.6(\text{kg})^2$ 大于 $50(\text{kg})^2$, 要问其总体方差是否真正大, 抑或并不大, 甚至小于 $50(\text{kg})^2$

测验假设 $H_0: \sigma^2 \geq 50$ 对 $H_A: \sigma^2 < 50$.

取5%为显著水平。

查附表5, 这一测验的 χ^2 临界值为 $\chi_{0.95,3}^2 = 0.35$,

而计算的 $\chi^2 = \frac{3 \times 175.6}{50} = 10.54$,

因 $10.54 > 0.35$, 没有跌入左侧的小概率区域, 所以 H_0 应被接受, 即总体方差并不小于 $50(\text{kg})^2$ 。

13

附表5 χ^2 值表 (右侧)

14

根据 $\chi^2 = \frac{v s^2}{\sigma^2}$, 可应用 χ^2 分布由样本 s^2 给出一个总体 σ^2 置信区间(confidence interval), 在此区间内包括有总体 σ^2 的概率为 $(1-\alpha)$,

即 $P\left\{\chi_{(1-\alpha/2),v}^2 \leq \frac{v s^2}{\sigma^2} \leq \chi_{(\alpha/2),v}^2\right\} = 1 - \alpha$

从而有: $\frac{v s^2}{\chi_{(\alpha/2),v}^2} \leq \sigma^2 \leq \frac{v s^2}{\chi_{(1-\alpha/2),v}^2}$

已知 $v s^2 = \sum (y - \bar{y})^2$, 故上面的公式又可记为:

$$\frac{\sum (y - \bar{y})^2}{\chi_{(\alpha/2),v}^2} \leq \sigma^2 \leq \frac{\sum (y - \bar{y})^2}{\chi_{(1-\alpha/2),v}^2}$$

15

[例] 求上面的举例资料中总体 σ^2 的95%置信限。

因为 $v = 3$, $\chi_{0.975,3}^2 = 0.22$, $\chi_{0.025,3}^2 = 9.35$, 且已知 $s^2 = 175.6$, 故对总体方差 σ^2 的95%置信限的下限 L_1 和上限 L_2 为:

$$L_1 = \frac{v s^2}{\chi_{(\alpha/2),v}^2} = \frac{3 \times 175.6}{9.35} = 56.3$$

$$L_2 = \frac{v s^2}{\chi_{(1-\alpha/2),v}^2} = \frac{3 \times 175.6}{0.22} = 2394.5$$

于是95%的置信限为:

$$56.3 \leq \sigma^2 \leq 2394.5$$

注: 这一置信限并不对称, 即从 L_1 到 s^2 的距离不等于 s^2 到 L_2 的距离。

利用置信限也可做显著性测验, 上面例子中给定总体的 $\sigma^2 = 50$, 在 $56.3 \sim 2394.5$ 范围外, 故亦推断两者非同一总体。标准差的置信限可进而算出为:

$$\sqrt{56.3} \leq \sigma \leq \sqrt{2394.5} \quad \text{即} \quad 7.5 \leq \sigma \leq 48.9$$

本例因 v 较小, 故方差置信限的区间甚大。

一般 $n \leq 30$ 时, 单个样本方差用 χ^2 分布来测验和推断置信区间; $n > 30$ 时, χ^2 分布近似对称, $\sqrt{2\chi^2} - \sqrt{2v-1}$ 近似服从 $N(0, 1)$ 分布, 因此, 用 u 测验并进行区间估计。

(χ^2 分布的平均数为 v , 方差为 $2v$ 。)

17

5.2.2 几个样本方差的同质性测验(test of homogeneity of variance among several samples)

假定有3个或3个以上样本, 每一样本均可估得一方差, 则由 χ^2 可测验各样本方差是否来自相同方差总体的假设,

这称为方差的同质性测验(test for homogeneity among variances), 可写为 $H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$ (k 为样本数)

对 $H_A: \sigma_1^2, \sigma_2^2, \dots, \sigma_k^2$ 不全相等。这一测验方法由Bartlett氏(1937)提出, 故又称为Bartlett测验(Bartlett test), 是一种近似的 χ^2 测验。

18

假如有 k 个独立的方差估计值:

$$s_1^2 = \frac{1}{v_1} \sum (y_1 - \bar{y}_1)^2 \quad s_2^2 = \frac{1}{v_2} \sum (y_2 - \bar{y}_2)^2$$

$$\dots, \quad s_k^2 = \frac{1}{v_k} \sum (y_k - \bar{y}_k)^2$$

各具 $v_1, v_2, \dots, v_k$ 个自由度, 那么合并的方差 s_p^2 为:

$$s_p^2 = \frac{\sum_{i=1}^k v_i s_i^2}{\sum_{i=1}^k v_i}$$

由此, Bartlett χ^2 值为: $\chi^2 = \left[\left(\sum_{i=1}^k v_i \right) \ln s_p^2 - \sum_{i=1}^k v_i \ln s_i^2 \right]$

上式的 $v_i = n_i - 1$, n_i 为样本容量,

19

[例] 假定有3个样本方差 $s_1^2=4.2, s_2^2=6.0, s_3^2=3.1$, 各具有自由度 $v_1=4, v_2=5, v_3=11$, 试测验其是否同质。

假设 $H_0: \sigma_1^2 = \sigma_2^2 = \sigma_3^2$ 对 H_A : 3个方差不全相等(这里的 H_A 不能用不等号表示, 因为如 H_0 被否定, 只能推论3者不相等而并不能确定属于 $\sigma_1^2 = \sigma_2^2 \neq \sigma_3^2, \sigma_1^2 \neq \sigma_2^2 = \sigma_3^2, \sigma_1^2 \neq \sigma_2^2 \neq \sigma_3^2$ 等情况的哪一种)。

然后, 在进行同质性测验的计算:

20

3个方差同质性测验的计算

i	s_i^2	v_i	$v_i s_i^2$	$\ln s_i^2$	$v_i \ln s_i^2$
1	4.2	4	16.8	1.43508	5.74032
2	6.0	5	30.0	1.79176	8.95880
3	3.1	11	34.1	1.13140	12.44540
Σ		20	80.9	4.35824	27.14452

21

由表可得: $s_p^2 = 80.9/20 = 4.045$

$$\sum v_i \ln s_p^2 = 20 \times \ln 4.045 = 20 \times 1.39748 = 27.94960$$

$$\sum v_i \ln s_i^2 = 5.74032 + 8.95880 + 12.44540 = 27.14452$$

$$\chi^2 = \left[\left(\sum_{i=1}^k v_i \right) \ln s_p^2 - \sum_{i=1}^k v_i \ln s_i^2 \right]$$

$$= 27.94960 - 27.14452 = 0.80508$$

查附表5, 当时 $v = k - 1 = 3 - 1 = 2$, $\chi^2 = 0.80508$ 的概率在0.50~0.75之间, 没跌入小概率区域, 因此接受 H_0 假设, 说明本例的3个方差估计值是同质性的。

22

附表5 χ^2 值表 (续)


χ^2	0.05	0.10	0.25	0.50	1.00	2.00	5.00	10.00	20.00	50.00	100.00
1	3.84	2.71	2.00	1.39	1.06	0.84	0.68	0.58	0.50	0.43	0.39
2	5.99	4.61	3.84	2.78	2.00	1.68	1.39	1.22	1.05	0.90	0.82
3	7.88	6.25	5.02	3.84	2.78	2.37	1.92	1.70	1.43	1.22	1.11
4	9.49	7.78	6.38	4.61	3.36	2.71	2.24	2.00	1.70	1.46	1.34
5	11.07	8.92	7.58	5.40	4.05	3.16	2.59	2.34	1.99	1.73	1.60
6	12.59	10.24	8.58	6.36	4.75	3.58	2.95	2.67	2.26	1.97	1.83
7	14.07	11.59	9.59	7.35	5.42	4.00	3.33	3.02	2.55	2.23	2.08
8	15.51	12.84	10.64	8.33	6.18	4.45	3.70	3.39	2.87	2.54	2.37
9	16.92	14.09	11.79	9.35	6.94	4.89	4.08	3.74	3.18	2.81	2.64
10	18.31	15.34	12.94	10.37	7.78	5.32	4.41	4.10	3.49	3.08	2.90
11	19.68	16.59	14.16	11.41	8.54	5.75	4.74	4.41	3.79	3.34	3.15
12	21.03	17.84	15.38	12.43	9.35	6.18	5.07	4.71	4.08	3.59	3.39
13	22.36	19.03	16.60	13.44	10.18	6.60	5.40	5.00	4.37	3.84	3.62
14	23.68	20.27	17.82	14.46	11.01	7.03	5.83	5.31	4.65	4.08	3.85
15	25.00	21.50	19.04	15.48	11.83	7.46	6.26	5.62	4.93	4.32	4.07
16	26.30	22.72	20.27	16.50	12.66	7.89	6.69	5.93	5.21	4.56	4.29
17	27.59	23.94	21.49	17.53	13.48	8.32	7.12	6.24	5.49	4.80	4.51
18	28.87	25.19	22.71	18.55	14.31	8.75	7.55	6.55	5.77	5.04	4.73
19	30.14	26.41	23.93	19.58	15.14	9.18	7.98	6.86	6.05	5.28	4.95
20	31.41	27.64	25.15	20.60	15.97	9.61	8.41	7.17	6.33	5.52	5.17
21	32.67	28.87	26.37	21.63	16.80	10.04	8.84	7.48	6.61	5.76	5.39
22	33.92	30.10	27.59	22.65	17.63	10.47	9.27	7.79	6.89	5.99	5.61
23	35.17	31.33	28.81	23.68	18.46	10.90	9.70	8.10	7.17	6.23	5.83
24	36.42	32.56	30.03	24.70	19.29	11.33	10.13	8.41	7.45	6.47	6.05
25	37.67	33.79	31.25	25.73	20.12	11.76	10.56	8.72	7.73	6.71	6.27
26	38.91	35.02	32.47	26.75	20.95	12.19	10.99	9.03	8.01	6.95	6.49
27	40.15	36.25	33.69	27.78	21.78	12.62	11.42	9.34	8.29	7.19	6.71
28	41.39	37.48	34.91	28.80	22.61	13.05	11.85	9.65	8.57	7.43	6.93
29	42.63	38.71	36.13	29.83	23.44	13.48	12.28	9.96	8.85	7.67	7.15
30	43.87	39.94	37.35	30.85	24.27	13.91	12.71	10.27	9.13	7.91	7.37
31	45.10	41.17	38.57	31.88	25.10	14.34	13.14	10.58	9.41	8.15	7.59
32	46.34	42.40	39.79	32.90	25.93	14.77	13.57	10.89	9.69	8.39	7.81
33	47.57	43.63	41.01	33.93	26.76	15.20	14.00	11.20	9.97	8.63	8.03
34	48.80	44.86	42.23	34.95	27.59	15.63	14.43	11.51	10.25	8.87	8.25
35	50.03	46.09	43.45	35.98	28.42	16.06	14.86	11.82	10.53	9.11	8.47
36	51.26	47.32	44.67	37.00	29.25	16.49	15.29	12.13	10.81	9.35	8.69
37	52.49	48.55	45.89	38.03	30.08	16.92	15.72	12.44	11.09	9.59	8.91
38	53.72	49.78	47.11	39.05	30.91	17.35	16.15	12.75	11.37	9.83	9.13
39	54.95	51.01	48.33	40.08	31.74	17.78	16.58	13.06	11.65	10.07	9.35
40	56.18	52.24	49.55	41.10	32.57	18.21	17.01	13.37	11.93	10.31	9.57
41	57.41	53.47	50.77	42.13	33.40	18.64	17.44	13.68	12.21	10.55	9.79
42	58.64	54.70	51.99	43.15	34.23	19.07	17.87	13.99	12.49	10.79	10.01
43	59.87	55.93	53.21	44.18	35.06	19.50	18.30	14.30	12.77	11.03	10.23
44	61.10	57.16	54.43	45.20	35.89	19.93	18.73	14.61	13.05	11.27	10.45
45	62.33	58.39	55.65	46.23	36.72	20.36	19.16	14.92	13.33	11.51	10.67
46	63.56	59.62	56.87	47.25	37.55	20.79	19.59	15.23	13.61	11.75	10.89
47	64.79	60.85	58.09	48.28	38.38	21.22	20.02	15.54	13.89	11.99	11.11
48	66.02	62.08	59.31	49.30	39.21	21.65	20.45	15.85	14.17	12.23	11.33
49	67.25	63.31	60.53	50.33	40.04	22.08	20.88	16.16	14.45	12.47	11.55
50	68.48	64.54	61.75	51.35	40.87	22.51	21.31	16.47	14.73	12.71	11.77

23

5.3 适合性测验 (test of goodness of fit)

5.3.1 适合性 χ^2 测验的方法 (methods of test for goodness of fit)

[例]: 玉米花粉粒中形成淀粉粒或糊精是一对相对性状。淀粉粒遇碘呈蓝色反应, 因而可以用碘试法直接观察花粉粒的分离现象。某项实验观察淀粉质与非淀粉质玉米杂交的 F_1 代花粉粒, 经碘处理后有3437粒呈蓝色反应, 3482粒呈非蓝色反应。根据遗传学理论可假设玉米花粉粒碘反应为1:1, 由此可以计得 $3437+3482=6916$ 粒花粉中, 蓝色反应与非蓝色反应的理论次数应各为3459.5粒。设以 O 代表观察次数, E 代表理论次数, 可将上列结果列成下页的表。



24

玉米花粉粒碘反应观察次数与理论次数

碘反应	观察次数(O)	理论次数(E)	O-E	(O-E) ² /E
蓝色	3437(O ₁)	3459.5(E ₁)	-22.5	0.1463
非蓝色	3482(O ₂)	3459.5(E ₂)	+22.5	0.1463
总数	6919	6919	0	0.2926

25



此处要推论是否符合1:1分离, 只要看观察次数与理论次数是否一致, 故可用 χ^2 测验, 可分为四个步骤:

(1) 设立无效假设, 即假设观察次数与理论次数的差异由抽样误差所引起, 即 H_0 : 花粉粒碘反应比例为1:1 与 H_A : 花粉粒碘反应比例不成1:1.

(2) 确定显著水平 $\alpha=0.05$.

(3) 在无效假设为正确的假定下, 计算超过观察 χ^2 值的概率, 这可由 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 求得 χ^2 值后, 按自由度查附表6得到。试验观察的 χ^2 值愈大, 观察次数与理论次数之间相差程度也愈大, 两者相符的概率就愈小。

26

(4) 依所得概率值的大小, 接受或否定无效假设在实际应用时, 往往并不需要计算具体的概率值。

若实得 $\chi^2 \geq \chi^2_{\alpha, v}$ 时, 则 H_0 发生的概率小于等于 α , 属小概率事件, H_0 便被否定;

若实得 $\chi^2 < \chi^2_{\alpha, v}$ 时, 则 H_0 被接受。

例如上表资料, $\chi^2 = \sum \frac{(O-E)^2}{E} = 0.1463 + 0.1463 = 0.2926$

查附表5, 当 $v=k-1=2-1=1$ 时 $\chi^2_{0.05, 1}=3.84$, 实得 $\chi^2=0.2926$ 小于 $\chi^2_{0.05, 1}$, 所以接受 H_0 。即认为观察次数和理论次数相符, 接受该玉米F₁代花粉粒碘反应比率为1:1的假设。

27

附表5 χ^2 临界值表 (右尾)

28

5.3.2 各种遗传分离比例的适合性测验(test of goodness of fit of various genetic segregation ratios)

[例] 大豆花色一对等位基因的遗传研究, 在F₂获得下表所列分离株数。问这一资料的实际观察比例是否符合于3:1的理论比值。

大豆花色一对等位基因遗传的适合性测验

花色	F ₂ 代实际株数(O)	理论株数(E)	O-E	O-E	(O-E) ² /E
紫色	208	216.75	-8.75	8.25	0.3140
白色	81	72.25	+8.75	8.25	0.9450
总数	289	289	0		1.2590

29

H_0 : 大豆花色F₂分离符合3:1比率; H_A : 不符合3:1比率。

显著水平 $\alpha=0.05$ 。

由于该资料只有k=2组, $v=k-1=1$,

表中计算出 $\chi^2 = 1.2590$

查附表5, $\chi^2_{0.05, 1} = 3.84$ 。现 $\chi^2 = 1.2590 < \chi^2_{0.05, 1} = 3.84$

故应接受 H_0 , 说明大豆花色这对性状是符合3:1比率, 即符合一对等位基因的表型分离比例。

30

【例】 两对等位基因遗传试验，如基因为独立分配，则 F_2 代的四种表现型在理论上应有9:3:3:1的比率。有一水稻遗传试验，以稃尖有色非糯品种与稃尖无色糯性品种杂交，其 F_2 代得表7.5结果。试检查实际结果是否符合9:3:3:1的理论比率。

F_2 代表型的观察次数和根据9:3:3:1算出的理论次数

表现型	稃尖有色 非糯	稃尖有色 糯稻	稃尖无色 非糯	稃尖无色 糯稻	总数
观察次数(O)	491	76	90	86	743
理论次数(E)	417.94	139.31	139.31	46.44	743
O-E	73.06	-63.31	-49.31	39.56	0

首先，按9:3:3:1的理论比率算得各种表现型的理论次数E，

$$\text{如稃尖有色非糯稻 } E=743 \times (9/16)=417.94,$$

$$\text{稃尖有色糯稻 } E=743 \times (3/16)=139.31, \dots$$

H_0 : 稃尖和糯性性状在 F_2 的分离符合9:3:3:1;

H_A : 不符合9:3:3:1.

显著水平: $\alpha=0.05$.

然后计算 χ^2 值

$$\chi^2 = \frac{73.06^2}{417.94} + \frac{(-63.31)^2}{139.31} + \frac{(-49.31)^2}{139.31} + \frac{39.56^2}{46.44} = 92.696$$

因本例共有 $k=4$ 组，故 $\nu=k-1=3$ 。查附表5，

$\chi_{0.05,3}^2 = 7.815$ 。现求得 $\chi^2 = 92.696 > \chi_{0.05,3}^2$ ，所以否定 H_0 ，接受 H_A ，即该水稻稃尖和糯性性状在 F_2 的实际结果不符合9:3:3:1的理论比率。

这一情况表明，该两对等位基因并非独立遗传，而可能为连锁遗传。

5.3.3 次数分布的适合性测验(test of goodness of fit of frequency distribution)

适合性测验还经常用来测验试验数据的次数分布是否符合某种理论分布(如二项分布、正态分布等)相符，以推断实际的次数分布究竟属于哪一种分布类型。

【例】 在大豆品种Richland田间考察单株粒重的变异是否符合正态分布。考查数据归成次数分布表列于下页表，组距为5g，该分布的次数 n 、平均数 $\bar{y}$ 、标准差 s 均列于表基部。

大豆单株粒重观察分布与理论正态分布的适合性测验
(摘自Steel and Torrie, 1980)(单位: g)

单株产量	次数(O)	(y- $\bar{y}$)	(y- $\bar{y}$) ²	P	理论次数(E)	χ^2
组限(y) 组中点						
0.5-5.5 3	7	-26.43	-2.065	0.0195	4.5	1.39
5.5-10.5 8	5	-21.43	-1.674	0.0277	6.3	0.27
10.5-15.5 13	7	-16.43	-1.284	0.0525	12.0	2.08
15.5-20.5 18	18	-11.43	-0.893	0.0863	19.8	0.16
20.5-25.5 23	32	-6.43	-0.502	0.1219	27.9	0.60
25.5-30.5 28	41	-1.43	-0.112	0.1477	33.8	1.53
30.5-35.5 33	37	3.57	0.279	0.1545	35.4	0.07
35.5-40.5 38	25	8.57	0.670	0.1386	31.7	1.42
40.5-45.5 43	22	13.57	1.060	0.1068	24.5	0.26
45.5-50.5 48	19	18.57	1.451	0.0712	16.3	0.45
50.5-55.5 53	6	23.57	1.841	0.0405	9.3	1.17
55.5-60.5 58	6	28.57	2.232	0.0201	4.6	0.43
60.5-65.5 63	3	33.57	2.623	0.0084	1.9	0.64
65.5-70.5 68	1	38.57	3.013	0.0044	1.0	0.00
n=229 $\bar{y}=31.93$ s=12.80 $\nu=14-3=11$ $\chi^2=10.47$						

测验的假设为 H_0 : 观察分布符合理论分布, H_A : 观察分布不符合理论分布。

按理论分布计算出各组的理论次数(E)，此例中正态分布下的理论次数可先计算出各组限的正态离差及其理论频率(P)，乘以总观察次数(n)便得到各组的理论次数。

例如第1组

$$P(y < 5.5) = P(u \leq \frac{y - \bar{y}}{s} = \frac{5.5 - 31.93}{12.80}) = P(u < -2.065) = 0.0195$$

$$\text{第2组 } P(5.5 \leq y < 10.5) = P(-2.065 \leq u < -1.674) = 0.0471 - 0.0195 = 0.0276$$

相应的理论次数E，第一组为 $0.0195 \times 229 = 4.5$;

第二组为 $0.0276 \times 229 = 6.3$

其他各组按同法计算后均列入表。

$$\chi^2 = \sum_i \frac{(O-E)^2}{E} = 1.39 + 0.27 + \dots + 0.64 + 0.00 = 10.47$$

自由度 $\nu = 14 - 1 - 2 = 11$ ，因扣去组数的自由度1个，估计2个参数 μ 和 σ 的自由度2个。

查附表5， ν 为11时 $\chi^2_{10.47}$ 的概率 P 在0.25~0.50范围内，观察分布与理论分布无显著差异，因而接受 H_0 ，说明大豆单株粒重的分布符合正态分布。

χ^2 用于进行次数分布的适合性测验时有一定的近似性，为使这类测验更确切，一般应注意以下几点：

- (1) 总观察次数 n 应较大，一般不少于50。
- (2) 分组数最好在5组以上。
- (3) 每组理论次数不宜太少，至少为5，尤其首尾各组。若组理论次数少于5，最好将相邻组的次数合并为一组。

5.4 独立性测验(test of independence)

应用 χ^2 进行独立性测验的无效假设是：

H_0 : 两个变量相互独立，对 H_A : 两个变数彼此相关。

计算过程：

- (1) 将所得次数资料按两个变量作双向分组，排列成相依表；
- (2) 根据两个变量相互独立的假设，算出每一组格的理论次数；
- (3) 由 $\chi^2 = \sum_i \frac{(O-E)^2}{E}$ 算得 χ^2 值。

这个 χ^2 的自由度随两个变数各自的分组数而不同，设横行分 r 组，纵行分 c 组，则 $\nu = (r-1)(c-1)$ 。

当观察的 $\chi^2 < \chi^2_{\alpha, \nu}$ 时，便接受 H_0 ，即两个变数相互独立；当观察的 $\chi^2 \geq \chi^2_{\alpha, \nu}$ 时，便否定 H_0 ，接受 H_A ，即两个变数相关。

独立性测验方法的各种类型：

- (1) 2×2 表的独立性测验
- (2) $2 \times C$ 表的独立性测验
- (3) $r \times c$ 表的独立性测验

5.4.1 2×2 表的独立性测验(test of independence of 2×2 tables)

> 2×2 表的独立性测验

2×2 相依表是指横行和纵行皆分为两组的资料。在作独立性测验时，其 $\nu = (2-1)(2-1) = 1$ 。

【例】调查经过种子灭菌处理与未经种子灭菌处理的小麦发生散黑穗病的穗数，得相依表，试分析种子灭菌与否和散黑穗病穗数多少是否有关。

防治小麦散黑穗病的观察结果

处理项目	发病穗数	未发病穗数	总数
种子灭菌	26(34.7)	50(41.3)	76
种子未灭菌	184(175.3)	200(208.7)	384
总数	210	250	460

假设 H_0 : 两变量相互独立，即种子灭菌与否和散黑穗病穗数多少无关； H_A : 两变数彼此相关。

显著水平 $\alpha = 0.05$ 。

根据两变量相互独立的假定，算得各组格的理论次数。

如种子灭菌项的发病穗数 $O_1 = 26$ ，其理论次数

$E_1 = (210 \times 76) / 460 = 34.7$ ，即该组格的横行总和乘以纵行总和再除以观察总次数(下同)；同样可算得

$O_2 = 50$ 的 $E_2 = (250 \times 76) / 460 = 41.3$ ；

$O_3 = 184$ 的 $E_3 = (210 \times 384) / 460 = 175.3$ ；

$O_4 = 200$ 的 $E_4 = (250 \times 384) / 460 = 208.7$ 。

以上各个 E 值填于表中的括号内。

以上各个E值代入

$$\chi^2 = \sum_i \frac{(O-E)^2}{E}$$

$$\chi^2 = \frac{(26-34.7)^2}{34.7} + \frac{(50-41.3)^2}{41.3} + \frac{(184-175.3)^2}{175.3} + \frac{(200-208.7)^2}{208.7} = 4.808$$

这里 $\nu = (2-1)(2-1) = 1$ ，查附表5， $\chi_{0.05,1}^2 = 3.84$ ，现实得 $\chi^2 = 4.808 > \chi_{0.05,1}^2$ ，故 $P < 0.05$ ，应否定 H_0 。即种子灭菌与否和散黑穗病发病高低有相关，种子灭菌对防治小麦散黑穗病有一定效果。

43

2×C表的独立性测验

2×C表是指横行分为两组，纵行分为C≥3组的相依表资料。在作独立性测验时，其 $\nu = (2-1)(c-1) = c-1$ 。

44

适用于两个样本不同基因型

5.4.2 2×C表的独立性测验 (test of independence of 2×C tables)

2×C表是指横行分为两组，纵行分为C≥3组的相依表资料。在作独立性测验时，其 $\nu = (2-1)(c-1) = c-1$ 。

【例】进行大豆等位酶Aph的电泳分析，193份野生大豆、223份栽培大豆等位基因型的次数列于表7.9，试分析大豆Aph等位酶的等位基因型频率是否因物种而不同。

野生大豆和栽培大豆Aph等位酶的等位基因型次数分布

物种	等位基因型			总计
	1	2	3	
野生大豆 G.soja	24(23.66)	68(123.87)	96(45.47)	193
栽培大豆 G.max	22(27.34)	199(143.13)	2(52.53)	223
总计	51	267	98	416

45

H_0 : 等位基因型频率与物种无关; H_A : 两者有关, 不同物种等位基因型频率不同。

显著水平 $\alpha = 0.05$ 。

根据 H_0 算得各观察次数的相应理论次数:

如观察次数29的 $E = (193 \times 51) / 416 = 23.66$,

观察次数22的 $E = (223 \times 51) / 416 = 27.34$, ...;

将其填入表的括号内。

再代入 $\chi^2 = \sum_i \frac{(O-E)^2}{E}$ 可得:

$$\chi^2 = \frac{(29-23.66)^2}{23.66} + \frac{(68-123.87)^2}{123.87} + \dots + \frac{(2-52.53)^2}{52.53} = 154.02$$

46

此处 $\nu = (2-1)(3-1) = 2$ 。查附表5， $\chi_{0.05,2}^2 = 5.99$ ，现实 $\chi^2 = 154.02 > \chi_{0.05,2}^2$ ， $P < 0.05$ ，应否定 H_0 ，接受 H_A ，即不同物种Aph等位基因型频率有显著相关，或者说不同物种的Aph等位基因型频率有显著差别。

47

5.4.2 r×c表的独立性测验 (test of independence of r×c tables)

若横行分r组，纵行分c组，且 $r \geq 3$ ， $c \geq 3$ ，则为r×c相依表。对r×c表作独立性测验时，其 $\nu = (r-1)(c-1)$ 。

【例】下表为不同灌溉方式下水稻叶片衰老情况的调查资料，试测验稻叶衰老情况是否与灌溉方式有关。

水稻在不同灌溉方式下叶片的衰老情况

灌溉方式	绿叶数	黄叶数	枯叶数	总计
深水	146 (140.69)	7 (8.78)	7 (10.53)	160
浅水	183 (180.26)	8 (11.24)	13 (13.49)	205
湿润	152 (160.04)	14 (9.98)	16 (11.98)	182
总计	481	30	36	547

48

H_0 : 稻叶衰老情况与灌溉方式无关; H_A : 稻叶衰老情况与灌溉方式有关。

取 $\alpha = 0.05$ 。

根据 H_0 的假定, 计算各组格观察次数的相应理论次数:
如与146相应的 $E = (481 \times 160) / 547 = 140.69$,

与183相应的 $E = (481 \times 205) / 547 = 180.26$,

所得结果填于表括号内。

根据 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 可得

$$\chi^2 = \frac{(146-140.69)^2}{140.69} + \frac{(7-8.78)^2}{8.78} + \dots + \frac{(16-11.98)^2}{11.98} = 5.62$$

49

本例 $\nu = (3-1)(3-1) = 4$, 查附表5, $\chi_{0.05,4}^2 = 9.49$,
现 $\chi^2 = 5.62 < \chi_{0.05,4}^2$, $P > 0.05$, 故应接受 H_0 , 即不同灌溉方式对水稻叶片的衰老情况没有显著影响。

50

5.5 χ^2 的可加性和联合分析 (additivity and joint analysis of χ^2)

[例] 下表给出三个大豆组合 F_3 家系世代对豆秆黑潜蝇抗性家系与感性家系的分离数据, 每一家系由1个 F_2 单株衍生, 抗性家系中包括有全抗家系及抗感分离的家系。经对三个组合分别的 χ^2 测验, 均符合3抗:1感理论分离比例。现要求进一步检测三组合综合起来是否符合3:1分离比例, 三组合间是否一致符合3:1分离比例, 或三组合是否具有同质性。

51

三个大豆组合 F_3 家系世代对豆秆黑潜蝇抗性的分离数据(理论分离比为3抗:1感)

组合		母本 P_1	父本 P_2	F_2		χ^2	P
				O	E		
I	江宁刺文豆	抗	20	0	73	75	0.50~0.75
	×	感	0	20	27	25	
	祁江秋稻黄乙	合计	20	20	100	100	
II	无锡长紫光甲	抗	20	0	62	68.25	0.10~0.25
	×	感	0	20	29	22.75	
	祁县天鹅蛋	合计	20	20	91	91	
III	祁县天鹅蛋	抗	0	20	90	95.25	0.25~0.50
	×	感	20	0	37	31.75	
	南农1138-2	合计	20	20	127	127	
三组合综合	抗			225	238.5	3.06	0.05~0.10
	感			93	79.5		
	合计			318	318		
三组合总计						3.66	

52

H_0 : 三组合综合起来符合3抗:1感分离比例, H_A : 综合群体不符合3:1分离比例; 及 H_0 : 三组合的分离比表现同质, 一致为3:1, H_A : 三组合分离比例不同质。

要测验上列假设, 必须计算出相应的 χ^2 值。

(1) 各组合的 χ^2 已用于测验各组合与理论分离比例3:1的相符性, 具1个自由度。

(2) 三个组合综合为一群体时的 χ^2 值, 或称为 $\chi^2_r = 3.06$, 亦具1个自由度。这一值可用于测验第一个无效假设, 根据其概率为0.05~0.10, 可推论三合一的群体总的分离比例亦符合3:1。

53

(3) 三组合各 χ^2 的总和 $\sum \chi^2_i = 3.66$, 具有3个自由度。若将这3个自由度分解, 1个归属于三组合间的共性, 2个归属于三组合间的个性, 它们相应的 χ^2 值为 $\chi^2_r = 3.06$ 和 $\sum \chi^2_i - \chi^2_r = 3.66 - 3.06 = 0.60$ 。 χ^2_r 已在(2)中进行过测验, 剩下 $\sum \chi^2_i - \chi^2_r$ 具2个自由度可用以测验第二个无效假设, 三个组合的同质性。此处 $\sum \chi^2_i - \chi^2_r = 0.60$, $\nu = 2$ 时 $P = 0.50 \sim 0.75$ 。说明符合同质性假设的概率甚大, 接受此假设, 因而三个组合表现一致的3:1分离比例是确实的。

54

根据表中的数据,三组合的亲本表现确实的抗、感差异, F_2 衍生的 F_3 家系表现出抗性为显性并一致符合3抗(抗+感):1感的家系间分离比例,因而可推论大豆对豆秆黑潜蝇的抗性是由1对显性基因控制的,组合间表现出一致的结果。

本例中因试验结果很一致,因而引出了共同的结论。若各个 χ^2 的结果出入较大, χ^2 与个别组合的结果不一致,表现出显著性,那么将着重分析各组组合间的非同质性及各组合的特异性。

55

6. 参数估计方法(estimation methods of parameters)

6.1 农业科学中的主要参数及其估计量的评选标准(principal parameters of agricultural science and the assessment criteria of their estimators)

6.2 矩法(method of moment)

6.3 最小二乘法(method of lest squares)

6.4 极大似然法(method of maximum likelihood)

56

6.1 农业科学中的主要参数及其估计量的评选标准(principal parameters of agricultural science and the assessment criteria of their estimators)

6.1.1 农业科学中的主要参数(principal parameters of agricultural science)

农业科学研究中需要估计的参数是多种多样的,主要包括:

- (1) 总体数量特征值参数,例如,用平均数来估计品种的产量,用平均数差数来估计施肥等处理的效应;
- (2) 在揭示变量间的相互关系方面,用相关系数来描述2个变数间的线性关系;用回归系数(regression coefficient)、偏回归系数(partial regression coefficient)等来描述原因变数变化所引起的结果变数的平均变化的数量,用通径系数(path coefficient)来描述成分性状对目标性状的贡献程度等。

57

6.1.2 参数估计量的评选标准(assessment criteria of parameter estimators)

(1) 数学期望(expectation)

数学期望(expectation)是试验中每次可能结果的概率乘以其结果的总和,它反映随机变量平均取值的大小。样本平均数的平均数就是一种数学期望。

例如,一个大豆品种的含油量为20%,测定一次可能是大于20%,再测定可能小于20%,大量反复测定后平均结果为20%,这时20%便可看作为该大豆品种含油量的数学期望。

随机变量的数字特征(numerical characteristics)是指随机变量的数学期望值(mathematical expectation value)。

58

- ▶ 对于离散型(间断性)随机变量 y 的分布列为: $P\{y=y_i\}=p_i$, 其中, $i=1, 2, \dots$, 那么随机变量 y 的数学期望 $E(y)$ 为:

$$E(y) = \sum_{i=1}^{\infty} y_i p_i$$

这样可以求得总体平均值。

- ▶ 对于连续型随机变量 y 的数学期望 $E(y)$ 为:

$$E(y) = \int_{-\infty}^{+\infty} y f(y) dy$$

其中 $f(y)$ 为随机变量 y 的概率密度函数,这样可以求得总体均值。

59

用 $D(y)$ 表示方差(variance), 有

$$D(y) = E[y - E(y)]^2$$

这就是随机变量函数的数学期望。

- ▶ 离散型随机变量方差的数学期望为:

$$D(y) = \sum_{i=1}^{\infty} [y_i - E(y)]^2 p_i$$

- ▶ 连续型随机变量方差的数学期望为:

$$D(y) = \int_{-\infty}^{+\infty} [y - E(y)]^2 f(y) dy$$

60

数学期望有这样一些常用的性质:

- (1) 常数(constant)的数学期望为常数本身;
- (2) 随机变量与常数的乘积的数学期望是常数与随机变量的数学期望的乘积;
- (3) 多个随机变量分别与常数的乘积的求和函数的数学期望是常数与多个随机变量的数学期望的乘积的和;
- (4) 多个相互独立的随机变量的乘积的数学期望是多个随机变量的数学期望的乘积。

- (1) $E(c) = c$, 其中 c 为常数;
- (2) $E(cX) = cE(X)$;
- (3) $E(X + Y) = E(X) + E(Y)$;
- (4) $E(X - Y) = E(X) - E(Y)$;
- (5) 设 X, Y 是相互独立的随机变量, 则有 $E(XY) = E(X)E(Y)$ 。

51

(2) 参数估计量的评选标准

评价估计量优劣的标准主要有无偏性、有效性、相合性等

(1) 无偏性(unbiasedness) 参数估计量的期望值与参数真值是相等的, 这种性质称为无偏性, 具有无偏性的估计量称为无偏估计量(unbiased estimator)。例如, 在抽样分布中已经介绍了高均差平方和除以自由度得到的均方的平均数等于总体方差, 即该均方的数学期望等于相应总体参数方差, 这就是说该均方估计量是无偏的。

估计量的数学期望值在样本容量趋近于无穷大时与参数的真值相等的性质称为渐近无偏性(asymptotic unbiasedness), 具有渐近无偏性的估计量称为渐近无偏估计量(asymptotic unbiased estimator)。

52

(2) 有效性 (efficiency) 无偏性表示估计值是在真值周围波动的一个数值, 即无偏性表示估计值与真值间平均差异为0, 近似可以用估计值作为真值的一个代表。

同一个参数可以有許多无偏估计量, 但不同估计量的期望方差(expected variance)不同, 也就是估计量在真值周围的波动大小不同。估计量的期望方差越大说明用其估计值代表相应真值的有效性越差; 否则越好, 越有效。不同的估计量具有不同的方差, 方差最小说明最有效。

如果一个无偏估计量相对与其它所有可能无偏估计量, 其期望方差最小, 那么称这种估计量为一致最小方差无偏估计量(minimum variance unbiased estimator)。

53

(3) 相合性(consistence) 用估计量估计参数涉及一个样本容量大小问题, 如果样本容量越大估计值越接近真值, 那么这种估计量是相合估计量。

除以上三方面标准外, 还有充分性与完备性也是常考虑的。

充分性(sufficiency)指估计量充分利用样本中每一变量的信息;

完备性(completeness)指该估计量是充分的、唯一的无偏估计量。

54

6.2 矩法(method of moment)

6.2.1 矩的概念(concept of moment)

矩(moment)分为原点矩(origin moment)和中心矩(central moment)两种。

对于样本 $y_1, y_2, \dots, y_n$, 各观测值的 k 次方的平均值, 称为样本的 k 阶原点矩, 记为 $\bar{y}^k$, 有 $\bar{y}^k = \frac{1}{n} \sum_{i=1}^n y_i^k$; 用观测值减去平均数得到的离均差的 k 次方的平均值称为样本的 k 阶中心矩, 记为 $(y - \bar{y})^k$ 或 $\hat{\mu}_k$, 有

$$\overline{(y - \bar{y})^k} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^k$$

对于总体 $y_1, y_2, \dots, y_N$, 各观测值的 k 次方的平均值, 称为总体的 k 阶原点矩, 记为 $E(y^k)$, 有 $E(y^k) = \frac{1}{N} \sum_{i=1}^N y_i^k$; 用观测值减去平均数得到的离均差的 k 次方的平均值称为总体的 k 阶中心矩, 记为 $E[(y - \mu)^k]$ 或 μ_k , 有

$$E[(y - \mu)^k] = \frac{1}{N} \sum_{i=1}^N (y_i - \mu)^k$$

55

6.2.2 矩法及矩估计量(method of moment and moment estimator)

所谓矩法就是利用样本各阶原点矩来估计总体相应各阶原点矩的方法。

即

$$\bar{y}^k = \frac{1}{n} \sum_{i=1}^n y_i^k \rightarrow E(y^k)$$

也可以用样本各阶原点矩的函数来估计总体各阶原点矩同一函数。

即若 $Q = f(E(y), E(y^2), \dots, E(y^k))$, 则

$$\hat{Q} = f(\bar{y}, \bar{y}^2, \dots, \bar{y}^k)$$

由此得到的估计量称为矩估计量(moment estimator)。

56

[例] 现获得正态分布 $N(\mu, \sigma^2)$ 的随机样本 $y_1, y_2, \dots, y_n$, 要求正态分布 $N(\mu, \sigma^2)$ 参数 μ 和 σ^2 的矩估计量。

首先, 求正态分布总体的1阶原点矩和2阶中心矩:

$$E(y) = \int_{-\infty}^{+\infty} y f(y) dy = \int_{-\infty}^{+\infty} y \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(y-\mu)^2}{2\sigma^2}\right] dy = \mu$$

$$\begin{aligned} E[(y-\mu)^2] &= \int_{-\infty}^{+\infty} (y-\mu)^2 f(y) dy \\ &= \int_{-\infty}^{+\infty} (y-\mu)^2 \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(y-\mu)^2}{2\sigma^2}\right] dy \\ &= \sigma^2 \end{aligned}$$

67

然后求样本的1阶原点矩和2阶中心矩, 为

$$\hat{\mu} = \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \hat{\mu}_2 = s^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

最后, 利用矩法, 获得总体平均数和方差的矩估计

$$\hat{\mu} = \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \hat{\sigma}^2 = s^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

故总体平均数和方差的矩估计值分别为样本平均数和样本方差, 方差的分母为 n 。

68

单峰分布曲线还有二个特征数, 即偏度(skewness)与峰度(kurtosis), 可分别用偏度系数和峰度系数作测度。

偏度系数(coefficient of skewness)是指3阶中心矩与标准差的3次方之比;

峰度系数(coefficient of kurtosis)是指4阶中心矩与标准差的4次方之比。

由样本计算的偏度系数 $cs = \hat{\mu}_3 / \hat{\sigma}^3 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^3 / \left[\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^{3/2}$

峰度系数 $ck = \hat{\mu}_4 / \hat{\sigma}^4 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^4 / \left[\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^2$

当偏度为正值时, 分布向大于平均数方向偏斜; 偏度为负值时则向小于平均数方向偏斜; 当偏度的绝对值大于2时, 分布的偏斜程度严重。

当峰度大于3时, 分布比较陡峭, 峰态明显, 即总体变数的分布比较集中。

69

[例] 计算140行水稻产量数据资料所属分布曲线的偏度和峰度。

140行水稻产量(单位: 克)

177	215	197	97	123	159	245	119	119	131	149	152	167	104
161	214	125	175	219	118	192	176	175	95	136	199	116	165
214	95	158	83	137	80	138	151	187	126	196	134	206	137
98	97	129	143	179	174	159	165	136	108	101	141	148	168
163	176	102	194	145	173	75	130	149	150	161	155	111	158
131	189	91	142	140	154	152	163	123	205	149	155	131	209
183	97	119	181	149	187	131	215	111	186	118	150	155	197
116	254	239	160	172	179	151	198	124	179	135	184	168	169
173	181	188	211	197	175	122	151	171	166	175	143	190	213
192	231	163	159	158	159	177	147	194	227	141	169	124	159

70

首先, 计算样本的2、3、4阶中心矩 $\hat{\mu}_2, \hat{\mu}_3, \hat{\mu}_4$, 以及标准差估计值:

$$\hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = 1303.735$$

$$\hat{\mu}_3 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^3 = 3953.891$$

$$\hat{\mu}_4 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^4 = 4.67729 \times 10^6$$

$$\hat{\sigma} = \sqrt{\hat{\mu}_2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2} = 36.107$$

然后, 根据矩法原理, 该分布的偏度与峰度估计值分别为:

$$cs = \hat{\mu}_3 / \hat{\sigma}^3 = 0.0849$$

$$ck = \hat{\mu}_4 / \hat{\sigma}^4 = 2.752$$

因此, 说明资料比较集中在平均数左右, 分布曲线并不是特别陡峭。

71

6.3 最小二乘法(method of least squares)

从总体中抽出的样本观察值与总体平均数是有差异的, 这种差异属于抽样误差(sampling error)。因而, 在总体平均数估计时要尽可能地降低这种误差, 使总体平均数估计值尽可能好。

参数估计的最小二乘法就是基于这种考虑提出的。

基本思想是使误差平方和最小, 达到在误差之间建立一种平衡, 以防止某一极端误差对决定参数的估计值起支配地位。这有助于揭示更接近真实的状况。

具体方法是使误差平方和 Q 为最小, 可通过求 Q 对估计参数的偏导数(partial derivative), 并令其等于0, 以求得参数估计量。

72

最小二乘法: 残差平方和最小。

不基于分布。
基于风险函数最小

[例] 用最小二乘法求总体平均数 μ 的估计量。

若从平均数为 μ 的总体中抽得样本为 $y_1, y_2, y_3, \dots, y_n$, 则观察值可划分为总体平均数与误差 e_i 之和,

$$y_i = \mu + e_i$$

总体平均数的最小二乘估计量就是使 y_i 与 μ 间的误差平方和为最小, 即

$$Q = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\mu})^2 \quad \text{为最小.}$$

为获得其最小值, 求 Q 对 μ 的导数, 并令导数等于 0, 可得:

$$\frac{\partial Q}{\partial \mu} = -2 \sum_{i=1}^n (y_i - \hat{\mu}) = 0$$

即总体平均数的估计量为:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n y_i$$

因此, 算术平均数为总体平均数的最小二乘估计。这与矩法估计是一致的。⁷³

估计离均差平方和 $Q' = \sum (y_i - \bar{y})^2$ 的数学期望:

$$\begin{aligned} E(Q') &= E[\sum (y_i - \bar{y})^2] = E[\sum (y_i - \mu - \bar{y} + \mu)^2] \\ &= E[\sum (y_i - \mu)^2 - 2 \sum (y_i - \mu)(\bar{y} - \mu) + \sum (\bar{y} - \mu)^2] \\ &= E[\sum (y_i - \mu)^2 - \sum (\bar{y} - \mu)^2] = n\sigma^2 - n\sigma^2/n \\ &= (n-1)\sigma^2 \end{aligned}$$

因而, σ^2 估计为:

$$\hat{\sigma}^2 = Q'/(n-1) = \sum (y_i - \bar{y})^2 / (n-1)$$

与常规以自由度为除数法一致。


74

[例] 求下表的两问分组资料缺1个小区的最小二乘估计量和估计值。

生长素处理豌豆的试验结果

处理 (A)	组 (B)				总和 T_i	平均 $\bar{y}_i$
	I	II	III	IV		
对照(CK)	60	62	61	60	243	60.8
赤霉素	65	65	68	y_e	$198+y_e$	
动力精	63	61	61	60	245	61.3
吲哚乙酸	64	67	63	61	255	63.8
硫酸腺嘌呤	62	65	62	64	253	63.3
马来酸	61	62	62	65	250	62.5
总和 T_j	375	382	377	$310+y_e$	$T=1444+y_e$	

75



76

最大似然法

6.4 极大似然法(method of maximum likelihood)

所谓极大似然法(maximum likelihood method)是指选择使事件发生概率最大的可能情况的参数估计方法。通俗理解, 就是利用已知的样本结果信息, 反推最有可能(最大概率)导致这些样本结果出现的模型参数值!

极大似然法包括二个步骤:

- (1) 建立包括有该参数估计量的似然函数(likelihood function)
- (2) 根据实验数据求出似然函数达极值时的参数估计量或估计值。

77

6.4.1 似然函数(likelihood function)

对于离散型随机变量, 似然函数是多个独立事件的概率函数的乘积。该乘积是概率函数值, 它是关于总体参数的函数。

例如, 一只大口袋里红、白、黑3种球, 采用复置抽样50次, 得到红、白、黑3种球的个数分别为12, 24, 14, 那么根据多项式的理论, 可以建立似然函数为:

$$\frac{50!}{12!24!14!} (p_1)^{12} (p_2)^{24} (p_3)^{14}$$

其中 p_1, p_2, p_3 分别为口袋中红、白、黑3种球的概率($p_3 = 1 - p_1 - p_2$), 它们是需要估计的。

78

对于连续型随机变量，似然函数是每个独立随机观测值的概率密度函数的乘积，则似然函数为：

$$L(\theta) = L(y_1, y_2, \dots, y_n; \theta) = f(y_1; \theta) f(y_2; \theta) \dots f(y_n; \theta)$$

若 y_i 服从正态分布 $N(\mu, \sigma^2)$ ，则 $\theta = (\mu, \sigma)$ ，上式可变为：

$$L(\mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_1-\mu)^2}{2\sigma^2}} \dots \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_n-\mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{1}{2\sigma^2}[(y_1-\mu)^2 + \dots + (y_n-\mu)^2]}$$

79

6.4.2 极大似然估计(maximum likelihood estimation)

极大似然估计(maximum likelihood estimation)就是指使似然函数为最大以获得总体参数估计的方法。其中，所获得的估计总体参数的表达式称为极大似然估计量，由该估计量获得的总体参数的估计值称为总体参数的极大似然估计值。

为了计算上的方便，一般将似然函数取对数，称为对数似然函数。因为取对数后似然函数由乘积变为加式，其表达式为：

$$\ln L(\theta) = \ln L(y_1, y_2, \dots, y_n; \theta) = \sum_{i=1}^n \ln f(y_i, \theta)$$

求极大似然估计量可以通过令对数似然函数对总体参数的偏导数等于0来获得，即当 $\theta = (\theta_1, \theta_2, \dots, \theta_l)$ ，有

$$\frac{\partial}{\partial \theta_k} \ln L(y_1, y_2, \dots, y_n; \theta_1, \theta_2, \dots, \theta_l)$$

80

求极大似然估计量可以通过令对数似然函数对总体参数的偏导数等于0来获得，即当 $\theta = (\theta_1, \theta_2, \dots, \theta_l)$ ，有

$$\frac{\partial}{\partial \theta_k} \ln L(y_1, y_2, \dots, y_n; \theta_1, \theta_2, \dots, \theta_l) = \sum_{i=1}^n \frac{\partial}{\partial \theta_k} f(y_i; \theta_1, \theta_2, \dots, \theta_l) = 0 \quad (k=1, 2, \dots, l)$$

由此获得总体参数的极大似然估计量。

81

[例] 设 $y_1, y_2, \dots, y_n$ 是正态总体 $N(\mu, \sigma^2)$ 的随机样本，求正态分布 $N(\mu, \sigma^2)$ 参数的极大似然估计量。

似然函数为：

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(y_i-\mu)^2}{2\sigma^2}\right] \quad \left(f_n(y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2}\right)$$

$$= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\right]$$

两边同时取对数，得：

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2$$

82

求偏导数后获得似然方程组为：

$$\begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \mu) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (y_i - \mu)^2 = 0 \end{cases}$$

解得：

$$\begin{cases} \mu = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y} \\ \sigma^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \mu)^2 \end{cases}$$

83

因此，正态分布总体平均数的极大似然估计量为：

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}$$

当总体平均值为未知时，方差估计量为：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

当总体平均值为已知时，方差估计量为：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \mu)^2$$

84

[例] 一只大口袋里有红、白、黑3种球，采用复置抽样50次，得到红、白、黑3种球的个数分别为12, 24, 14，求红、白、黑球事例中 p_1, p_2, p_3 的极大似然估计值。（按多项式的理论）

由 $\frac{50!}{12! 24! 14!} (p_1)^{12} (p_2)^{24} (p_3)^{14}$ 可获得对数似然函数：

$$\ln L(p_1, p_2, p_3) = C + 12 \ln p_1 + 24 \ln p_2 + 14 \ln p_3 \\ = C + 12 \ln p_1 + 24 \ln p_2 + 14 \ln(1 - p_1 - p_2)$$

其中， C 为常数。

分别求 $\ln L(p_1, p_2, 1 - p_1 - p_2)$ 对 p_1, p_2 的偏导数，并令为0，得似然方程组：


$$\begin{cases} \frac{\partial}{\partial p_1} \ln L(p_1, p_2, 1 - p_1 - p_2) = \frac{12}{p_1} + \frac{14}{1 - p_1 - p_2} \cdot (-1) = 0 \\ \frac{\partial}{\partial p_2} \ln L(p_1, p_2, 1 - p_1 - p_2) = \frac{24}{p_2} + \frac{14}{1 - p_1 - p_2} \cdot (-1) = 0 \end{cases}$$

联立求解，得：

$$\hat{p}_1 = 6/25, \hat{p}_2 = 12/25, \hat{p}_3 = 7/25$$

显然，极大似然估计值 $\hat{p}_1, \hat{p}_2, \hat{p}_3$ 等于其观测频率。

[例] 两个亲本的基因型分别为 $AABB$ 和 $aabb$ ，这两个亲本杂交后 F_2 出现了4种基因型，分别为 $A_B_$ 、 A_bb 、 $aaB_$ 和 $aabb$ ，得到四种基因型的个数分别为 c, d, e, f ，已知 AA 和 BB 两对基因间存在连锁关系，现欲估计重组率？



设重组率为 r ，根据遗传学推导，可以得到4种基因型的概率。

F_2 群体基因型的分离情况

基因型	$A_B_$	A_bb	$aaB_$	$aabb$	总数
观察得到基因型个数	$c(289)$	$d(26)$	$e(29)$	$f(76)$	$n(420)$
概率	$\frac{2 + (1-r)^2}{4}$	$\frac{1 - (1-r)^2}{4}$	$\frac{1 - (1-r)^2}{4}$	$\frac{(1-r)^2}{4}$	1

由两对连锁主基因控制的 F_2 群体16种基因型的概率计算如下表。从中可计算出4种表现型的概率。

F_2 群体的基因型及其概率

配子及概率	AB (1-r)/2	Ab $r/2$	aB $r/2$	ab (1-r)/2
AB (1-r)/2	AABB (1-r) ² /4	AABb $r(1-r)/4$	AaBB $r(1-r)/4$	AaBa (1-r) ² /4
Ab $r/2$	AABb $r(1-r)/4$	AAbb $r^2/4$	AaBb $r^2/4$	Aabb $r(1-r)/4$
aB $r/2$	AaBB $r(1-r)/4$	AaBb $r^2/4$	aaBB $r^2/4$	aaBb $r(1-r)/4$
ab (1-r)/2	AaBa (1-r) ² /4	Aabb $r(1-r)/4$	aaBb $r(1-r)/4$	aabb (1-r) ² /4

按多项式分布，可以根据概率函数得到似然函数为：

$$L(r) = \frac{n!}{c!d!e!f!} \left\{ \frac{2 + (1-r)^2}{4} \right\}^c \left\{ \frac{1 - (1-r)^2}{4} \right\}^d \left\{ \frac{1 - (1-r)^2}{4} \right\}^e \left\{ \frac{(1-r)^2}{4} \right\}^f$$

若以 $\theta = (1-r)^2$ 代入上式，则似然函数和对数似然函数分别为：

$$L(r) = \frac{n!}{c!d!e!f!} \left\{ \frac{2 + \theta}{4} \right\}^c \left\{ \frac{1 - \theta}{4} \right\}^d \left\{ \frac{1 - \theta}{4} \right\}^e \left\{ \frac{\theta}{4} \right\}^f$$

$$\ln L(\theta) = k + c \ln \left[\frac{2 + \theta}{4} \right] + (d + e) \ln \left[\frac{1 - \theta}{4} \right] + f \ln \left[\frac{\theta}{4} \right]$$

(k 是常数项)

对上式求导数，并令导数为0，可得方程：

$$\frac{c}{2 + \theta} - \frac{d + e}{1 - \theta} + \frac{f}{\theta} = 0$$

上式化为一元二次方程

$$n\theta^2 - (c - 2d - 2e + f)\theta - 2f = 0$$

$$\hat{\theta} = \frac{(c - 2d - 2e - f) \pm \sqrt{(c - 2d - 2e - f)^2 + 8fn}}{2n}$$

在 $\hat{\theta}$ 的两个解中取一个符合遗传规律的解，那么，

重组率的解为： $\hat{r} = 1 - \sqrt{\hat{\theta}}$ 。

重组率方差估计量为： $D(\hat{r}) = \frac{(1 - \hat{\theta})(2 + \hat{\theta})}{2n(1 + 2\hat{\theta})}$

对于本例, 有

$$\hat{\theta} = \frac{(289 - 2 \times 26 - 2 \times 29 + 76) \pm \sqrt{(289 - 2 \times 26 - 2 \times 29 + 76)^2 + 8 \times 76 \times 420}}{2 \times 420}$$

$$= 0.1226 \pm 0.6140$$

取正根, $\hat{\theta} = 0.7366$,

由此, $\hat{r} = 1 - \sqrt{0.7366} = 0.142$.

$$s(\hat{r}) = \sqrt{D(\hat{r})} = \sqrt{\frac{(1 - 0.7366)(2 + 0.7366)}{2 \times 420 \times (1 + 2 \times 0.7366)}} = 0.019$$

重组率方差估计量

6.4.3 似然比测验(likelihood ratio test)

极大似然估计中, 经常存在两种至多种可能的假设。但哪一种假设更好更切合, 需要用适当的测验方法去做决定。这种在极大似然估计中对多种假设合理性问题的测验, 称作似然比测验(likelihood ratio test)。

(1) 似然比测验的基本步骤

- 设立假设 $H_0: q=q_1$; 备择假设 $H_a: q=q_2$
- 建立似然函数并计算极大似然函数值
- 根据两个极大似然函数建立和计算似然比统计量 (LR)
- 用似然比统计量构建假设测验统计量, 计算出 χ^2 值, 根据 χ^2 分布测验显著性

(2) 似然比测验在连锁遗传重组率估计中的应用

6.4.4 关于三种估计方法的讨论(discussion about the three estimation methods)

➤ 上述3种参数估计方法对比:

- (1) 对于总体平均数的估计量, 3种估计方法都具有无偏性、有效性和相合性;
- (2) 对于总体方差的估计量, 由离均差平方和期望值所得的是无偏的, 但由矩法和极大似然法所得两种估计量是有偏的, 但都是相合的; 最小二乘法无直接的总体方差估计量。

➤ 3种常用方法的不同要求:

- (1) 极大似然法要求已知总体的分布, 才能获得估计量。
- (2) 另外两种方法对分布没有严格的要求。

➤ 3种常用方法的应用范围:

- (1) 极大似然法估计结果大多具有无偏性、有效性和相合性等优良的估计量性质。
- (2) 最小二乘法在估计线性回归模型参数时具有灵活方便的特点。
- (3) 矩估计方法由于不需要知道总体分布也是经常采用的方法, 但该方法估计结果有时不具备优良的估计量性质, 而且局限在与矩有关的估计量。