

运筹学笔记：

一、基本单纯形法

(7 条消息) [【运筹学】单纯形法总结 \(单纯形法原理 | 单纯形法流程 | 单纯形表 | 计算检验数 | 最优解判定 | 入基变量 | 出基变量 | 方程组同解变换 \)](#) ★★ ★ 韩曙亮的博客 - CSDN 博客

1、基本单纯形法的几个问题：(基本单纯形法要求一定能找到单位矩阵作为起始)

用松弛化为标准形式：添加松弛变量将不等号化为等号，保证所有变量都大于等于 0

找初始基可行解（一般方法为构造某一部分单位矩阵）

最优性检验（检验数 σ 的计算： c_i -参数）

基可行解迭代（如何确定入基变量（按检验数最大选取）和出基变量（按 b_i/a_{ik} 即右侧系数除以相应入基变量前的系数最小进行选取））

最优解判别（有无穷解、唯一解还是无解）

若最后检验数全等于 0，有唯一可行解，若有至少一个检验数小于 0，则有无穷可行解，若检验数全小于 0（没有一个等于 0），则有无界解。

2、单纯形表的各个元素的含义

c_j	c_j		3	4	0	0	
C_B 基变量系数 (目标函数)	基变量	常数 b	x_1	x_2	x_3	x_4	θ_i
0 (目标函数 x_3 系数 c_3)	x_3	40	2	1	1	0	40 (θ_3)
0 (目标函数 x_4 系数 c_4)	x_4	30	1	3	0	1	10 (θ_4)
σ_j			3 (σ_1)	4 (σ_2)	0	0	
-	-	-	-	-	-	-	-
0 (目标函数 x_3 系数 c_3)	x_3	30	$\frac{5}{3}$	0	1	$-\frac{1}{3}$	18 (θ_3)
4 (目标函数 x_2 系数 c_2)	x_2	10	$\frac{1}{3}$	1	0	$\frac{1}{3}$	30 (θ_2)
σ_j (检验数)			$\frac{5}{3}$ (σ_1)	0	0	$-\frac{4}{3}$ (σ_4)	

二、人工变量法

(7 条消息) [【运筹学】人工变量法总结 \(人工变量法解的分析 | 标准型变换 | 构造单位阵 | 目标函数引入 M | 计算检验数 | 选择入基变量 | 选择出基变量 | 中心元变换 | \)](#) ★★ ★ 运筹学人工变量法 韩曙亮的博客 - CSDN 博客

（如果无法直接找到单位矩阵，用人工变量法构建单位矩阵）

在无法直接产生与系数矩阵同秩的单位矩阵的时候，人为引入几个人工变量使其构成对角单位矩阵，但是为了防止引入人工变量对线性规划的最大、最小解产生影响，在 max/min 栏处要 $-Mx_i$ ，这里的 M 为正无穷，寓意只要新引入的人工变量不为 0 就会产生很大的影响。

人工变量法的关键在于一定要在不断的迭代过程中将人工变量替换成其他已有的变量，只要人工变量为出基变量，非人工变量为入基变量，人工变量栏也可以消去。人工变量可以看成是一个“由头”，在后续迭代过程中将“头”舍去，如果在迭代过程中无法将人工变量替走，则无可行解。

c_j	c_j		3	2	①入基变量 -1	0	0	-M	-M	
C_B 基变量系数 (目标函数)	X_B 基变量	常数 b	x_1	x_2	x_3	x_4	x_5	x_6	x_7	θ_i
-M (目标函数 x_6 系数 c_6)	x_6	4	-4	3	1	-1	0	1	0	4 (θ_6)
0 (目标函数 x_5 系数 c_5)	x_5	10	1	-1	2	0	1	0	0	5 (θ_5)
-M (目标函数 x_7 系数 c_7)	x_7	1	2	-2	1	0	0	0	1	1 (θ_7)
σ_j (检验数)			$3 - 2M$ (σ_1)	$2 + M$ (σ_2)	$-1 + 2M$ (σ_3)	$-M$ (σ_4)	0	0	0	

③选择步骤②中计算出的较小的值对应的变量 x_7 作为出基变量

②,常数 b 除以入基变量 x_3 大于0的系数 (如果有系数小于0, 将计算后的值看做无穷大)

除以大于0的数

得到

三、对偶理论

(7条消息) 【运筹学】对偶理论总结 (对称性质 | 弱对偶定理 | 最优性定理 | 强对偶性 | 互补松弛定理) ★★ 对称式的对偶问题中的“对称”是指什么。韩曙亮的博客-CSDN 博客

1、对偶问题的理解：

- **生产**：目标函数追求 **利润最大化**，约束方程设备的使用时长受约束，**小于等于** 某个时间值；
- **出租设备**：目标函数追求 **租金最小化**，约束方程设备产生的利润要 **大于等于** 生产的利润，不能亏钱；

2、对偶松弛定理：

互补松弛性：最优解的充要条件

$$(Ax - b)^T y = 0 \text{ 和 } x^T (A^T y - c^T) = 0$$

$$x_s^T y = 0 \text{ 和 } x_s^T y_s = 0$$

先将问题的对偶解算出来，得到对偶解的值（条件 1），代入对偶问题的不等式可得到对偶问题不等式是否为严格不等式（条件 2）

条件 1：说明对偶问题的解如果不为 0，原问题的对应解为等式（即 $AX - b = 0$ ），

条件 2：反之如果将对偶问题解代入可得为严格不等式，则原问题的对应解为 0。

3、对偶的自反性：问题的对偶的对偶是原问题

原问题与对偶问题的对应关系

原问题		对偶问题
约束	↔	原变量
原变量	↔	约束
原变量	↔	松弛变量
松弛变量	↔	原变量
基解	↔	检验数
检验数	↔	基解

4、对偶单纯形法：

对偶单纯形法思路：

单纯形法思路：

保持 y 为可行解，使 x 演变为可行解

单纯形法：找基 B ，满足 $B^{-1}b \geq 0$ ，若 $c - c_B B^{-1}A$ 不全 ≤ 0 ，（即检验数）。

对偶单纯形法：找基 B ，满足 $c - c_B B^{-1}A \leq 0$ ，但 $B^{-1}b$ 不全 ≥ 0

迭代  保持 $B^{-1}b \geq 0$ ，使 $c - c_B B^{-1}A \leq 0$

保持 x 为可行解，使 y 演变为可行解

迭代  保持 $c - c_B B^{-1}A \leq 0$ ，使 $B^{-1}b \geq 0$

主要在选择出基和入基变量上以及最优性检验上不太相同：

2. 如果所有的 $b_i > 0$ ，已是最优解

否则：(1)取 x_r 为出基变量，满足

$$b_r = \min_i \{b_i < 0\} \quad i = 1, \dots, m$$

(2)取 x_s 为入基变量，满足

$$\theta' = \frac{\sigma_s}{a_{rs}} = \min_i \left\{ \frac{\sigma_j}{a_{rj}} \mid a_{rj} < 0, j = 1, \dots, n \right\}$$

3. 最优性检验

判断迭代后所有的 $b_i' > 0$? 如果不满足，继续迭代

5、灵敏度分析：

灵敏度分析指最优解在参数、约束条件或变量个数发生变化时的影响。

通常有**两类问题**：

(1) 参数变化时，**最优解**如何变？

(2) **最优解/最优基**保持不变，参数变化的范围。

四、运输规划

[\(7 条消息\) 【运筹学】运输规划、表上作业法总结 \(运输规划模型 | 运输规划变量个数 | 表上作业法 | 最小元素法 | 差额 Vogel 法 ★ | 闭回路法 \) ★★★_最大差额法运筹学_韩曙亮的博客-CSDN 博客](#)

1、运输问题的方法

(1) 两种表上作业法找初始基变量的方法：最小元素法、差额法

(2) 检验最优解方法：闭回路法（在基变量处可转可不转，在非基变量处只能执行转，计算的各个转弯点处的一个+一个-计算和）

(3) 换基方法：对检验数小于 0 的，作为入基变量（新的基变量），选择其路径转弯处为-号的变量中运费最小的一个为出基变量

2、运输规划的秩： $m+n-1$ (m 个行约束（运出地）， n 个列约束（运入地）），产销平衡导致约束变量-1

单纯形法变量数目： $m \times n + (m+n-1)$

五、整数规划

宗旨是先求松弛问题，再根据松弛问题求其最近的整数解。松弛问题是将整数约束山区变为一般线性规划问题。


整数规划的约束是各解都为整数，且得到的目标函数结果也为整数。

1、整数规划的求解方法

(1) 分支定界法：

[\(7 条消息\) 【运筹学】整数规划、分支定界法总结 \(整数规划 | 分支定界法 | 整数规划问题 | 松弛问题 | 分支定界法 | 分支定界法概念 | 分支定界法步骤 \) ★★ 分支定界法求解整数规划 韩曙亮的博客-CSDN 博客](#)

每次将 x_i 分两部分讨论，一个 x_i 讨论完后，讨论基解其他 x_i 的值。直到满足整数规划的约束。



在松弛问题得到结果基础上把每个变量分为上下最接近的两个整数，看得到的其他解是否为整数解，如果不是继续将这一不是的解继续分为两部分，知道分叉树所有解都得到了整数满意解，选择其中的最符合的那个。

可用于求混合整数规划问题和纯整数规划问题，因为可以分每个变量是否需要满足整数约束进行讨论，更快，更灵活。

(2) 割平面法：

需要综合应用对偶单纯形法和单纯形表

[\(7 条消息\) 运筹学教学|十分钟快速掌握割平面法及对偶单纯形法 \(附 Java 代码及算例\) _对偶法求分割面 zll hust 的博客-CSDN 博客](#)

构造割平面方法：采用整数约束条件进行变量替换得到。

方法为利用整数约束条件引入新变量构成新的松弛问题（该问题相比于原问题多了一个变量，多了一个约束），解该松弛问题，看所有解是否为整数符合约束条件

割平面的一般形式：

$$f_{i_B} - \sum_{j_N \in N} f_{i_B j_N} x_{j_N} \leq 0$$

割平面的取法并不唯一，可选 f_{i_B} 最大的一个。

如果一个割平面不够，则在松弛问题1的基础上，继续构造割平面。

收敛速度经常很慢，常与分枝定界法配合使用！

2、0-1 指派问题（匈牙利法）

匈牙利法的原则在于同时增减各行或各列的元素对结果无影响。

(7条消息) 运筹学_韩曙亮的博客-CSDN 博客

匈牙利算法

指派问题最优解的性质：

若将指派问题的系数矩阵 $C = (c_{ij})_{n \times n}$ 的某行或某列减去一个常数，得到的新的系数矩阵 C' ，则对应的两个指派问题具有相同的最优解。

方法：

变换系数矩阵 C ，找到 n 个位于不同行、不同列的零元素，则对应的指派最优。

因此第一步就是给所有的行或列减去同一个数，尽可能使其变小。产生很多 0，挑选独立零元素（不同行、不同列的 0），按要求打勾，最终目的是得到 n 个不同行、不同列的零元素。

六、目标规划

目标规划是线性规划的最后一种变式，他的特点在于目标规划是多目标的要求，对于各个目标有优先级的要求，同时各个目标还可以超出或缺乏（也就是达到和不达到均需列入）

1、目标规划的特点

线性规划要求找到最优解，目标规划要求找到满意解，线性规划的约束为刚性约束，目标规划的约束为软约束，即约束可能无法满足绝对 $\leq$ 或 $\geq$ 的刚性约束，但是可以使其约束的超出量或相差量尽可能小。

目标规划的目标可以设定优先级。

软约束

$$100x_1 + 80x_2 + d^- - d^+ = 10000$$

引入偏差变量：

d^+ ：决策值超过目标值部分(正偏差变量)

d^- ：决策值不足目标值部分(负偏差变量)

满足 $d^+ \geq 0, d^- \geq 0, d^+ \cdot d^- = 0$

相同优先级的目标给予同样的优先因子，对于其中还可以给予权系数 W ，权系数越大同级中的重要性也越高。

2、目标规划的方法：

(1) 在各不等式后加 $+$ $-$ 两个松弛变量，用于表示超出和缺少的量。（变为软约束）

(2) 给目标函数各目标加一个优先因子 P （建立优先级）

3、目标规划的解法：

(1) 集中求解：采用集中单纯形法，列一张单纯形表，只有一个目标函数，但是有多个检验数，每个检验数按优先因子大小不同，计算不同。

优先因子

则原目标函数为：

$$\min\{P_1 d_1^+, P_2(d_2^- + d_2^+), P_3(d_3^-)\}$$

$$\min Z = P_1 d_1^+ + P_2(d_2^- + d_2^+) + P_3(d_3^-)$$

为了说明目标的优先性，定义了优先因子 P_i ：

$$P_i \gg P_{i+1} > 0$$

即目标 i 比目标 $i+1$ 具有绝对的优先权

(2) 序贯算法：按不同优先级的目标一个一个满足后算下一个目标。

目标规划的序贯式算法

基本思路：按优先级的顺序，从最高级开始，逐个满足目标。

具体方法：将已计算目标函数值，作为下一级目标的硬约束。

可以用单纯形表分多部解决问题，但是计算量较大。

七、非线性规划的解析解法

类型一：无约束情况

1、一阶求梯度为零点

一阶极值条件（必要条件）

驻点条件 $\nabla f(\mathbf{x}^*) = \left. \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*} = \mathbf{0}$

梯度 $\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \frac{\partial f(\mathbf{x})}{\partial x_2} \\ \vdots \\ \frac{\partial f(\mathbf{x})}{\partial x_n} \end{bmatrix}$

梯度的几何性质：

➤ $\nabla f(\mathbf{x})$ 与目标函数等值面的切面正交，为等值面在 $\mathbf{x}$ 的法向量

➤ $\mathbf{x}$ 的梯度方向 $\nabla f(\mathbf{x})$ 是 $\mathbf{x}$ 点目标函数值 $f(\mathbf{x})$ 增长最快的方向

$$f(\mathbf{x} + \lambda \mathbf{p}) - f(\mathbf{x}) \approx \lambda \nabla f(\mathbf{x})^T \mathbf{p}$$

2、二阶验证矩阵为正定矩阵（强最优，充分）、非负定矩阵（弱最优，必要）

二次型： $\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$ $\mathbf{A}$ 为对称矩阵

$\forall \mathbf{x} \neq \mathbf{0} \quad \mathbf{x}^T \mathbf{A} \mathbf{x} > 0 \quad \longrightarrow \quad \mathbf{A} > 0$ 正定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0 \quad \longrightarrow \quad \mathbf{A} \geq 0$ 半正定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} < 0 \quad \longrightarrow \quad \mathbf{A} < 0$ 负定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} \leq 0 \quad \longrightarrow \quad \mathbf{A} \leq 0$ 半负定矩阵

■二阶必要条件：（局部极小值）

$$\nabla f(\mathbf{x}^*)=0 \text{ 且 } \nabla^2 f(\mathbf{x}^*) \geq 0$$

■二阶充分条件：（严格局部极小值）

$$\nabla f(\mathbf{x}^*)=0 \text{ 且 } \nabla^2 f(\mathbf{x}^*) > 0$$

类型二：有约束情况：

1、等式条件约束：拉格朗日乘数法（类似微积分）

2、可行方向与下降方向

可行方向：沿该方向，移动无限小步后依然还在可行域内，几何意义为与所有约束梯度方向一致，满足 $g(\mathbf{x}) > 0$ 的要求。

下降方向：沿该方向，移动无限小步后目标函数的值减小，几何含义为与目标函数负梯度方向一致（即下降方向一致）

3、不等式约束：库恩塔格条件

[KKT 条件，原来如此简单 | 理论+算例实践 - 知乎 \(zhihu.com\)](#)

类似于在找到最值点后，分成是直接满足还是条件最值满足两种情况。

➤若 $\mathbf{x}^*$ 是局部极小点，存在不全为零的非负实 $\mu_j \geq 0, j=1,2,\dots,l$ ，使

$$\text{Fritz John条件} \begin{cases} \mu_0 \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j \nabla g_j(\mathbf{x}^*) = \mathbf{0} & \text{Lagrange函数驻点条件} \\ \mu_j g_j(\mathbf{x}^*) = 0 & j=1,2,\dots,l \quad \text{互补松弛条件} \\ \mu_j \geq 0 & j=0,1,\dots,l \quad \text{非负条件} \end{cases}$$

上述条件隐含了如下事实： $j \notin J(\mathbf{x}^*) \Rightarrow g_j(\mathbf{x}^*) > 0 \Rightarrow \mu_j = 0$

FJ 条件之所以不是二次最优的充分条件是由于 μ_0 不一定非0，当 $\mu_0=0$ 时，对 f 的梯度将消去，此时各个起作用的约束线性相关，条件失效，因此只要给各个起作用的梯度加上线性无关的约束即可，得到著名的 KKT 条件：

➤若 $\mathbf{x}^*$ 是局部极小点，起作用约束的 $\nabla g_j(\mathbf{x}^*)$ 线性无关[约束规格(constraint qualification)]，则下列条件成立：

$$\begin{aligned} \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) &= \mathbf{0} \\ \mu_j^* g_j(\mathbf{x}^*) &= 0 & j=1,2,\dots,l & \text{Karush(1939)} \\ \mu_j^* &\geq 0 & j=1,2,\dots,l & \text{Kuhn-Tucker (1951)} \end{aligned}$$

可全为0

KKT 条件依然只是极小点的必要条件，当规划为凸规划问题时，过渡到充要条件。

KKT 条件的几何意义：目标函数的梯度方向向量和约束的梯度方向向量共线且方向相同。

（几何意义的证明具体见上 KKT 条件链接）

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad g_j(\mathbf{x}) \geq 0 \quad j=1,2,\dots,l$$

（几何意义相对于该形式而言）

4、一般约束：结合不等式约束和等式条件约束两种

广义Lagrange函数法

定义Lagrange函数

$$L(\mathbf{x}, \boldsymbol{\gamma}, \boldsymbol{\mu}) = f(\mathbf{x}) - \sum_{i=1}^m \gamma_i h_i(\mathbf{x}) - \sum_{j=1}^l \mu_j g_j(\mathbf{x})$$

类似无约束极值问题，得到：

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0} \quad \text{Lagrange驻点条件}$$

$$\mu_j^* g_j(\mathbf{x}^*) = 0 \quad j = 1, 2, \dots, l \quad \text{互补松弛条件}$$

$$\mu_j^* \geq 0 \quad j = 1, 2, \dots, l \quad \text{非负条件}$$

$$h_i(\mathbf{x}^*) = 0 \quad i = 1, 2, \dots, m \quad \text{可行性条件}$$

$$g_j(\mathbf{x}^*) \geq 0 \quad j = 1, 2, \dots, l$$

h 为等式约束，g 为不等式约束

八、非线性规划的数值解法

类型一：无约束数值解法：

1、基于梯度的数值解法：

最优化：线搜索中有最速下降法、牛顿法、拟牛顿法、共轭梯度法，那么他们分别时候用啊？

- 知乎 (zhihu.com)

(1) 最速下降法/梯度下降法：其下降方向是沿附近点负梯度方向，易计算，具有全局收敛性，从任意处开始都会收敛到一个局部极小值。

在极值点附近会存在摆动，收敛很慢，不一定能在有限步收敛到极点（无二次终止性），一般用于收敛前期使其到达极值点附近。（需要进行最优搜索得到最优步长）

(2) 牛顿法：下降方向是直接指向极值点（不需要进行最优搜索，直接通过求逆得到步长）

牛顿法

$$\frac{d(\mathbf{k}^T \mathbf{x})}{d\mathbf{x}} = \mathbf{k}$$

$$\frac{d\left(\frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x}\right)}{d\mathbf{x}} = \mathbf{A} \mathbf{x}$$

■ 设计思想：直接指向极值点。

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

$$\text{两边对 } \mathbf{x} \text{ 求导} \quad \longrightarrow \quad \nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

$$\mathbf{x} = \mathbf{x}^* \quad \longrightarrow \quad \nabla f(\mathbf{x}^*) = 0 \approx \nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x}^* - \mathbf{x}^{(k)})$$

$$\longrightarrow \quad \mathbf{x}^* \approx \mathbf{x}^{(k)} - [\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$$

$$\longrightarrow \quad \mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)}) \quad \text{迭代方向}$$

优点：极值点附近收敛速率快。

缺点：计算量大，需要二阶导数和矩阵逆。

远离极值点时，牛顿方向不一定是下降方向。

应用场合：二次目标函数或极值点附近，通常需采用进一步修正。

【最优化】无约束优化方法-牛顿法 - 知乎 (zhihu.com)

LM 修正：保证牛顿法方向为下降方向， $\mu=0$ ，牛顿法， $\mu=\infty$ ，最速下降法。

拟牛顿法：用当前迭代值点代替求二阶导数和逆的 $\mathbf{x}$ （未知量），以避免求二阶导数和逆

(3) 变尺度法：

➤ 目标：给出一种求取 H_k 的方法

由Davidon提出，Fletcher和Powell改进，也称DFP算法。

迭代方向： $p^{(k)} = -H_k \nabla f(x^{(k)})$

$$H_{k+1} = H_k + \Delta H_k \quad H_1 = I$$

$$\Delta H_k = \frac{\delta_k \delta_k^T}{\delta_k^T \gamma_k} - \frac{H_k \gamma_k \gamma_k^T H_k}{\gamma_k^T H_k \gamma_k}$$

$$\delta_k \triangleq x^{(k+1)} - x^{(k)} \quad \gamma_k \triangleq \nabla f(x^{(k+1)}) - \nabla f(x^{(k)})$$

可以证明：1、 H_k 满足拟牛顿条件，为Hesse矩阵的逆。

2、当目标函数为正定二次函数时，可经有限步迭代收敛于极值（二次终止性）。为什么不是1步？

(4) 共轭梯度法：

- 共轭方向定义：若 A 正定，且 $p^{(1)}$ 和 $p^{(2)}$ 满足 $p^{(1)T} A p^{(2)} = 0$ ，则 $p^{(1)}$ 、 $p^{(2)}$ 关于 A 共轭。（共轭是正交概念的推广）
 $\Rightarrow$ 若 $p^{(1)}$ 、 $p^{(2)}$ 称关于 A 共轭，则 $p^{(1)}$ 和 $A p^{(2)}$ 正交。


- 二次凸函数： $f(x) = 1/2 (x - x^*)^T A (x - x^*)$

➡ $\nabla f(x) = A(x - x^*)$

$p^{(1)} := p_1$ ($x^{(2)}$ 点切线方向)

$p^{(2)} := -(x^{(2)} - x^*)$

➡ $p^{(1)T} A p^{(2)} = -p_1^T \nabla f(x^{(2)}) = 0$



共轭梯度法需要进行一维最优步长搜索，同时可以有限步逼近

- 共轭方向组定义：若 A 是 n 阶正定矩阵，且 $p^{(1)}, p^{(2)} \dots p^{(k)}$ 为 k 个关于 A 两两共轭的方向，则称这组方向关于 A 共轭。

- 性质： $k \leq n$ ，则 A 的 k 个非零共轭方向线性无关。（反证法）

$$\sum_{i=1}^k \alpha_i p^{(i)} = 0 \quad \Rightarrow \quad \sum_{i=1}^k \alpha_i p^{(i)T} A p^{(j)} = \alpha_j p^{(j)T} A p^{(j)} = 0 \quad \Rightarrow \quad \alpha_j = 0$$

- 定理：沿着 A 的 n 个非零共轭方向依次做一维最优步长搜索，则最多经过 n 步可找到二次凸函数的极小值。

可见只要按非零共轭方向做 n 次最有搜索，最多 n 次即可得到极值。

2、迭代步长的选择：

固定步长：如0.618法，斐波那契法，使用为梯度下降法

最优步长：基于梯度计算当前的最优步长

目标： $\lambda_k = \arg \min_{\lambda} f(x^{(k)} + \lambda p^{(k)})$

$$f(x^{(k)} + \lambda p^{(k)}) = f(x^{(k)}) + \lambda \nabla f(x^{(k)})^T p^{(k)} + \frac{1}{2} \lambda^2 p^{(k)T} \nabla^2 f(x^{(k)}) p^{(k)} + O(\lambda^2)$$

$$\text{极小值} \quad \Rightarrow \quad \frac{df(x^{(k)} + \lambda p^{(k)})}{d\lambda} \approx \nabla f(x^{(k)})^T p^{(k)} + \lambda p^{(k)T} \nabla^2 f(x^{(k)}) p^{(k)} = 0$$

$$\Rightarrow \quad \lambda^* = \frac{-\nabla f(x^{(k)})^T p^{(k)}}{p^{(k)T} \nabla^2 f(x^{(k)}) p^{(k)}}$$

特点：1、解析解，不需迭代

2、需求Hesse矩阵

3、 $x^{(k)} + \lambda p^{(k)}$ 未必是极小值

注意得到的最优步长不一定是最短步长。

最速下降法即为使用步长为最优步长的算法，其具有最优步长时，前后两步梯度必定垂直的性质。

3、迭代终止原则：

绝对误差准则，相对误差准则（前后两次迭代后的点的位置距离小于某一规定值），
梯度模准则（前后两次的梯度模比或本次的梯度模小于某一规定值）

类型二：有约束极值问题数值解法：

可行方向法，制约函数法，逐次逼近法

1、可行方向法：Zoutendijk 可行方向法

简要方法是寻找一个最优可行下降方向 d （目标函数梯度反向，制约函数梯度同向），引入 η 构建线性规划问题，如果 $\eta=0$ ，则无可行下降方向，得到最小点，如果 $\eta<0$ ，则可行下降方向 d ，再用一维极值方法得到最佳步长即可。具体见书 P102。

2、制约函数法（序列无约束最小化方法）：

核心思想是将有约束问题转化为一系列无约束极值问题。

方法分类：外点法。内点法，混合法

(1) 外点法：设定罚函数，使得违反约束在可行域外的点向可行域内逼近。

● 构造罚函数

$$\min P(\mathbf{x}, M_k) = f(\mathbf{x}) + M_k \sum_{i=1}^m h_i^2(\mathbf{x}) + M_k \sum_{j=1}^l [\min(0, g_j(\mathbf{x}))]^2$$

M 较大，为惩罚因子，当其不符合约束条件时，会导致后一项较大产生惩罚。

1、只有 $M \rightarrow \infty$ ，才保证 $\lambda^*(k) \rightarrow \lambda^*$ 、 $\mu^*(k) \rightarrow \mu^*$ ， $\mathbf{x}_k^* \rightarrow \mathbf{x}^*$ 。
为减小收敛点的误差，需 $M_k \rightarrow \infty$ 。

2、 M_k 过大，有可能导致 Hesse 矩阵病态（条件数很大），极小值将位于狭长的深谷，导致目标函数值对搜索方向敏感。

$$\text{cond}(\mathbf{H}) = \|\mathbf{H}\| \cdot \|\mathbf{H}^{-1}\| \geq \lambda_{\max} / \lambda_{\min}$$

3、改进策略

1) 设计精确罚函数（例如 I_1 罚函数），令有限 M_k 的 $P(\mathbf{x}, M_k)$ 驻点恰好为 $\mathbf{x}^*$ 。

2) 构造增广 Lagrange 函数对罚函数进行修正，在有限 M_k 时也能使 $\mathbf{x}_k^*$ 逼近最优解 $\mathbf{x}^*$ 。

(2) 内点法：设定障碍函数，使得一直在可行域内部的点无法穿越边界，有“障碍约束”，在可行域内找到原问题的最优解。

● 构造障碍函数

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r) = f(\mathbf{x}) + r \sum_{j=1}^l \frac{1}{g_j(\mathbf{x})}$$

或

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r) = f(\mathbf{x}) - r \sum_{j=1}^l \log g_j(\mathbf{x})$$

其中 $R_0 = \{\mathbf{x} | g_j(\mathbf{x}) > 0, j=1, 2, \dots, l\}$ 严格内点

$r > 0$ 为障碍因子，其在迭代中的取值会不断减小，趋向于 0，使 $\mathbf{x}$ 可趋向于边界。

(3) 混合法：（两种方法的使用情景）

- 内点法不能处理等式约束问题
- 外点法不能处理目标函数在可行域外不存在的问题
- 对等式约束和当前不被满足的不等式约束，使用罚函数法，对满足的不等式约束，使用障碍函数法。

3、逐次逼近法：通过近似，将一般约束极值问题转化为易求解的规划问题

方法：序贯线性规划法 SLP 和序贯二次规划法 SQP

九、动态规划问题

1、名词解释/基本概念：

(1) 阶段：问题过程，按时间、空间的特征分解成若干相互联系的阶段。

(2) 状态：

2. 状态：

k 阶段开始时的客观条件，记为 $s_k \in S_k$ 。

S_k 为 k 阶段状态集合。

如例2中，
 $S_1 = \{A\}$
 $S_2 = \{B_1, B_2, B_3\}$
 $S_3 = \{C_1, C_2\}$
 $S_4 = \{D_1, D_2, D_3\}$

注意：上述定义将导致问题的逆序求解，顺序求解时状态定义为阶段结束时的客观条件。

(3) 决策

3. 决策：

依据状态做出的决定，记为 $u_k(s_k) \in D_k(s_k)$ ，
 $D_k(s_k)$ 为状态 s_k 的允许决策集合。

例2中：

$D_1(A) = \{B_1, B_2, B_3\}$ $u_1(A) = B_i \quad i=1,2,3$

$D_2(B_1) = \{C_1, C_2\}$ $u_2(B_1) = C_i \quad i=1,2$

(4) 策略

各阶段决策依次构成的决策序列。记为

$p_{1,n} = \{u_1(s_1), u_2(s_2), \dots, u_n(s_n)\} \in P$
 P 为允许策略集合。

例2中

允许策略的总数为： $3 \times 2 \times 3 \times 1 = 18$

动态规划的目的是要选择最优的一种策略


(5) 后部子策略和子过程

后部子过程策略，从 k 阶段开始到终了阶段的决策子序列，记为

$$p_{k,n}(s_k) = \{u_k(s_k), u_{k+1}(s_{k+1}), \dots, u_n(s_n)\} \in P_{k,n}(s_k)$$

(6) 指标函数

评价沿子策略 $p_{k,n}$ 过程性能优劣的函数，记为 $V_{k,n}(s_k, p_{k,n})$ 。



$$V_{4,4}(D_1, p_{4,4}) = V_{4,4}(D_1, u_4) = v_4(D_1, E) = 3$$

指标函数的可分离性

φ_k 的常见的形式有：

为了实现动态规划的递推结构，要求

$$V_{k,n}(s_k, p_{k,n}) = V_{k,k}(s_k, u_k) + V_{k+1,n}(s_{k+1}, p_{k+1,n})$$

指标函数具有可分离性

$$V_{k,n}(s_k, p_{k,n}) = \varphi_k(s_k, u_k, V_{k+1,n}(s_{k+1}, p_{k+1,n}))$$

$$= v_k(s_k, u_k) + V_{k+1,n}(s_{k+1}, p_{k+1,n})$$

$$= \sum_{j=k}^n v_j(s_j, u_j)$$

阶段指标函数

φ_k 是 $V_{k+1,n}(s_{k+1}, p_{k+1,n})$ 的严格单调函数。

指标函数一般可有这一阶段的决策与决策的前提下的指标函数之和的最小值来决定。

2、最优化原理和最优化定理：

最优化原理：最优策略的子策略是对应子问题的最优策略（必要条件）

最优化定理：子问题的局部最优将导致整个问题的全局最优，即问题具有最优子结构的性质，也就是说一个问题的最优解只取决于其子问题的最优解，而非最优解对问题的求解没有影响。在最短路径问题中，A到E的最优路径上的任一点到终点E的路径，也必然是该点到终点E的条最优路径，即整体优化可以分解为若干个局部优化。

3、状态无后效性：

某阶段的状态一旦确定，则此后过程的演变不再受此前各状态及决策的影响。

给定某阶段的状态 s_k ，则以后各阶段的状态 s_l ($l > k$) 都只受 s_k 的影响，与之前的状态无关。(不只是与过去无关，而是未来只与现在这一个状态有关)

4、动态规划的逆序解法和顺序解法：

顺序解法和逆序解法本质上没有区别，只是其各个状态对应的条件不同。

顺序法：

顺序法：第一步指标函数为0，下一步的指标函数为这一步的所有策略与之前的指标函数之和取最小值（每个对应的指标函数都是其前策略的最小值）

逆序法：最后一步指标函数为0。前一步的指标函数为该步到后一步的策略与其对应指标函数之和，取最小值。

顺序解法迭代方式:

$$f_k(s_{k+1}) = \underset{u_k \in D_k(s_{k+1})}{opt} (v_k(s_{k+1}, u_k) + f_{k-1}(s_k))$$

$$f_0(s_1) = 0$$

k阶段状态

逆序解法:

$$f_k(s_k) = \underset{u_k \in D_k(s_k)}{opt} (v_k(s_k, u_k) + f_{k+1}(s_{k+1}))$$

$$f_{n+1}(s_{n+1}) = 0$$

十、图论和网络分析

1、基本概念: 邻接矩阵 (表示路的通断), 权矩阵 (表示路的难度)

树、网络、链与道路、生成树、生成子图、

2、最短路径问题

(1) Dijkstra 算法: (不能跑最长路, 权系数中用无穷代表断点, 无法求出最长更新值)

Dijkstra算法

■ P点: 已确定最短路径的点, 长度为 $P(v_i)$ 。

■ T点: 未确定 $P(v_i)$ 的点, 但已知当前步起点 v_1 到 v_i 距离的最小值, 记为 $T^{(k)}(v_i)$ 。

1、设定初值

$$T^{(0)}(v_1) = 0 \quad T^{(0)}(v_j) = \infty \quad j=2,3,\dots,n$$

2、确定P点

$$P(v_i) = \min_j \{T^{(k)}(v_j)\}$$

3、更新T值

$$T^{(k+1)}(v_j) = \min_i \{T^{(k)}(v_i), P(v_i) + l_{ij}\} \quad l_{ij} = \begin{cases} d_{ij} & (i,j) \in E \\ +\infty & (i,j) \notin E \end{cases}$$

大致流程就是先确定一个起始出发点一个终点 (但是其实 D 算法会在过程中把除起始点以外所有点的最值都算出来), 然后每次从已求出最短路径的点出发再找一个最短点 (P), 同时记录其他各个点的路径长度 (T), 如此遍历直到所有点的最短路都求出来。

所以实际纳入 P 点 (也就是确定最短路径的点) 的点的顺序是按最短路径的长度从小到大来算出来的。

Dijkstra 算法的优缺点:

贪心算法, 时间复杂度为 $O(N^2)$ 缺点: 不适用于路径权值为负数的图。

与动态规划不同之处: 动态规划需要对下一级所有的可连接点进行遍历, 可能对已得到最短问题解的点也进行更新, 对已经升级为 P 点的点也进行更新

(2) 逐次逼近法 (实际为动态规划)

可以用于路径权值为负的图

1、设定初值

$$T^{(0)}(v_1) = 0 \quad T^{(0)}(v_j) = \infty \quad j=2,3,\dots,n$$


2、更新T值

$$T^{(k+1)}(v_j) = \min_i \{T^{(k)}(v_i) + l_{ij}\} \quad l_{ij} = \begin{cases} d_{ij} & (i,j) \in E \\ +\infty & (i,j) \notin E \end{cases}$$

3、收敛条件

$$T^{(k+1)}(v_j) = T^{(k)}(v_j) \quad j=1,2,\dots,n$$

例 计算从点 v_1 到所有其它顶点的最短路



$$P_{1j}^{(0)} = w_{1j}$$

解：初始条件为 $P_{11}^{(0)} = 0, P_{12}^{(0)} = 2, P_{13}^{(0)} = 5, P_{14}^{(0)} = -3$

以后按照公式 $P_{1j}^{(k)} = \text{Min}_{1 \leq i \leq n} \{ P_{1i}^{(k-1)} + w_{ij} \}$ 进行迭代。

直到得到 $P_{1j}^{(t)} = P_{1j}^{(t-1)}$ ，迭代停止。

N 为点的个数。

(3) floyd 算法

Floyd算法

权矩阵： $D^{(k)} = (d_{ij}^{(k)})_{n \times n}$

初值： $D^{(0)} = (d_{ij}^{(0)})_{n \times n} = (l_{ij})_{n \times n}$ $l_{ij} = \begin{cases} d_{ij} & (i, j) \in E \\ +\infty & (i, j) \notin E \end{cases}$

$$d_{ij}^{(k)} = \min \{ d_{ij}^{(k-1)}, d_{ik}^{(k-1)} + d_{kj}^{(k-1)} \} \quad k=1, 2, \dots, n$$

最多经过前 $k-1$ 个节点的最短路径

3、最大流问题：

■最大流问题：求网络的最大可行流

$$\max f = \sum_k x_{kt} = \sum_j x_{sj} \quad \begin{array}{l} s \text{ 起点/源source} \\ t \text{ 终点/汇sink} \end{array}$$

$$\text{s.t.} \quad \sum_k x_{ki} = \sum_j x_{ij} \quad \begin{array}{l} i \neq s, i \neq t \\ i=1, 2, \dots, n \end{array} \quad \text{流量平衡条件}$$

$$0 \leq x_{ij} \leq u_{ij} \quad i, j=1, 2, \dots, n \quad \text{容量限制条件}$$

正向饱和：等于边的最大流量为正向饱和边

反向饱和：反向等于 0

最大流性质

➤ **现象**：若存在连接起点和终点的链的每一条边都是不饱和边，即存在可增广链，则可使总流量增加。

➤ **性质**：两点间的可行流为最大流的充要条件是：
网络不存在可增广链

因此问题变化为使得网络没有可增广链。因此先找一条不饱和边，再逐步调整流量知道所有边饱和。

4、最大流和最小割问题：将整个流网络分割为两个割集

割集容量：对网络 $G=(V,E,U)$ ， E' 为将起点 v_s 和终点 v_t 分离在S、T两部分的割集，则割集容量 $U(E')$ 为所有起点在S、终点在T的边的容量之和。

定理1：设 f 为网络 $G=(V,E,U)$ 的任一可行流， E' 为将起点 v_s 和终点 v_t 分离的割集，则有 $f \leq U(E')$

定理2：网络 G 中，从 v_s 到 v_t 的最大流等于分离 v_s 和 v_t 的最小割的容量

5、最小消费流问题：

最小费用流问题解题思路

思路：1。先寻找一个初始最小费用可行流 $f_0 < f_g$

2。沿着可增广链增加 $f = f_0 + \Delta$ ，使 $f \rightarrow f_g$

最小费用可增广链的寻找

■ 长度网络 $L(f)$

1。 $(v_i, v_j) \in E$,

$$l_{ij} = \begin{cases} c_{ij} & x_{ij} < u_{ij} \\ +\infty & x_{ij} = u_{ij} \end{cases} \quad \text{饱和边不可增加流量}$$

2。 $(v_i, v_j) \in E$ ，考虑反向边

$$l_{ji} = \begin{cases} -c_{ij} & x_{ij} > 0 \\ +\infty & x_{ij} = 0 \end{cases} \quad \text{饱和边不可增加流量}$$

求 f 的最小费用可增广链 $\Leftrightarrow$ 求 $L(f)$ 中起点与终点间的最短路

十一、对策论

- 1、概念：3 要素——局中人、策略集、赢得函数/支付函数
- 2、矩阵博弈（有限零和博弈）

纯策略矩阵博弈模型

博弈模型 $G = \{I, II; S_1, S_2; A\}$

➤ 局中人 I、II

➤ 策略集

$$S_1 = \{\alpha_1, \alpha_2, \dots, \alpha_m\}$$

$$S_2 = \{\beta_1, \beta_2, \dots, \beta_n\}$$

➤ 局中人 I 的赢得矩阵： A

➤ 局中人 II 的赢得矩阵： $-A$

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

3、理性博弈原则：

- 自身利益最大化原则：自身的赢得值尽可能大
- 共许原则：双方均无改变策略的意愿

自身利益最大化原则

- 问题：不确定对方决策情况下的最优决策
- 准则：从最坏的预期中选则最好的（悲观准则）
一种保守而贪心的准则
“做最坏的打算，争取最好的结果”

➤ 局中人 I 最大预期赢得（赢得指自身最小收益）

极大极小值： $\max_i \min_j a_{ij}$

➤ 局中人 II 最小预期损失（损失指对手最大收益）

极小极大值： $\min_j \max_i a_{ij}$

4、最优策略对

极大极小值和极小极大值

- 两者之间的关系： $\max_i \min_j a_{ij} \leq \min_j \max_i a_{ij}$

最优纯策略对

➤ 如果存在

$$\max_i \min_j a_{ij} = \min_j \max_i a_{ij} = a_{i^*, j^*} \triangleq V_G$$

则 $(\alpha_{i^*}, \beta_{j^*})$ 为矩阵博弈的**最优纯策略对**，也称为**最优局势**。 V_G 称为博弈值。

■ 矩阵博弈最优纯策略对存在的充要条件是存在鞍点。

$$a_{ij^*} \leq a_{i^*j^*} \leq a_{i^*j} \quad \text{鞍点条件}$$

$$\begin{array}{c} a_{ij^*} \leq a_{i^*j^*} \leq a_{i^*j} \\ \Rightarrow \max_i a_{ij^*} \leq a_{i^*j^*} \leq \min_j a_{i^*j} \end{array}$$

j*列最大值**i*列最小值**

5、纳什均衡解的意义

Nash均衡解

鞍点解的博弈解释：没有一方愿意单方面改变策略，因为单方面改变策略均无法改善自身的赢得值，更多情况下反有损害。（共许原则）

这样的最优策略对具有一定稳定性，被称为**平衡局势**(Equilibrium Situation)、**均衡解**(Equilibrium Solution)，或直接简称为**解**(solution)。

纯策略博弈时：均衡解（鞍点） $\Rightarrow$ 最优纯策略对
解的可能性：单个解、多个解、无纯策略解